CESI
ÉCOLE D'INGÉNIEURS

Stockage & Big Data

CER | Architecture

Lundi 19 octobre 2026

Mazou Marine
Fisa Info 25–28
CESI

TABLE DES MATIÈRES

Étude de cas : Architecture Big Data **2**
AAV . . . 2
Rôles . . . 2
Mots clés . . . 3
Contexte . . . 3
Problématique . . . 3
Contraintes . . . 3
Généralisation . . . 4
Livrables . . . 4
Pistes de solutions . . . 4
Plan d'actions . . . 5

1 Définitions des mots clés **6**

2 Infrastructure et traitement distribués **10**
2.1 Cluster de serveurs et virtualisation . . . 10
2.2 Stockage : DAS, NAS et SAN . . . 10
2.3 Le cloud pour le stockage de données . . . 11
2.4 Système de fichiers distribué : HDFS . . . 12
2.5 Traitement distribué : MapReduce . . . 13
2.6 Difficultés des traitements distribués . . . 14

3 Entreposage et modélisation des données **15**
3.1 OLTP vs OLAP . . . 15
3.2 Fonctionnement d'une application d'entreposage . . . 16
3.3 Niveaux de modélisation . . . 16
3.4 Approches de conception d'un entrepôt . . . 17
3.5 Modèles de stockage : relationnel et NoSQL . . . 18
3.6 Modélisation dimensionnelle : étoile, flocon, constellation . . . 19
3.7 Choix pour le CHU . . . 20

4 Architecture du projet CHU **22**
4.1 Schéma d'architecture d'Archie . . . 22
4.2 Limites du schéma . . . 23
4.3 Proposition d'architecture . . . 23
4.4 Contraintes RGPD sur les données . . . 26

Conclusion **27**

Capitalisation **28**

Ressources **29**

ÉTUDE DE CAS : ARCHITECTURE BIG DATA

AAV

1 Identifier les contraintes sur les données liées au RGPD

2 Interpréter les 5V du Big Data

2 Décrire une architecture Big Data

2 Décrire une infrastructure de stockage distribuée (cluster de serveurs, virtualisation, NAS vs SAN, . . .)

2 Décrire l'utilisation du cloud dans le cadre du stockage de données

3 Présenter le traitement de données de manière distribuée (exemple : MapReduce)

2 Décrire le fonctionnement des systèmes de fichiers distribués

2 Décrire le fonctionnement d'une application d'entreposage de données

3 Concevoir un modèle dimensionnel (Data Mart)

1 Identifier les difficultés associées aux traitements distribués

RÔLES

- Animateur : Stéphane
- Secrétaire / Scribe : Marine
- Gestionnaire : Victor

MOTS CLÉS

- Big Data
- CHU
- Entrepôt de données
- Data Lake
- Cloudera
- Power BI
- RGPD
- Données multidimensionnelles
- Environnement virtualisé
- Modélisation des données
- Outil de planification

CONTEXTE

Votre équipe reprend le projet du groupe CHU (*Cloud Healthcare Unit*). Vous disposez de 3 semaines pour livrer une maquette complète d'entrepôt de données décisionnel pour le secteur hospitalier en repartant du schéma d'architecture Big Data et du modèle logique.

PROBLÉMATIQUE

Comment valider une architecture Big Data performante et concevoir le modèle logique d'un entrepôt de données décisionnel adapté aux données personnelles du projet CHU ?

CONTRAINTES

- Temps (2 jours)
- Budget
- L'existant (schéma d'architecture ; les données)
- Performances / Volumétrie
- Conformité / Légalité

GÉNÉRALISATION

- Big Data
- Architecture
- Datawarehouse
- Data Lake
- Virtualisation
- Cloud
- Cloudera
- Power BI
- Stockage
- Modélisation
- RGPD

LIVRABLES

- Une maquette d'architecture répondant aux besoins du projet
- Modèle logique / conceptuel de données

PISTES DE SOLUTIONS

- Se renseigner sur les styles d'architecture Big Data, le stockage distribué, les systèmes de fichiers distribués, les Data Lakes et l'évolution des architectures décisionnelles.
- Étudier le schéma de l'architecture produit par Archie et faire le lien avec les outils présents dans l'environnement virtualisé (comme Cloudera et Power BI).
- Explorer les fichiers de données situés dans le dossier « Mes documents » afin d'identifier les informations répondant aux analyses du cahier des charges.
- Appliquer les principes des bases de données multidimensionnelles et de l'entre-posage de données (Datawarehouse) pour démarrer la modélisation logique en parallèle.
- Se renseigner sur la protection des données à caractère personnel via la ressource « Data et RGPD » ainsi que sur les métiers de la data science.

PLAN D'ACTIONS

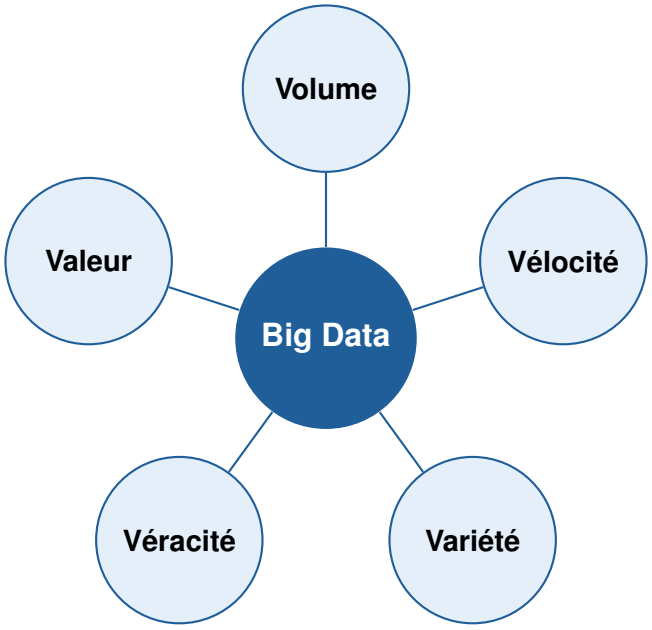
- Définir les mots clés liés au Big Data, à l'entreposage de données décisionnel et au RGPD.
- Étudier les ressources fournies sur l'architecture Big Data, le Datawarehouse, le Data Lake, la virtualisation, le stockage distribué et le RGPD.
- Analyser le schéma de l'architecture d'Archie et inspecter l'environnement virtualisé mis en place.
- Parcourir les données du dossier « Mes documents » en identifiant les données personnelles et les besoins d'analyse décrits dans le cahier des charges.
- Concevoir en parallèle la modélisation des données (modèle logique multidimensionnel) pour répondre aux exigences de performance.
- Valider le choix de l'architecture et le modèle logique dans le délai de 2 jours afin de préparer les phases suivantes (intégration, implémentation physique, exploitation et visualisation).

1 DÉFINITIONS DES MOTS CLÉS

Big Data: Le Big Data désigne des ensembles de données si volumineux, rapides ou variés qu'ils dépassent les capacités des outils de stockage et de traitement traditionnels (SGBD relationnel sur un seul serveur). On le caractérise classiquement par les **5 V** :

- **Volume** : des quantités de données massives (téraoctets, pétaoctets) ;
- **Vélocité** : des données produites et à traiter rapidement, parfois en temps réel ;
- **Variété** : des données structurées (tables), semi-structurées (JSON, XML, CSV) et non structurées (textes, images médicales) ;
- **Véracité** : la fiabilité et la qualité des données, à vérifier avant exploitation ;
- **Valeur** : l'intérêt métier que l'on peut tirer de l'analyse des données.

Pour y répondre, on distribue le stockage et les calculs sur un ensemble de machines (cluster) plutôt que d'augmenter la puissance d'un seul serveur.



CHU: Dans le sujet, CHU désigne le groupe *Cloud Healthcare Unit*, client du projet, qui souhaite disposer d'un entrepôt de données décisionnel pour le secteur hospitalier. Le terme renvoie aussi aux Centres Hospitaliers Universitaires, établissements qui produisent un grand volume de données de santé (patients, consultations, hospitalisations, actes, prescriptions). Ces données sont sensibles et soumises à une réglementation stricte.

Entrepôt de données (Data Warehouse): Un entrepôt de données est une base de données dédiée à l'analyse et à la prise de décision. Selon la définition de Bill Inmon, ses données sont :

- **orientées sujet** : organisées autour des thèmes métier (patients, séjours, actes) ;
- **intégrées** : issues de sources multiples puis harmonisées ;
- **non volatiles** : les données chargées ne sont ni modifiées ni supprimées ;
- **historisées** : conservées dans le temps pour suivre les évolutions.

Il est alimenté par un processus ETL (*Extract, Transform, Load*) et peut être découpé en **Data Marts**, des sous-ensembles dédiés à un service ou à un besoin d'analyse précis.

Data Lake: Un Data Lake (lac de données) est un espace de stockage qui conserve de grandes quantités de données **brutes**, dans leur format d'origine, qu'elles soient structurées ou non. Contrairement à l'entrepôt, le schéma n'est appliqué qu'au moment de la lecture (*schema-on-read*). Il repose généralement sur un système de fichiers distribué (HDFS) ou un stockage objet dans le cloud.

	Data Warehouse	Data Lake
Données	Structurées, nettoyées	Brutes, tous formats
Schéma	À l'écriture (*schema-on-write*)	À la lecture (*schema-on-read*)
Usage	Reporting, tableaux de bord, OLAP	Exploration, data science, archivage
Utilisateurs	Décideurs, analystes métier	Data scientists, data engineers

Les deux sont complémentaires : le Data Lake sert souvent de zone d'atterrissage avant l'alimentation de l'entrepôt.

Cloudera: Cloudera est un éditeur qui fournit une distribution de l'écosystème **Apache Hadoop** (CDH, puis Cloudera Data Platform). Elle regroupe et administre les principaux outils Big Data :

- **HDFS** : système de fichiers distribué qui découpe et réplique les fichiers sur les nœuds du cluster ;
- **YARN** et **MapReduce** : gestion des ressources et traitement distribué ;
- **Hive** et **Impala** : interrogation des données en SQL ;
- **HBase** : base NoSQL orientée colonnes ;
- **Sqoop** : import/export entre bases relationnelles et Hadoop ;
- **Hue** : interface web pour manipuler ces outils.

Dans le projet, Cloudera constitue la couche de stockage et de traitement de l'architecture.

Power BI: Power BI est l'outil de *Business Intelligence* de Microsoft. Il se connecte à de nombreuses sources (dont Hive et Impala), permet de modéliser les données et de construire des tableaux de bord interactifs. Dans l'architecture, il forme la couche de restitution : il présente aux décideurs du CHU les indicateurs (KPI) calculés à partir de l'entrepôt.

RGPD: Le Règlement Général sur la Protection des Données (UE 2016/679), applicable depuis le 25 mai 2018, encadre le traitement des données à caractère personnel. Les données de santé y sont classées comme **données sensibles** : leur traitement est interdit sauf exceptions encadrées. Principes à respecter dans le projet :

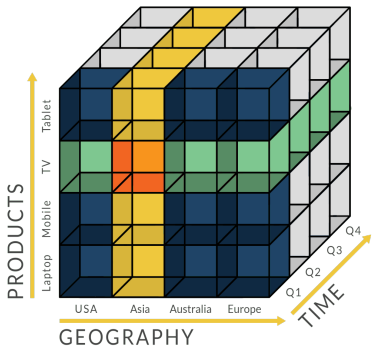
- **licéité et finalité** : traiter les données pour un objectif défini et légitime ;
- **minimisation** : ne conserver que les données nécessaires aux analyses ;
- **limitation de la conservation** : définir une durée de conservation ;
- **sécurité** : contrôle des accès, chiffrement, traçabilité ;
- **pseudonymisation** / **anonymisation** : retirer ou remplacer les identifiants directs (nom, numéro de sécurité sociale).

En France, l'hébergement de données de santé doit en plus être confié à un hébergeur certifié HDS, et la CNIL contrôle le respect du règlement.

Données multidimensionnelles: Les données multidimensionnelles sont organisées pour l'analyse selon plusieurs axes. Elles reposent sur deux notions :

- **les faits** : les mesures à analyser, souvent numériques (nombre de consultations, durée de séjour, coût) ;
- **les dimensions** : les axes d'analyse (temps, patient, établissement, diagnostic, professionnel de santé).

Cette organisation forme un **cube OLAP** que l'on peut explorer par agrégation (*roll-up*), détail (*drill-down*), découpage (*slice*, *dice*) ou pivot.



Source : Wikimedia Commons, Olap-3d-cube.png (CC BY-SA 4.0)

Environnement virtualisé: Un environnement virtualisé est un ensemble de machines virtuelles exécutées sur une même machine physique grâce à un hyperviseur (VMware, VirtualBox, Hyper-V). Dans le projet, il héberge les outils de la maquette (Cloudera, Power BI) et les fichiers de données. Il permet de reproduire l'architecture cible à moindre coût, de l'isoler et de la remettre en état facilement (instantanés).

Modélisation des données: La modélisation consiste à décrire la structure des données avant de les implémenter, à plusieurs niveaux (conceptuel, logique, physique). Pour un entrepôt, on utilise une modélisation dimensionnelle, qui organise les données en faits et en dimensions. Les différents modèles sont étudiés dans la partie 3.

Outil de planification: Un outil de planification sert à organiser le projet dans le temps : découper le travail en tâches, estimer leur durée, identifier les dépendances et répartir les responsabilités. Exemples : diagramme de Gantt (MS Project, GanttProject), tableau Kanban (Trello, Jira). Avec trois semaines pour livrer la maquette, il permet de suivre l'avancement de chaque phase (architecture, intégration, implémentation, visualisation).

2 INFRASTRUCTURE ET TRAITEMENT DISTRIBUÉS

2.1 CLUSTER DE SERVEURS ET VIRTUALISATION

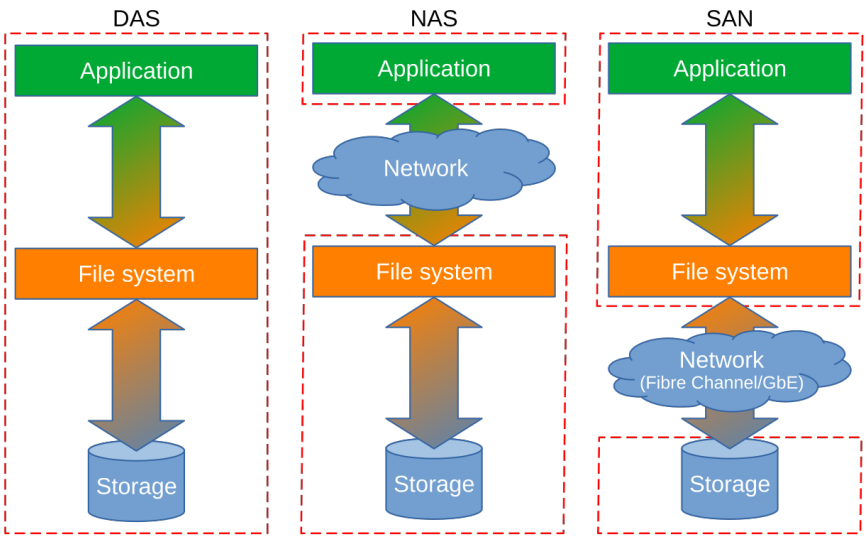
Cluster de serveurs: Un cluster est un ensemble de serveurs (**nœuds**) reliés en réseau qui travaillent comme un seul système. Face à l'augmentation des données, deux stratégies existent :

- **scalabilité verticale** (*scale up*) : ajouter de la puissance (CPU, RAM, disques) à un seul serveur. Simple, mais limité et coûteux ;
- **scalabilité horizontale** (*scale out*) : ajouter des serveurs standards au cluster. C'est le principe du Big Data : la capacité augmente de façon quasi linéaire avec le nombre de nœuds.

Le cluster apporte aussi la **tolérance aux pannes** : les données étant répliquées, la perte d'un nœud n'interrompt pas le service.

Virtualisation: La virtualisation permet de faire tourner plusieurs serveurs virtuels sur une même machine physique. Elle facilite le déploiement et la mutualisation des ressources (maquettes, environnements de test). Pour un cluster Big Data en production, on préfère souvent des machines physiques ou des conteneurs, car Hadoop repose sur la **localité des données** : le calcul est envoyé sur le nœud qui stocke la donnée, ce qu'une couche de stockage virtualisée partagée peut fausser.

2.2 STOCKAGE : DAS, NAS ET SAN



Source : Wikimedia Commons, Mattias Campe, DASvsNASvsSAN.svg (CC BY-SA 4.0)

	DAS	NAS	SAN
Principe	Disques attachés directement au serveur	Serveur de fichiers partagé sur le réseau	Réseau dédié au stockage, vu comme des disques locaux
Accès	Bloc, local	Fichier (NFS, SMB/-CIFS)	Bloc (Fibre Channel, iSCSI)
Réseau	Aucun	Réseau local (Ethernet)	Réseau dédié haut débit
Avantages	Simple, rapide, peu coûteux	Facile à partager, peu coûteux	Très performant, haute disponibilité
Inconvénients	Non partagé	Performances limitées par le réseau	Coûteux, complexe à administrer
Usage	Nœuds Hadoop (HDFS)	Partage de documents, sauvegardes	Bases de données critiques, virtualisation

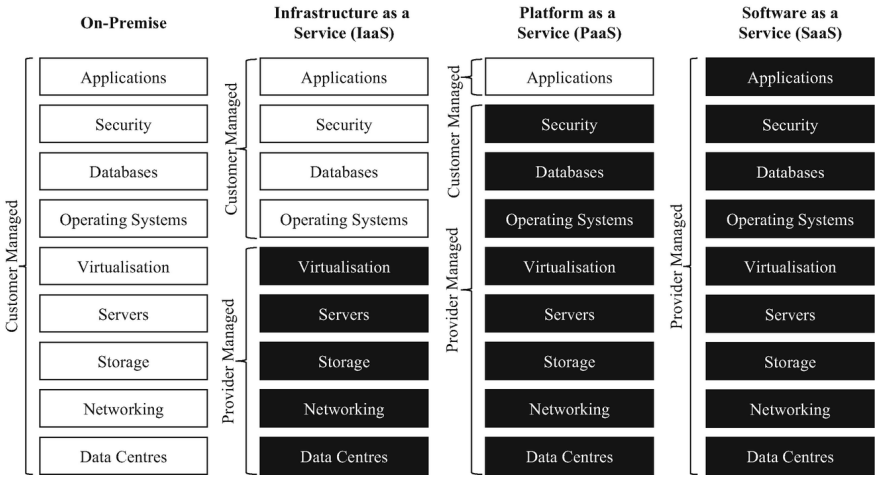
Hadoop privilégie le DAS : chaque nœud stocke ses propres blocs et HDFS assure lui-même le partage et la réplication, sans matériel de stockage coûteux.

2.3 LE CLOUD POUR LE STOCKAGE DE DONNÉES

Le cloud fournit des ressources informatiques à la demande, accessibles par le réseau et facturées à l'usage. On distingue trois modèles de service :

- **IaaS** : le fournisseur met à disposition l'infrastructure (machines virtuelles, stockage, réseau) ;
- **PaaS** : il fournit en plus une plateforme gérée (par exemple un cluster Hadoop ou un entrepôt managé) ;
- **SaaS** : il fournit une application prête à l'emploi (Power BI Service).

Et trois modèles de déploiement : **public** (ressources mutualisées chez un fournisseur), **privé** (dédié à une organisation) et **hybride** (combinaison des deux).



Source : Wikimedia Commons, P. Rosati & T. Lynn (domaine public). En noir : ce que gère le fournisseur.

Pour le stockage, le cloud propose notamment le **stockage objet** (Amazon S3, Azure Blob Storage, Google Cloud Storage), souvent utilisé comme Data Lake.

Avantages	Inconvénients
Élasticité : capacité ajustée au besoin	Dépendance au fournisseur et au réseau
Pas d'investissement matériel initial	Coûts difficiles à prévoir sur de gros volumes
Haute disponibilité et réplication géographique	Localisation et confidentialité des données
Services managés (moins d'administration)	Conformité réglementaire à vérifier

Pour le CHU, les données de santé imposent un fournisseur certifié **HDS** et un hébergement compatible avec le RGPD (données dans l'Union européenne).

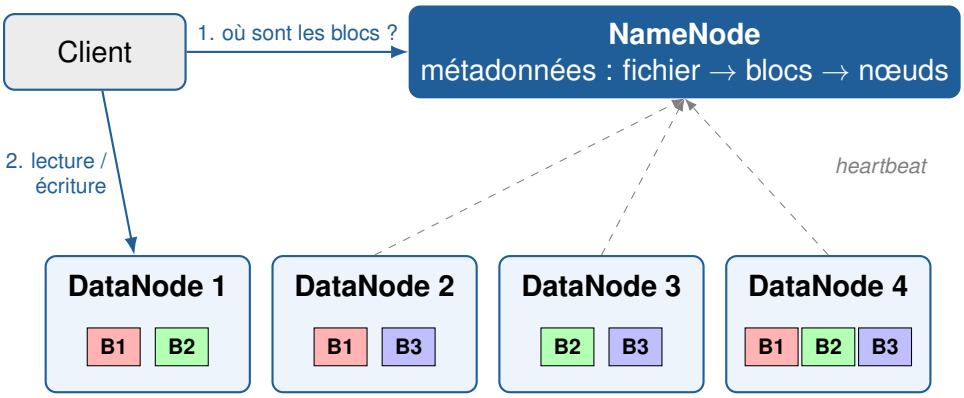
2.4 SYSTÈME DE FICHIERS DISTRIBUÉ : HDFS

Un système de fichiers distribué stocke les fichiers sur plusieurs machines tout en les présentant à l'utilisateur comme un système de fichiers unique. HDFS (*Hadoop Distributed File System*) en est l'exemple de référence. Il repose sur une architecture maître/esclaves :

- **NameNode** (maître) : gère l'arborescence et les métadonnées, c'est-à-dire la liste des blocs de chaque fichier et leur emplacement. Il ne stocke pas les données ;
- **DataNodes** (esclaves) : stockent les blocs de données et envoient régulièrement un signal de vie (*heartbeat*) au NameNode ;
- **Secondary** / **Standby NameNode** : sauvegarde les métadonnées ou prend le relais en cas de panne du NameNode.

Fonctionnement :

- chaque fichier est découpé en **blocs** de grande taille (128 Mo par défaut) ;
- chaque bloc est **répliqué** (3 copies par défaut) sur des nœuds différents, en tenant compte des racks (*rack awareness*) ;
- si un DataNode ne répond plus, le NameNode recrée les copies manquantes à partir des autres répliques ;
- le modèle est ***write once, read many*** : un fichier écrit n'est pas modifié, on y ajoute ou on le réécrit. Ce modèle est adapté aux lectures séquentielles de gros volumes.



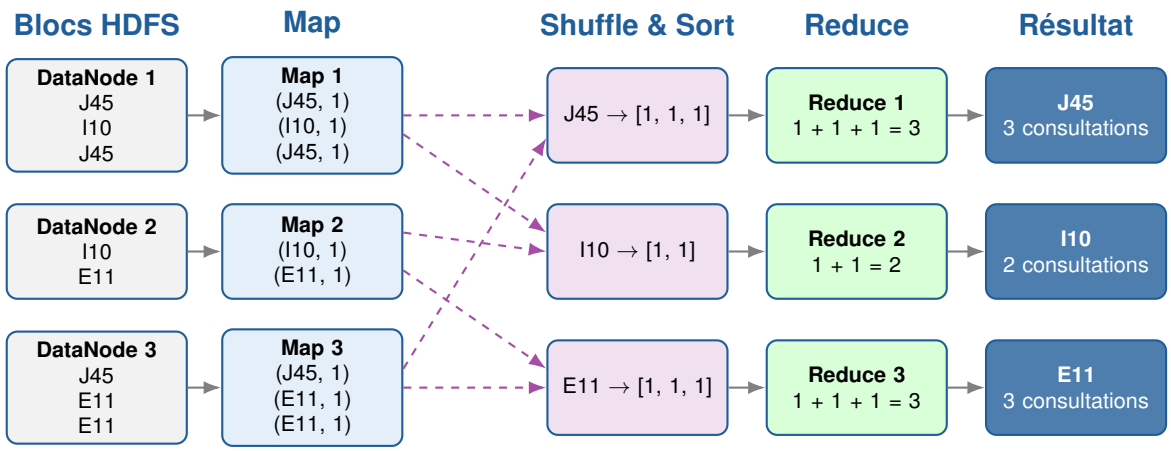
Le fichier est découpé en trois blocs (B1, B2, B3), chacun répliqué sur trois DataNodes différents : la perte d'un nœud ne fait perdre aucune donnée.

2.5 TRAITEMENT DISTRIBUÉ : MAPREDUCE

MapReduce est un modèle de programmation qui traite de gros volumes de données en parallèle sur un cluster. Plutôt que de rapatrier les données vers le programme, on envoie le programme sur les nœuds qui stockent les données. Le traitement se déroule en trois étapes :

1. **Map** : chaque nœud lit ses blocs et produit des paires *(clé, valeur)* ;
2. **Shuffle & Sort** : les paires sont regroupées et triées par clé, puis envoyées vers les nœuds de réduction ;
3. **Reduce** : pour chaque clé, les valeurs sont agrégées (somme, moyenne, comptage) pour produire le résultat final.

Exemple CHU : compter le nombre de consultations par diagnostic (code CIM-10) à partir d'un fichier de consultations réparti en trois blocs sur trois DataNodes. Les codes sont des exemples : J45 asthme, I10 hypertension, E11 diabète de type 2.



Pendant le *shuffle* (flèches violettes), chaque paire est envoyée vers le nœud de réduction chargé de sa clé : toutes les paires J45 arrivent au même Reduce, quel que soit le DataNode d'origine. C'est la seule étape où les données circulent sur le réseau. Le reste du traitement s'exécute là où sont stockés les blocs (colocalisation).

Dans l'écosystème Cloudera, Hive traduit les requêtes SQL en traitements distribués de ce type : un `SELECT code_diagnostic, COUNT(*) FROM fait_consultation GROUP BY code_diagnostic` produit le même résultat.

2.6 DIFFICULTÉS DES TRAITEMENTS DISTRIBUÉS

- **Pannes** : plus il y a de machines, plus une panne est probable. Le système doit détecter les nœuds défaillants et relancer leurs tâches ailleurs.
- **Réseau** : la latence et la bande passante limitent les performances, surtout lors de la phase de *shuffle* où les données circulent entre les nœuds.
- **Déséquilibre de charge** (*data skew*) : si une clé concentre beaucoup de données, un seul nœud fait l'essentiel du travail et ralentit tout le traitement.
- **Cohérence** : d'après le **théorème CAP**, un système distribué ne peut garantir à la fois la cohérence, la disponibilité et la tolérance au partitionnement réseau. Il faut choisir un compromis.
- **Latence de MapReduce** : les résultats intermédiaires sont écrits sur disque, ce qui le rend lent pour les traitements itératifs ou interactifs (d'où des alternatives comme Spark ou Impala).
- **Petits fichiers** : HDFS est conçu pour de gros fichiers. Beaucoup de petits fichiers saturent la mémoire du NameNode.
- **Complexité** : le développement, le débogage et l'administration d'un cluster demandent des compétences spécifiques.
- **Sécurité** : les données étant réparties et répliquées sur de nombreux nœuds, il faut sécuriser chaque nœud (authentification Kerberos, chiffrement, contrôle d'accès).

3 ENTREPOSAGE ET MODÉLISATION DES DONNÉES

3.1 OLTP VS OLAP

Les bases de données opérationnelles et l'entrepôt de données ne répondent pas au même besoin :

	OLTP (transactionnel)	OLAP (analytique)
Objectif	Faire tourner l'activité au quotidien	Analyser l'activité et aider à la décision
Opérations	Nombreuses petites transactions (INSERT, UPDATE, DELETE)	Peu de requêtes, mais lourdes (agrégations sur des millions de lignes)
Données	Actuelles, détaillées	Historisées, agrégées
Modèle	Normalisé (3FN) pour éviter la redondance	Dimensionnel (étoile, flocon) pour accélérer les lectures
Exemple CHU	Dossier patient, prise de rendez-vous	Taux d'occupation des lits par service et par mois

Exemple sur les données du CHU : la même information n'est pas écrite ni lue de la même façon.

OLTP : base PostgreSQL

```
INSERT INTO "Consultation"
  ("Id_patient", "Code_diag", "Date")
VALUES (29620, 'J45', '2023-03-14');
```

Une ligne écrite, en quelques millisecondes, des milliers de fois par jour.

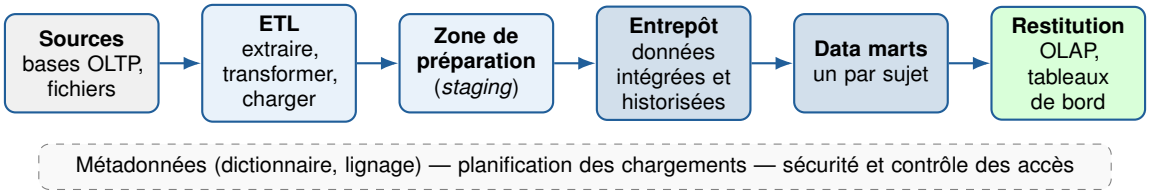
OLAP : entrepôt Hive

```
SELECT e.region, t.annee, COUNT(*),
  AVG(f.duree_sejour)
FROM fait_hospitalisation f
JOIN dim_etablissement e USING (id_etab)
JOIN dim_temps t USING (id_date)
GROUP BY e.region, t.annee;
```

Des millions de lignes lues et agrégées, en quelques secondes.

3.2 FONCTIONNEMENT D'UNE APPLICATION D'ENTREPOSAGE

Une application d'entreposage de données fait le lien entre les bases OLTP et les outils d'analyse. Les données suivent une chaîne de traitement en plusieurs étapes :



1. **Extraction** : les données sont lues dans les sources, en totalité la première fois puis de façon incrémentale (seules les lignes nouvelles ou modifiées).
2. **Transformation** : nettoyage (doublons, valeurs manquantes, formats de date), harmonisation des codes entre sources, calculs (durée de séjour, âge) et, pour le CHU, pseudonymisation des données personnelles.
3. **Chargement** : les données sont insérées dans l'entrepôt, qui conserve l'historique. Les data marts sont ensuite alimentés à partir de l'entrepôt.
4. **Restitution** : les outils OLAP et de reporting interrogent les data marts. Les utilisateurs naviguent dans les données sans écrire de requêtes.

Les chargements sont planifiés, par exemple chaque nuit, pour ne pas perturber les applications de production.

3.3 NIVEAUX DE MODÉLISATION

Avant de choisir un modèle d'entrepôt, on distingue trois niveaux de description des données (méthode Merise) :

Niveau	Question	Contenu	Exemple CHU
Conceptuel (MCD)	Quelles données ?	Entités, associations, cardinalités	Un patient passe 0 à n consultations
Logique (MLD)	Comment les organiser ?	Tables, clés primaires et étrangères	Consultation (Num_consultation, #Id_patient, #Code_diag, Date)
Physique (MPD)	Avec quel SGBD ?	Types, index, partitions, format de stockage	Table Hive au format ORC partitionnée par année

Les règles de passage du MCD au MLD sont les suivantes :

- une entité devient une table et son identifiant devient la clé primaire ;
- une association de cardinalité (0,1)/(1,1) – (0,n) devient une clé étrangère du côté (1,1) ou (0,1) ;
- une association (0,n) – (0,n) devient une table d'association dont la clé est le couple des identifiants. Ses attributs propres (une date par exemple) deviennent des colonnes de cette table.

3.4 APPROCHES DE CONCEPTION D'UN ENTREPÔT

Trois approches s'opposent pour organiser l'entrepôt lui-même.

Bill Inmon : l'entrepôt d'entreprise normalisé (*top-down*)
On construit d'abord un entrepôt central unique, modélisé en troisième forme normale (3FN), qui intègre toutes les données de l'organisation. Les data marts dimensionnels sont ensuite dérivés de cet entrepôt.

+ Source unique et cohérente, peu de redondance, bonne base pour de nouveaux besoins.
– Long et coûteux à construire avant les premiers résultats, requêtes d'analyse complexes (nombreuses jointures).

Ralph Kimball : les data marts dimensionnels (*bottom-up*)
On construit directement des data marts en étoile, un par processus métier. Ils sont reliés entre eux par des **dimensions conformes**, c'est-à-dire partagées et identiques partout (le temps, le patient). L'ensemble forme l'entrepôt (architecture en bus).

+ Premiers résultats rapides, modèle compréhensible par les utilisateurs, très performant en lecture.
– Redondance dans les dimensions, cohérence globale qui dépend de la rigueur sur les dimensions conformes.

Dan Linstedt : le Data Vault
L'entrepôt est découpé en trois types de tables : les **hubs** (clés métier, par exemple le numéro patient), les **links** (relations entre hubs) et les **satellites** (attributs descriptifs historisés).

+ Historisation complète et traçable (audit), ajout de nouvelles sources sans modifier l'existant, chargements parallélisables.
– Grand nombre de tables, modèle non interrogeable directement : il faut des data marts en étoile au-dessus.

Critère	Inmon	Kimball	Data Vault
Démarche	Descendante	Ascendante	Hybride
Modèle	Relationnel 3FN	Dimensionnel (étoile)	Hubs, links, satellites
Mise en œuvre	Longue	Rapide	Moyenne
Performance des requêtes	Faible sans data marts	Élevée	Faible sans data marts
Ajout d'une source	Modifie le modèle	Modifie les dimensions	Ajout de tables, sans impact
Historisation	Bonne	Selon les dimensions (SCD)	Complète
Complexité	Élevée	Faible	Élevée

3.5 MODÈLES DE STOCKAGE : RELATIONNEL ET NOSQL

Le modèle relationnel (tables liées par des clés, langage SQL, transactions ACID) reste la référence pour l'entrepôt. Le Big Data a popularisé d'autres modèles, dits NoSQL, qui sacrifient une partie de la cohérence au profit de la répartition sur un cluster :

Modèle	Principe	Usage	Exemples
Relationnel	Tables, schéma fixe, jointures SQL	Entrepôt, applications de gestion	PostgreSQL, Hive
Clé-valeur	Une clé donne accès à une valeur opaque	Cache, sessions	Redis
Orienté colonnes	Lignes identifiées par une clé, colonnes regroupées en familles	Gros volumes, accès rapide par clé	HBase, Cassandra
Document	Documents JSON au schéma souple	Données semi-structurées	MongoDB
Graphe	Nœuds et relations	Réseaux, parcours de liens	Neo4j

Dans un Data Lake, le schéma est appliqué à la lecture (*schema-on-read*) : les fichiers bruts sont stockés tels quels, et Hive leur associe une structure de table au moment de la requête. Les données du CHU sont structurées (tables et fichiers CSV), le modèle relationnel dimensionnel reste donc le plus adapté.

3.6 MODÉLISATION DIMENSIONNELLE : ÉTOILE, FLOCON, CONSTELLATION

Un modèle dimensionnel sépare deux types de tables :

- la **table de faits** enregistre les événements à analyser. Elle contient les clés étrangères vers les dimensions et des **mesures** numériques. Une mesure est additive (nombre de consultations), semi-additive (nombre de lits occupés, qu'on ne somme pas dans le temps) ou non additive (taux de satisfaction) ;
- les **tables de dimensions** décrivent le contexte des faits (qui, quoi, où, quand). Leurs attributs servent à filtrer et à regrouper.

La conception suit les quatre étapes de Kimball : choisir le processus métier, déclarer le **grain** (ce que représente une ligne de faits), identifier les dimensions, puis identifier les mesures. Pour suivre les changements d'une dimension dans le temps (un patient qui déménage), on utilise les **SCD** (*Slowly Changing Dimensions*) : écrasement de la valeur (type 1), nouvelle ligne avec dates de validité (type 2) ou colonne « ancienne valeur » (type 3).

On distingue trois formes de schéma :

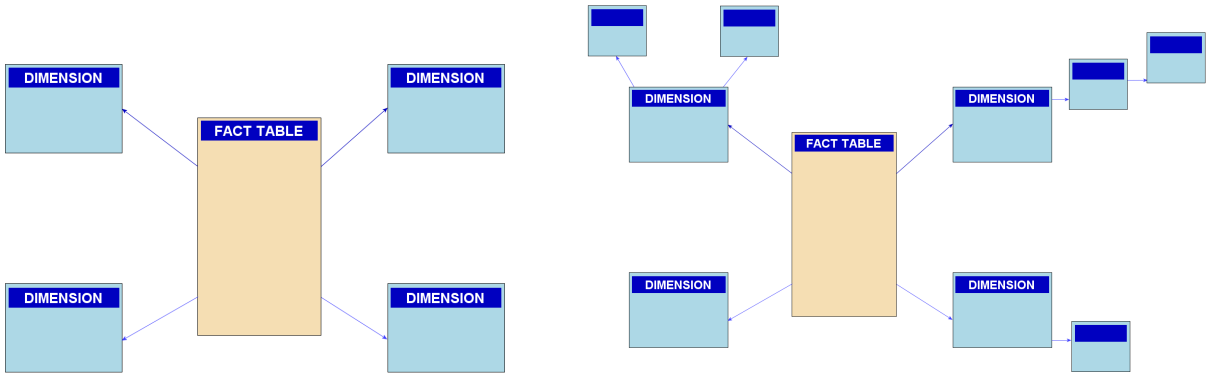


Schéma en étoile Schéma en flocon

Source : Wikimedia Commons, SqlPac (CC BY-SA 3.0)

- **Étoile** : une table de faits entourée de dimensions dénormalisées, reliées directement à elle.
- **Flocon** : les dimensions sont normalisées en sous-tables hiérarchiques (ville → département → région).
- **Constellation** : plusieurs tables de faits partagent des dimensions conformes. C'est la forme d'un entrepôt construit selon Kimball.

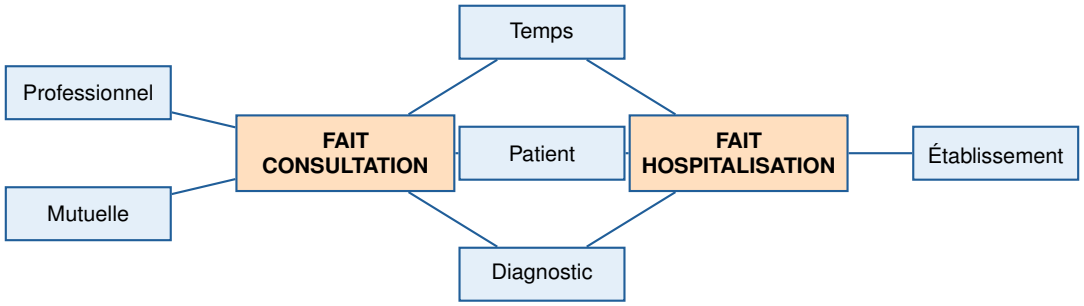


Schéma en constellation (exemple CHU)

Critère	Étoile	Flocon	Constellation
Dimensions	Dénormalisées	Normalisées	Partagées entre faits
Jointures	Une par dimension	Plusieurs par dimension	Une par dimension et par fait
Performance	Très bonne	Plus faible	Bonne
Redondance	Forte	Faible	Forte, mais dimensions communes
Lisibilité	Très simple	Plus complexe	Moyenne
Usage	Un data mart	Hiérarchies profondes, dimensions volumineuses	Entrepôt multi-sujets

3.7 CHOIX POUR LE CHU

Pour une maquette à livrer en trois semaines, l'approche de **Kimball** est la plus adaptée : elle produit vite des data marts exploitables dans Power BI. Les sujets d'analyse (consultations, hospitalisations, satisfaction, décès) partagent le temps, les patients, les établissements et les diagnostics. On retient donc un schéma en **constellation**, en gardant chaque data mart en étoile pour limiter les jointures dans Hive.

À partir des données fournies, les tables de faits candidates sont :

Fait	Grain	Mesures	Dimensions
Consultation	Une consultation	Nombre, durée (fin − début)	Temps, Patient, Professionnel, Diagnostic, Mutuelle
Prescription	Un médicament prescrit lors d'une consultation	Nombre de prescriptions	Temps, Patient, Médicament, Professionnel
Hospitalisation	Un séjour	Nombre, durée en jours	Temps (entrée), Patient, Établissement, Diagnostic
Satisfaction	Un établissement pour une année de recueil	Scores par thème, nombre de réponses, taux de recommandation	Temps (année), Établissement
Décès	Un décès	Nombre, âge au décès	Temps, Lieu (commune)

Les dimensions Temps, Patient (pseudonymisé), Établissement (code FINESS) et Diagnostic (code CIM-10) sont conformes : une seule table de chaque, utilisée par tous les faits. Au niveau physique, les tables seront stockées dans Hive au format ORC et partitionnées par année. Chaque année devient un dossier dans HDFS. Une requête filtrée sur `annee = 2023` ne lit alors que le dossier correspondant (*partition pruning*), et le format ORC, stocké par colonnes et compressé, ne lit que les colonnes utiles :

Stockage physique dans HDFS

```
/user/hive/warehouse/chu.db/
  fait_hospitalisation/
    annee=2021/  part-00000.orc
    annee=2022/  part-00000.orc
    annee=2023/  part-00000.orc
  dim_etablissement/  part-00000.orc
  dim_temps/  part-00000.orc
```

4 ARCHITECTURE DU PROJET CHU

4.1 SCHÉMA D'ARCHITECTURE D'ARCHIE

Le schéma fourni par Archie décrit la chaîne de traitement des données du projet CHU, des sources jusqu'à la restitution. Il est redessiné ci-dessous en couches. Les pastilles rouges renvoient aux limites relevées dans la partie suivante.

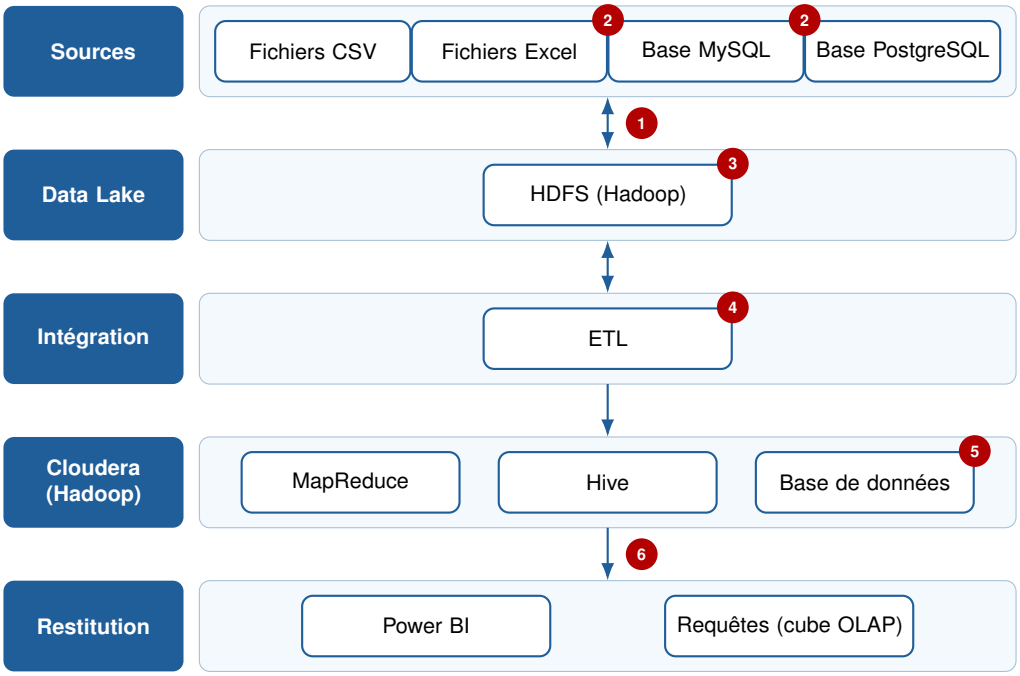


Schéma d'Archie, redessiné

L'architecture se lit de haut en bas, en cinq couches :

1. **Sources de données** : des fichiers plats (CSV, Excel) et des bases relationnelles (MySQL, PostgreSQL), qui représentent les systèmes existants du CHU.
2. **Data Lake (HDFS Hadoop)** : les données sont collectées brutes dans le système de fichiers distribué de Hadoop, qui les découpe en blocs répliqués sur les nœuds du cluster.
3. **ETL** : les données sont extraites du Data Lake, nettoyées, transformées puis chargées dans l'entrepôt.
4. **Stockage et traitement (Cloudera / Hadoop)** : l'entrepôt de données est hébergé sur la plateforme Cloudera. Hive expose les données en SQL, et MapReduce exécute les traitements distribués.
5. **Restitution** : Power BI produit les tableaux de bord, et les requêtes multidimensionnelles (cube OLAP) répondent aux analyses du cahier des charges.

4.2 LIMITES DU SCHÉMA

Le principe général (sources, Data Lake, ETL, entrepôt, restitution) est correct, mais le schéma présente plusieurs erreurs ou manques :

1. **Flèches bidirectionnelles.** Les sources, HDFS et l'ETL sont reliés par des doubles flèches. Une chaîne décisionnelle lit les sources sans jamais les modifier : le flux doit aller dans un seul sens.
2. **Sources inexactes.** Les données fournies (« DATA 2024 ») ne contiennent aucune base MySQL, et un seul fichier Excel, simple doublon d'un CSV de satisfaction. On dispose d'une sauvegarde PostgreSQL (patients, consultations, prescriptions, médicaments, mutuelles) et de fichiers CSV (hospitalisations, établissements et professionnels de santé, décès, satisfaction).
3. **HDFS isolé de Cloudera.** HDFS fait partie de la distribution Cloudera. Le Data Lake et l'entrepôt sont hébergés sur le même cluster, ce que le schéma ne montre pas.
4. **ETL non défini.** L'outil n'est pas nommé et son rôle se limite à un passage. Dans le projet, c'est **Talend Open Studio for Big Data**, et c'est à cette étape que les données doivent être pseudonymisées.
5. **Entrepôt non identifié.** « Base de données » ne dit pas où se trouve l'entrepôt ni comment il est modélisé. Il faut des tables Hive organisées en data marts dimensionnels.
6. **Restitution lente.** Power BI interrogerait Hive, qui exécute des traitements MapReduce écrits sur disque : plusieurs dizaines de secondes par requête. Pour des tableaux de bord interactifs, Impala est plus adapté.
7. **Aucune sécurité ni conformité.** Rien n'apparaît sur le RGPD, l'hébergement HDS, l'authentification ou les droits d'accès, alors que les données sont des données de santé.
8. **Aucune planification.** Le schéma ne montre pas comment et quand les chargements sont déclenchés.

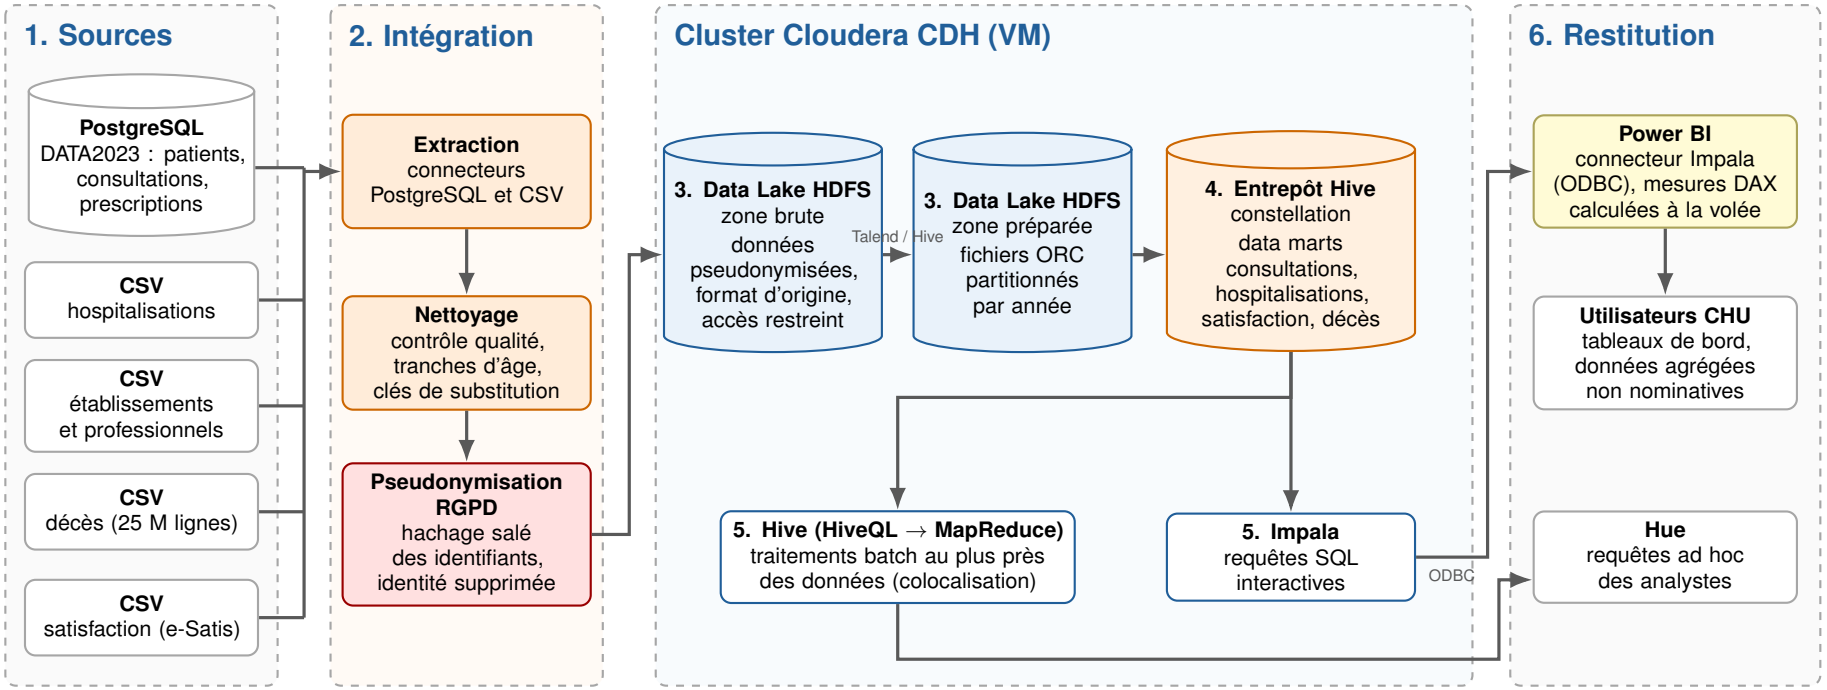
4.3 PROPOSITION D'ARCHITECTURE

L'architecture proposée corrige ces points. Elle est hybride : un Data Lake HDFS pour le stockage et un entrepôt Hive en constellation pour l'analyse. Elle repose sur les outils de l'environnement virtualisé (machine Cloudera QuickStart CDH 5.12, Talend Open Studio for Big Data, Power BI). Le schéma est présenté page suivante.

Couche	Outil	Rôle
Sources	PostgreSQL, CSV	Données de gestion du CHU et données publiques (établissements, décès, satisfaction)
Intégration	Talend Open Studio for Big Data	Extraire, contrôler, pseudonymiser puis déposer les données dans HDFS
Data Lake	HDFS	Conserver les données brutes (pseudonymisées) et préparées, répliquées sur le cluster
Entrepôt	Hive	Tables dimensionnelles en constellation, au format ORC partitionné
Accès	Hive, Impala	Hive pour les traitements lourds, Impala pour les requêtes interactives
Restitution	Power BI, Hue	Tableaux de bord des décideurs, requêtes des analystes
Transverse	Kerberos, Sentry, HDS	Sécurité, droits d'accès, conformité RGPD

Ce qui change par rapport au schéma d'Archie :

- le flux est à sens unique, des sources vers la restitution ;
- les sources correspondent aux données réellement fournies ;
- Talend est placé avant HDFS : les données sont pseudonymisées avant d'être stockées, et aucune donnée directement identifiante n'est écrite dans HDFS ;
- le Data Lake est découpé en une zone brute et une zone préparée, toutes deux dans le cluster Cloudera ;
- l'entrepôt est explicite : des data marts Hive en constellation ;
- Impala sert les tableaux de bord, Hive reste pour les traitements batch ;
- sécurité, conformité et planification deviennent des couches transverses.



Sécurité et RGPD (transverse) : hébergement certifié HDS · authentification Kerberos · droits par rôle (Sentry) · chiffrement des données · journalisation des accès · durées de conservation par zone.
Les identifiants directs (nom, prénom, n° de sécurité sociale, adresse, date de naissance) sont pseudonymisés par Talend avant d'être écrits dans HDFS : seules des données pseudonymisées puis agrégées atteignent l'entrepôt et Power BI.
Orchestration : jobs Talend planifiés (chargement nocturne).

Architecture proposée : Data Lake et entrepôt sur le cluster Cloudera

4.4 CONTRAINTES RGPD SUR LES DONNÉES

Les données du projet sont des données de santé, classées comme données sensibles par le RGPD (article 9). Le tableau suivant recense les données personnelles de chaque source et le traitement prévu dans Talend :

Source	Données personnelles	Traitement
Patient (PostgreSQL)	Nom, prénom, adresse, e-mail, téléphone, numéro de sécurité sociale, date de naissance	Identifiant remplacé par un hachage salé, colonnes d'identité supprimées, date de naissance réduite à une tranche d'âge, adresse réduite au département
Consultation, prescription, hospitalisation	Diagnostics, médicaments, durées de séjour (données de santé)	Conservés, mais rattachés au seul identifiant pseudonymisé
Professionnels de santé	Nom, prénom, profession, commune	Données publiques (annuaire RPPS) ; seuls l'identifiant, la profession et la spécialité sont nécessaires
Décès	Nom, prénom, date et lieu de naissance et de décès	Fichier public de l'INSEE ; utilisé pour des statistiques agrégées, sans les noms
Satisfaction	Aucune (résultats agrégés par établissement)	Aucun traitement particulier

Les autres principes du RGPD se traduisent ainsi dans l'architecture :

- **finalité** : les données ne servent qu'au pilotage de l'activité hospitalière décrit dans le cahier des charges ;
- **minimisation** : seules les colonnes utiles aux analyses sont chargées (le groupe sanguin, le poids ou la taille ne le sont que si un indicateur les utilise) ;
- **conservation** : une durée est fixée pour chaque zone, et les partitions par année permettent de supprimer facilement les données expirées ;
- **sécurité** : hébergement HDS, authentification Kerberos, droits par rôle et journalisation des accès ;
- **droits des personnes** : la table de correspondance entre identifiant réel et pseudonyme reste dans le système source, hors du cluster, ce qui permet de traiter une demande d'accès ou d'effacement.

La pseudonymisation n'est pas une anonymisation : les données restent personnelles au sens du RGPD. Seuls les indicateurs agrégés publiés dans Power BI, avec des effectifs suffisants, peuvent être considérés comme anonymes.

CONCLUSION

En réponse à la problématique, valider une architecture Big Data performante pour le projet CHU a d'abord demandé de corriger le schéma d'Archie. Son principe général (sources, Data Lake, ETL, entrepôt, restitution) est juste, mais les flux sont à double sens, les sources ne correspondent pas aux données fournies, l'entrepôt n'est pas identifié et rien ne traite la sécurité ni le RGPD.

L'architecture proposée est **hybride**. **Talend** extrait les données PostgreSQL et CSV, les contrôle et les **pseudonymise avant tout stockage**. **HDFS** conserve ces données dans une zone brute puis une zone préparée, répliquées sur le cluster Cloudera. **Hive** les organise en data marts. **Impala** sert les requêtes interactives de **Power BI**, et Hive reste pour les traitements batch exécutés en MapReduce au plus près des données. La sécurité (hébergement HDS, Kerberos, droits par rôle, journalisation) et la planification des chargements sont des couches transverses.

Pour le modèle logique, l'étude des approches de modélisation conduit à retenir celle de **Kimball**, sous la forme d'une **constellation** : des tables de faits (consultations, hospitalisations, satisfaction, décès) qui partagent des dimensions conformes (temps, patient pseudonymisé, établissement, diagnostic). Ce modèle est rapide à mettre en place, lisible pour les utilisateurs et performant en lecture, ce qui convient à une maquette à livrer en trois semaines.

La suite du projet consiste à finaliser le modèle dimensionnel détaillé, puis à passer à l'intégration des données avec Talend, à l'implémentation physique dans Hive et à la construction des tableaux de bord dans Power BI.

CAPITALISATION

AAV	Commentaire	Statut
Identifier les contraintes sur les données liées au RGPD	Données personnelles recensées source par source (identité des patients, données de santé, fichier des décès) avec le traitement prévu : pseudonymisation, minimisation, conservation, hébergement HDS.	Acquis
Interpréter les 5V du Big Data	Volume, vélocité, variété, véracité et valeur définis et illustrés par les données de santé du CHU.	Acquis
Décrire une architecture Big Data	Schéma d'Archie analysé, huit limites relevées, puis architecture corrigée proposée (Talend, HDFS, Hive, Impala, Power BI) et justifiée couche par couche.	Acquis
Décrire une infrastructure de stockage distribuée (cluster de serveurs, virtualisation, NAS vs SAN, . . .)	Cluster et scalabilité horizontale, virtualisation et localité des données, comparaison DAS / NAS / SAN.	Acquis
Décrire l'utilisation du cloud dans le cadre du stockage de données	Modèles IaaS, PaaS, SaaS et de déploiement, stockage objet, avantages et limites, contrainte HDS pour les données de santé.	Acquis
Présenter le traitement de données de manière distribuée (exemple : MapReduce)	Étapes Map, Shuffle & Sort et Reduce illustrées par le comptage des consultations par diagnostic, et lien avec les requêtes Hive.	Acquis
Décrire le fonctionnement des systèmes de fichiers distribués	Architecture de HDFS (NameNode, DataNodes), découpage en blocs, réplication et tolérance aux pannes.	Acquis
Décrire le fonctionnement d'une application d'entreposage de données	OLTP et OLAP comparés, chaîne ETL, zone de préparation, entrepôt, data marts et restitution.	Acquis
Concevoir un modèle dimensionnel (Data Mart)	Approches Inmon, Kimball et Data Vault comparées, schémas étoile, flocon et constellation étudiés, faits et dimensions du CHU identifiés. Le modèle détaillé reste à finaliser.	Partiel
Identifier les difficultés associées aux traitements distribués	Pannes, réseau, déséquilibre de charge, théorème CAP, latence de MapReduce, petits fichiers, complexité et sécurité.	Acquis

RESSOURCES

- **Documentation Apache Hadoop (HDFS, MapReduce)** : https://hadoop.apache.org/docs/stable/
- **Apache Hive** : https://hive.apache.org/
- **Apache Impala** : https://impala.apache.org/
- **Documentation Cloudera** : https://docs.cloudera.com/
- **Documentation Talend** : https://help.talend.com/
- **Documentation Power BI** : https://learn.microsoft.com/fr-fr/power-bi/
- **Techniques de modélisation dimensionnelle (Kimball Group)** : https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/kimball-techniques/dimensional-modeling-techniques/
- **RGPD (CNIL)** : https://www.cnil.fr/fr/reglement-europeen-protection-donnees
- **Hébergement de données de santé (HDS)** : https://esante.gouv.fr/produits-services/hds
- **Fichier des personnes décédées (INSEE, data.gouv.fr)** : https://www.data.gouv.fr/fr/datasets/fichier-des-personnes-decedees/