CESI
ÉCOLE D'INGÉNIEURS

Stockage & Big Data

Workshop | Modélisation multidimensionnelle

Mardi 20 octobre 2026

Mazou Marine
Fisa Info 25–28
CESI

TABLE DES MATIÈRES

Introduction **2**

Exercice 1 : du MCD au MLD **3**
Modèle 1 : association 1-n 4
Modèle 2 : association n-n porteuse d'un attribut 5
Modèle 3 : association n-n historisée 6

Exercice 2 : ventes d'une entreprise industrielle **7**
1. Modèle en étoile 8
2. Modèle en flocon 9
3. Avantages et inconvénients 10

Exercice 3 : réservation d'hôtels **11**
1. Règles de gestion 11
2. Modèle dimensionnel logique : revenus de l'hôtel 12

Exercice 4 : modèle physique de données **14**
Choix d'implémentation 14
Contraintes 14
Schéma du modèle physique 15

Exercice 5 : data mart des ventes de meubles **16**
a) Modèle en étoile 16
b) Modèle en flocon 17

Exercice 6 : flocon, étoile et constellation **18**
a) Modèle en flocon 18
b) Modèle en étoile 19
c) Modèle en constellation 20

Conclusion **21**

INTRODUCTION

Les bases de données relationnelles des systèmes **OLTP** (*Online Transaction Processing*) sont conçues pour enregistrer les opérations du quotidien : elles sont normalisées et optimisées pour les insertions et les mises à jour. Un **entrepôt de données** (*data warehouse*) ou un **magasin de données** (*data mart*) répond à un autre besoin : analyser l'activité dans le temps à l'aide de systèmes **OLAP** (*Online Analytical Processing*).

Ce workshop met en pratique la **modélisation dimensionnelle** :

- une **table de faits** contient les **mesures** numériques à analyser (quantités, montants…) et les clés étrangères vers les dimensions. Son **grain** est le niveau de détail d'une ligne ;
- une **table de dimension** contient les **axes d'analyse** (qui, quoi, où, quand…) et leurs attributs descriptifs, souvent organisés en **hiérarchies** (jour → mois → année) ;
- le modèle peut être en **étoile** (dimensions dénormalisées), en **flocon** (hiérarchies normalisées en sous-tables) ou en **constellation** (plusieurs tables de faits partageant des dimensions).

Les schémas suivent la même légende :

Légende : clé primaire #clé étrangère *mesure*

EXERCICE 1 : DU MCD AU MLD

Le passage du modèle conceptuel (entité-association) au modèle logique relationnel repose sur trois règles :

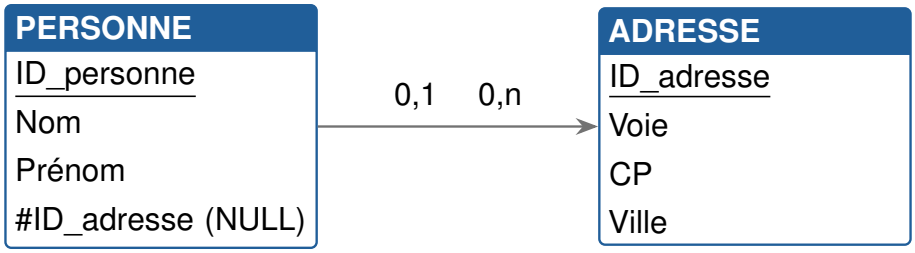
1. chaque **entité** devient une **table** ; son identifiant devient la **clé primaire** ;
2. une association **binaire de type 1-n** (cardinalité maximale 1 d'un côté) disparaît : la table du côté « 1 » reçoit une **clé étrangère** vers l'autre table. Si la cardinalité minimale est 0, la clé étrangère peut être `NULL` ;
3. une association **n-n** devient une **table d'association**. Sa clé primaire est composée des clés étrangères des entités reliées, et elle reçoit les attributs portés par l'association.

MODÈLE 1 : ASSOCIATION 1-N

Une personne réside à **0 ou 1** adresse, une adresse accueille **0 à n** personnes. La cardinalité maximale est 1 du côté `Personne` : l'association `Réside` disparaît et `Personne` reçoit l'identifiant de l'adresse en clé étrangère.

MLD – Modèle 1

PERSONNE (ID_personne, Nom, Prénom, #ID_adresse)
ADRESSE (ID_adresse, Voie, CP, Ville)



Légende : clé primaire #clé étrangère *mesure*

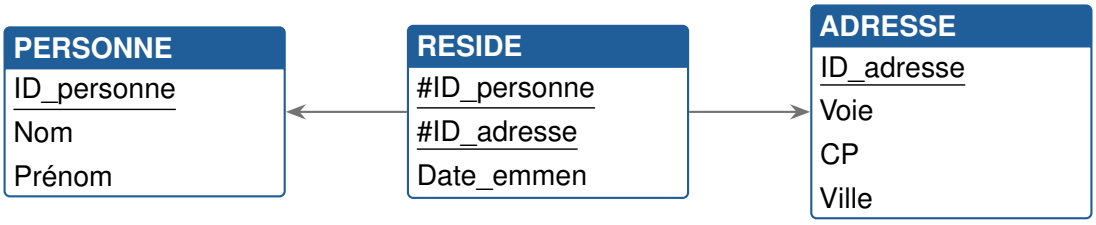
`ID_adresse` est **nullable** (cardinalité minimale 0) : une personne peut ne pas avoir d'adresse connue.

MODÈLE 2 : ASSOCIATION N-N PORTEUSE D'UN ATTRIBUT

Une personne peut résider à plusieurs adresses (dans le temps) et une adresse peut accueillir plusieurs personnes. L'association `Réside` est **n-n** : elle devient une table dont la clé primaire est le couple des deux identifiants. Elle porte la date d'emménagement.

MLD – Modèle 2

PERSONNE (ID_personne, Nom, Prénom)
ADRESSE (ID_adresse, Voie, CP, Ville)
RESIDE (#ID_personne, #ID_adresse, Date_emmen)



Légende : clé primaire #clé étrangère *mesure*

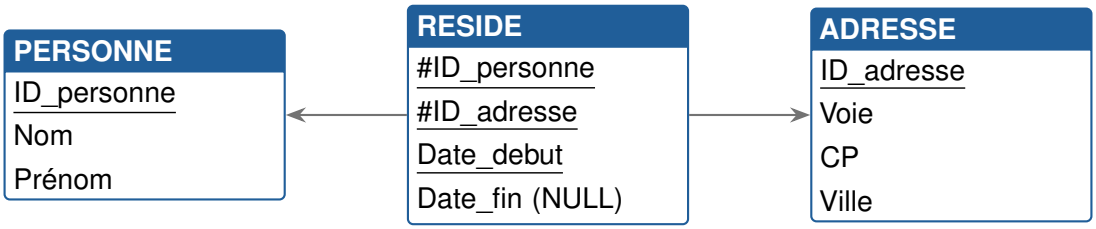
Avec cette clé, une personne ne peut être liée qu'**une seule fois** à une même adresse : un retour à une ancienne adresse écraserait la date d'emménagement. Le modèle 3 corrige ce point.

MODÈLE 3 : ASSOCIATION N-N HISTORISÉE

Même règle que le modèle 2, mais l'association porte une **période** (`Date_debut`, `Date_fin`). Pour garder tout l'historique, y compris plusieurs séjours d'une même personne à une même adresse, `Date_debut` entre dans la clé primaire.

MLD – Modèle 3

PERSONNE (ID_personne, Nom, Prénom)
ADRESSE (ID_adresse, Voie, CP, Ville)
RESIDE (#ID_personne, #ID_adresse, Date_debut, Date_fin)



Légende : clé primaire #clé étrangère *mesure*

Contraintes à ajouter : `Date_fin` vaut `NULL` pour la résidence actuelle, et `Date_fin` $\geq$ `Date_debut`. C'est le principe des **dimensions à évolution lente** (*SCD de type 2*) utilisées dans les entrepôts pour historiser un attribut.

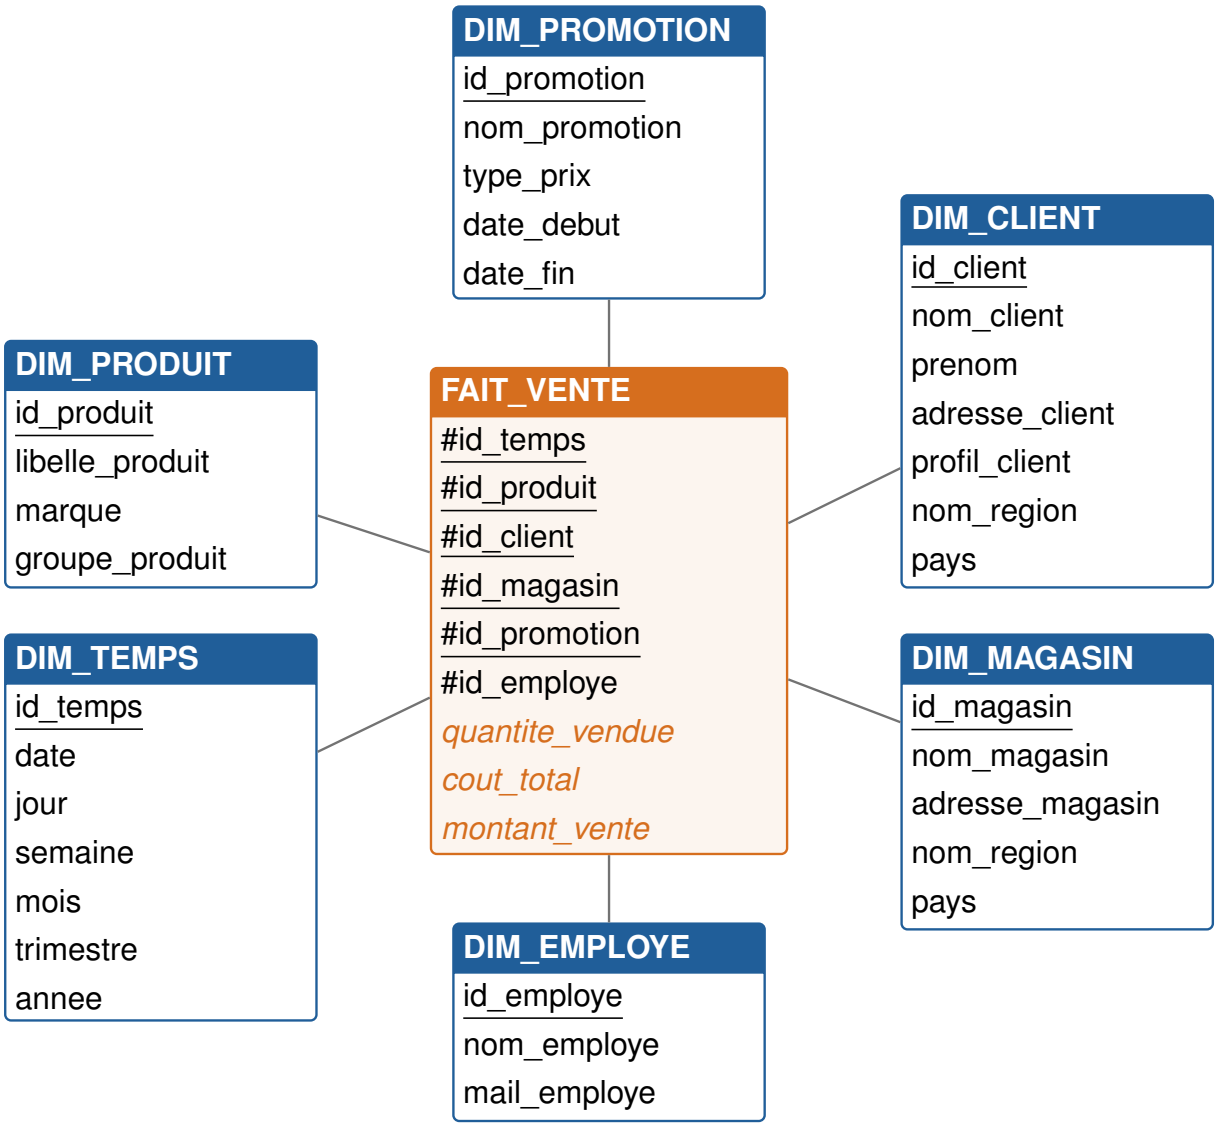
EXERCICE 2 : VENTES D'UNE ENTREPRISE INDUSTRIELLE

Besoin : analyser dans le temps les **quantités vendues** et les **coûts associés**, par produit, client, magasin et promotion.

- **Fait :** la vente.
- **Grain :** une ligne = un produit vendu à un client, dans un magasin, un jour donné, sous une promotion donnée.
- **Mesures :** `quantite_vendue`, `cout_total` (coût associé à la vente) et `montant_vente`. Elles sont **additives** : on peut les sommer sur tous les axes.
- **Dimensions :** Temps, Produit, Client, Magasin, Promotion. Les données fournies contiennent aussi `nom_employé` et `mail_employé` : les employés enregistrent les clients, on ajoute donc une dimension Employé (performance des vendeurs).

1. MODÈLE EN ÉTOILE

Chaque dimension est **une seule table dénormalisée** : les hiérarchies (groupe de produit, région, pays. . .) sont des colonnes de la dimension.



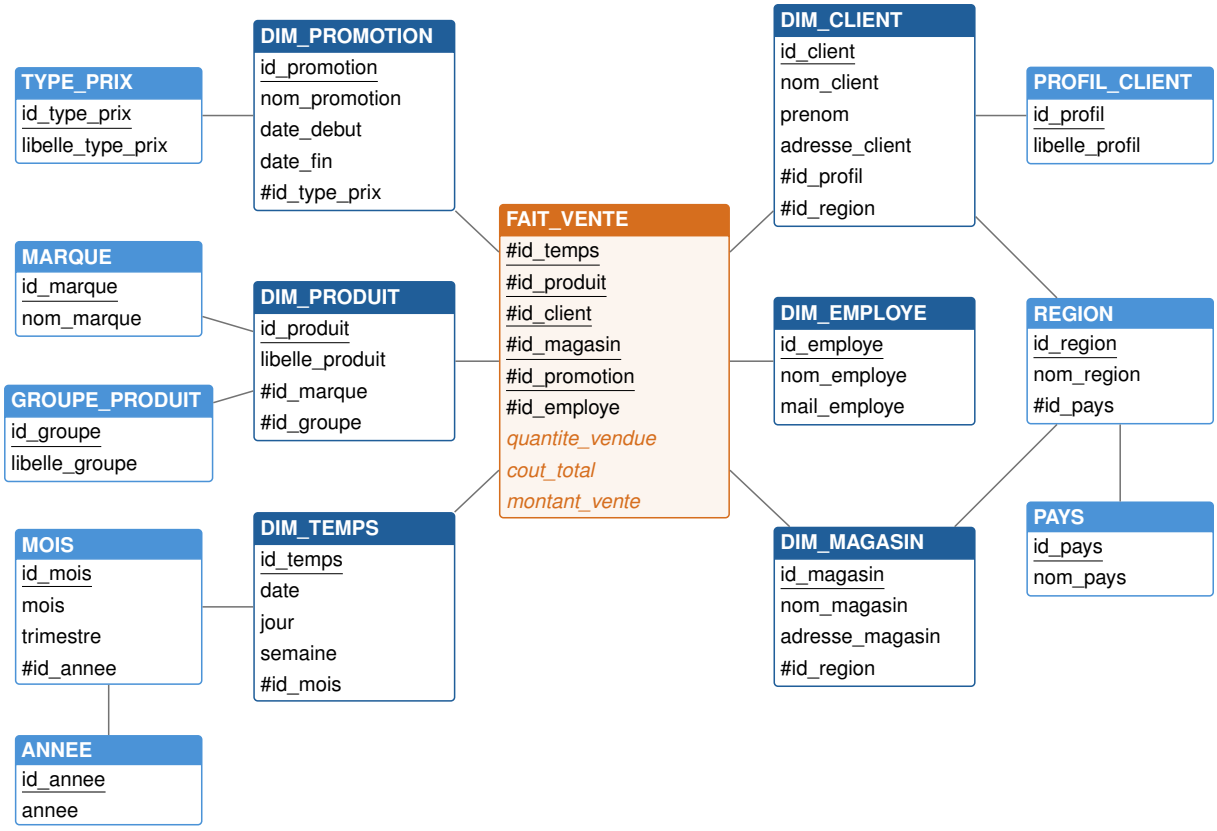
Légende : clé primaire #clé étrangère *mesure*

La clé primaire de la table de faits est la combinaison des clés des dimensions qui définissent le grain. `id_employe` est une clé étrangère simple : il décrit la vente sans en changer le grain.

2. MODÈLE EN FLOCON

On **normalise les hiérarchies** des dimensions : chaque niveau devient une sous-table reliée par une clé étrangère. La table de faits ne change pas.

- Produit → Marque et Produit → Groupe de produit ;
- Client → Profil client ; Client et Magasin → Région → Pays (sous-tables **partagées**) ;
- Promotion → Type de prix ;
- Temps (jour) → Mois → Année.



Légende : clé primaire #clé étrangère *mesure*

3. AVANTAGES ET INCONVÉNIENTS

	Modèle en étoile	Modèle en flocon
Structure	Une table par dimension, dénormalisée	Dimensions normalisées en sous-tables
Requêtes	✓ Simples, peu de jointures (fait ↔ dimension)	✗ Plus de jointures, requêtes plus longues à écrire
Performances	✓ Rapides en lecture, adaptées à l'OLAP	✗ Plus lentes sur de gros volumes
Stockage	✗ Redondance (ex. : le pays répété pour chaque client)	✓ Pas de redondance, moins d'espace disque
Mise à jour	✗ Une modification se répète sur de nombreuses lignes	✓ Une seule ligne à modifier, cohérence garantie
Hiérarchies	✗ Implicites, dans les colonnes	✓ Explicites, faciles à parcourir (*drill-down*)
Lisibilité	✓ Simple à comprendre pour les métiers	✗ Schéma plus complexe
Usage	Data marts, outils de reporting (Power BI. . .)	Dimensions volumineuses ou hiérarchies partagées

En pratique, l'**étoile** est privilégiée pour la restitution (les dimensions sont petites face à la table de faits, donc la redondance coûte peu). Le **flocon** se justifie quand une dimension est très volumineuse ou qu'une hiérarchie est partagée (ici Région/Pays entre clients et magasins).

EXERCICE 3 : RÉSERVATION D'HÔTELS

1. RÈGLES DE GESTION

RG1 : Un hôtel possède un **classement** de 1 à 5 étoiles.

RG2 : Un hôtel appartient à **0 ou 1 chaîne hôtelière** ; une chaîne regroupe un ou plusieurs hôtels.

RG3 : Un hôtel est situé à une adresse, dans une ville et un pays (Thierry voyage à l'étranger).

RG4 : Un hôtel est décrit par plusieurs **caractéristiques** (options : piscine, spa, Wi-Fi. . .) ; une même caractéristique se retrouve dans plusieurs hôtels.

RG5 : Un hôtel possède plusieurs **chambres** ; une chambre appartient à un seul hôtel.

RG6 : Une chambre est d'un seul **type** (simple, double, suite. . .) ; un type concerne plusieurs chambres.

RG7 : Le **tarif journalier** dépend du **type de chambre** et de la **date de réservation** (saison, période).

RG8 : Un client effectue une ou plusieurs **réservations** ; une réservation est faite par un seul client.

RG9 : Une réservation porte sur une ou plusieurs chambres, pour une **période** définie par une date d'arrivée et une date de départ (départ postérieur à l'arrivée).

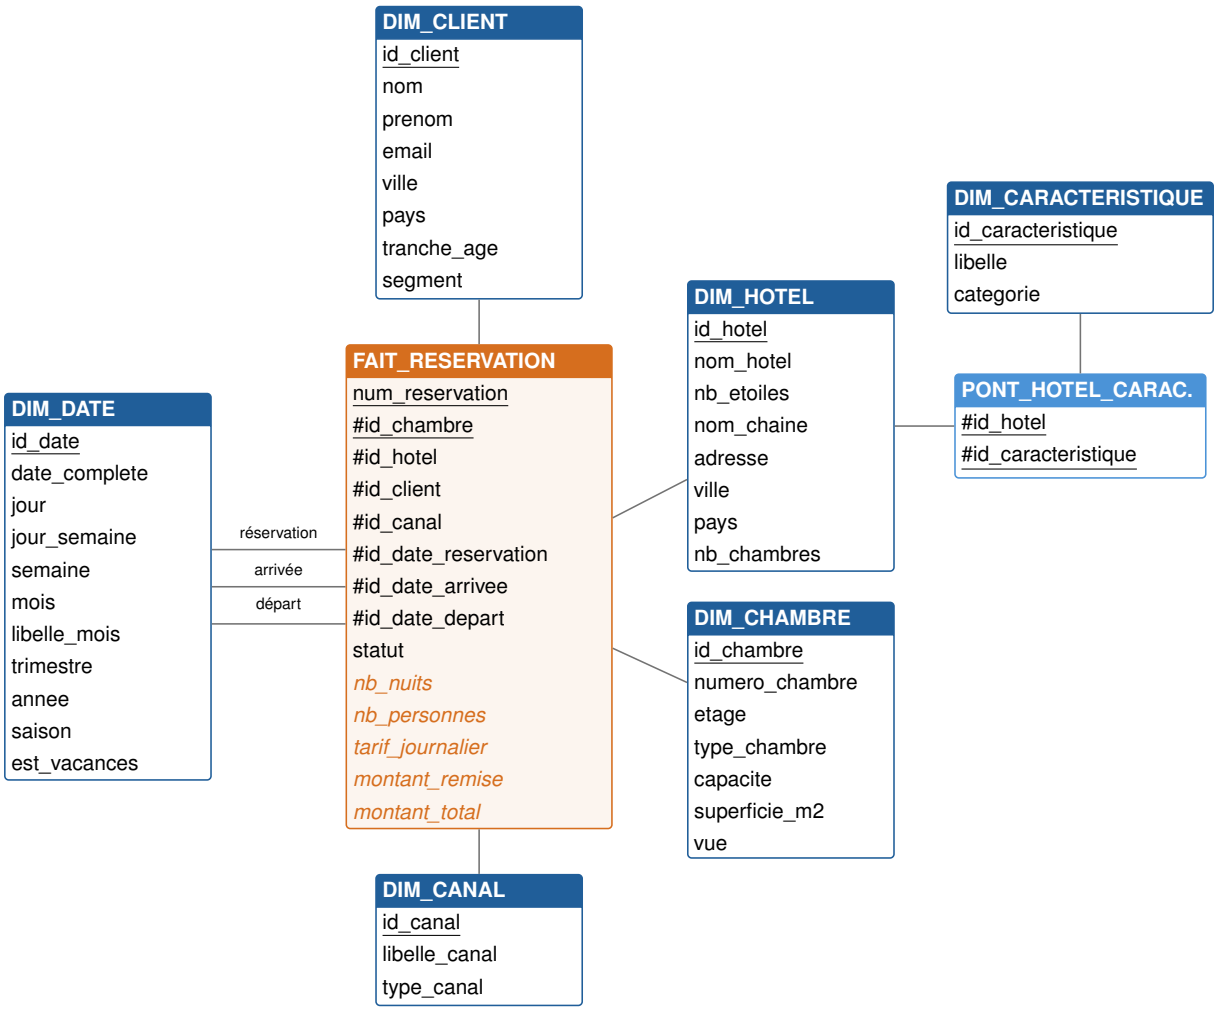
RG10 : Une chambre ne peut pas être réservée deux fois sur une même nuit : elle n'est **disponible** que si aucune réservation ne couvre la période demandée.

RG11 : Le **montant** d'une réservation vaut le nombre de nuits multiplié par le tarif journalier appliqué (moins une éventuelle remise).

RG12 : Une réservation peut être **modifiée** (réduction de la période, comme Thierry) ou **annulée**.

2. MODÈLE DIMENSIONNEL LOGIQUE : REVENUS DE L'HÔTEL

- **Fait :** la réservation (source du revenu). **Grain :** une chambre réservée dans une réservation ; le numéro de réservation est une **dimension dégénérée**.
- **Mesures :** `nb_nuits`, `nb_personnes`, `montant_remise`, `montant_total` (additives) et `tarif_journalier` (non additive : on en calcule la moyenne).
- La dimension Date joue **trois rôles** : réservation (qui fixe le tarif, RG7), arrivée et départ. Les caractéristiques sont reliées aux hôtels par une **table pont** (n-n, RG4).



Légende : clé primaire #clé étrangère *mesure*

MLD (notation relationnelle) :

DIM_DATE (id_date, date_complete, jour, jour_semaine, semaine, mois, libelle_mois, trimestre, annee, saison, est_vacances)
DIM_CLIENT (id_client, nom, prenom, email, ville, pays, tranche_age, segment)
DIM_HOTEL (id_hotel, nom_hotel, nb_etoiles, nom_chaine, adresse, ville, pays, nb_chambres)
DIM_CHAMBRE (id_chambre, numero_chambre, etage, type_chambre, capacite, superficie_m2, vue)
DIM_CANAL (id_canal, libelle_canal, type_canal)
DIM_CARACTERISTIQUE (id_caracteristique, libelle, categorie)
PONT_HOTEL_CARACTERISTIQUE (#id_hotel, #id_caracteristique)
FAIT_RESERVATION (num_reservation, #id_chambre, #id_hotel, #id_client, #id_canal, #id_date_reservation, #id_date_arrivee, #id_date_depart, statut, nb_nuits, nb_personnes, tarif_journalier, montant_remise, montant_total)

Ce modèle répond aux questions d'analyse des revenus : chiffre d'affaires par chaîne, hôtel, nombre d'étoiles ou type de chambre ; évolution selon la saison ou le mois d'arrivée ; tarif moyen par type de chambre ; durée moyenne de séjour ; part des réservations modifiées ou annulées ; revenu selon le canal ou le pays d'origine du client.

EXERCICE 4 : MODÈLE PHYSIQUE DE DONNÉES

Le modèle physique traduit le MLD de l'exercice 3 pour un SGBD précis, ici **PostgreSQL** : chaque attribut reçoit un **type** de données, et on précise les **contraintes** (clés, valeurs autorisées, `NOT NULL`). Le schéma est présenté page suivante.

CHOIX D'IMPLÉMENTATION

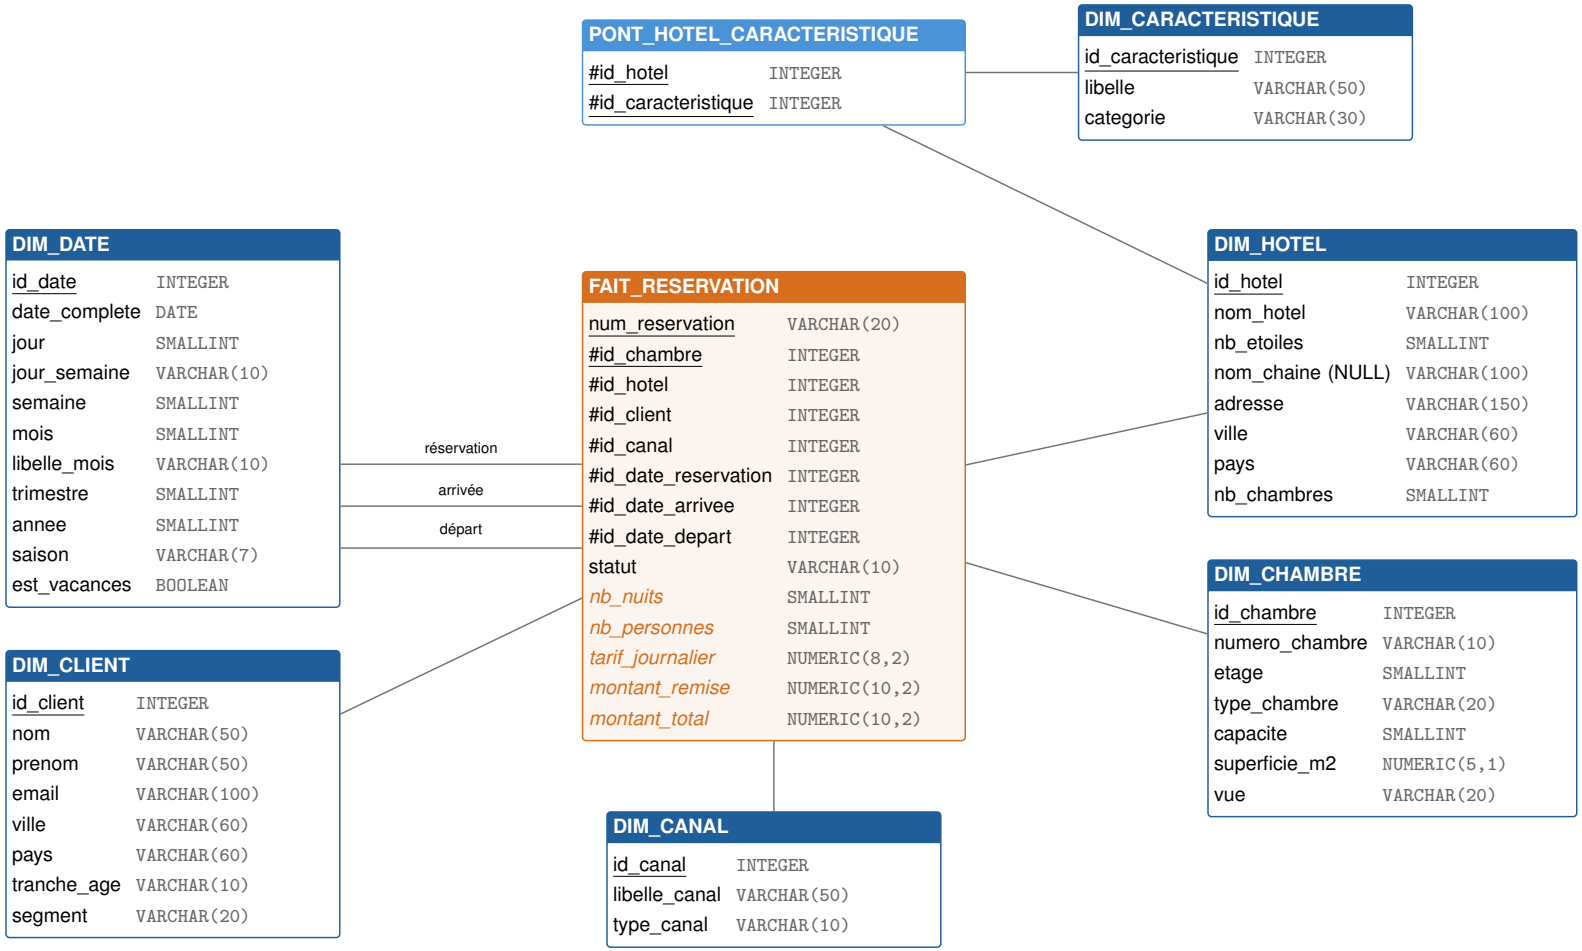
Élément	Choix
Clés des dimensions	`INTEGER` : clés de substitution (*surrogate keys*) attribuées par l'ETL, indépendantes des identifiants sources
Clé de la date	`INTEGER` au format `AAAAMMJJ` (ex. : `20270702`) : lisible et ordonnée
Montants	`NUMERIC(p,2)` : valeurs exactes, sans erreur d'arrondi (pas de `FLOAT`)
Petits entiers	`SMALLINT` (étoiles, nuits, capacité, mois…)
Textes	`VARCHAR(n)` dimensionnés selon la donnée
Booléens	`BOOLEAN` (`est_vacances`)

CONTRAINTES

- **Intégrité :** `PRIMARY KEY` sur chaque table, `FOREIGN KEY` du fait vers les dimensions, `NOT NULL` sur les attributs obligatoires (`nom_chaine` reste `NULL` pour un hôtel indépendant).
- **Domaines (`CHECK`) :** `nb_etoiles` entre 1 et 5 ; `statut` $\in$ {Confirmée, Modifiée, Annulée} ; `type_chambre` $\in$ {Simple, Double, Twin, Suite, Familiale} ; `nb_nuits`, `nb_personnes` > 0 ; montants ≥ 0.
- **Cohérence des dates :** date de réservation $\leq$ date d'arrivée $<$ date de départ.
- **Performances :** index sur les clés étrangères de `FAIT_RESERVATION`, utilisées dans toutes les jointures.

Le script SQL correspondant (`sql/ex4_hotel_datamart.sql`) a été testé avec un jeu d'essai (`sql/ex4_jeu_essai.sql`) : les contraintes rejettent bien un départ antérieur à l'arrivée, une chambre inexistante ou un hôtel à 6 étoiles.

SCHÉMA DU MODÈLE PHYSIQUE

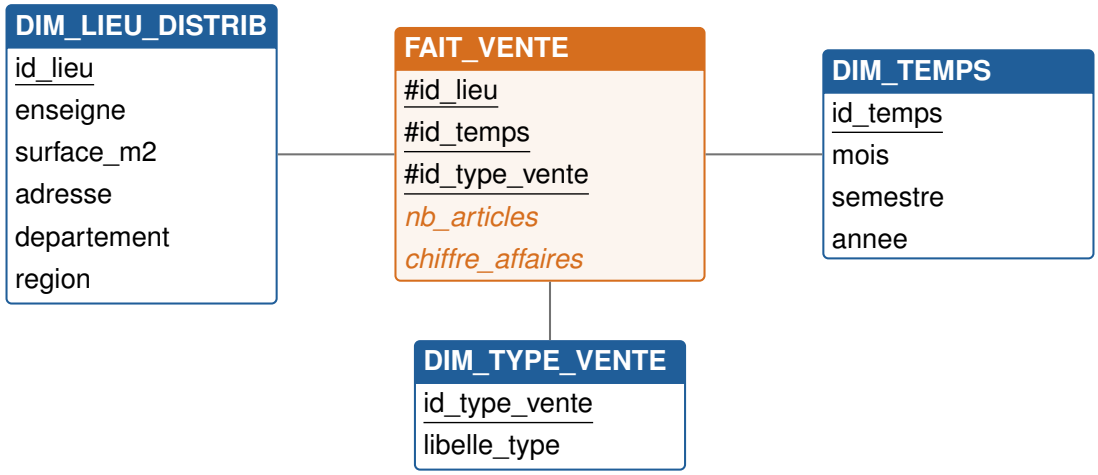


Légende : clé primaire #clé étrangère *mesure*

EXERCICE 5 : DATA MART DES VENTES DE MEUBLES

- **Fait à observer :** la vente.
- **Axes d'analyse :** le lieu de distribution (enseigne, surface, adresse, département, région), le temps (mois, semestre, année) et le type de vente.
- **Mesures :** le **nombre d'articles** vendus et le **chiffre d'affaires**.
- **Grain :** les ventes d'un type donné, dans un lieu de distribution, sur un mois.

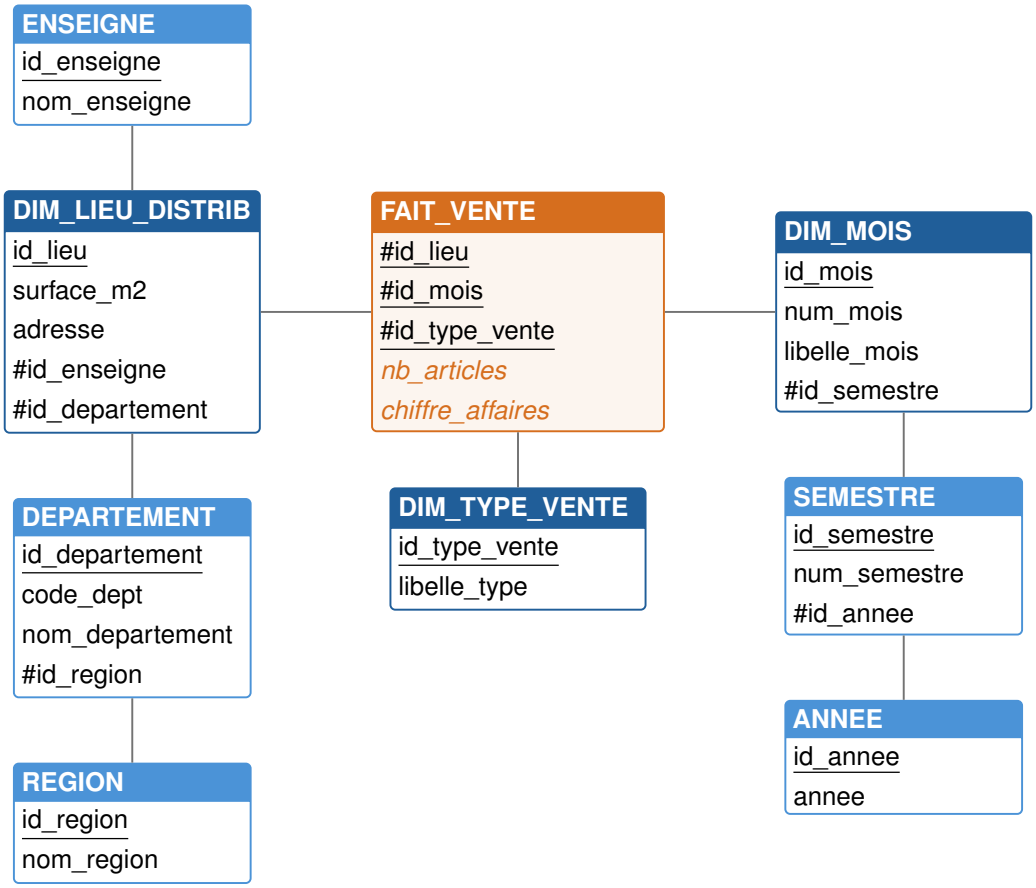
A) MODÈLE EN ÉTOILE



Légende : clé primaire #clé étrangère *mesure*

B) MODÈLE EN FLOCON

On normalise les hiérarchies : Lieu → Enseigne, Lieu → Département → Région, et Mois → Semestre → Année.

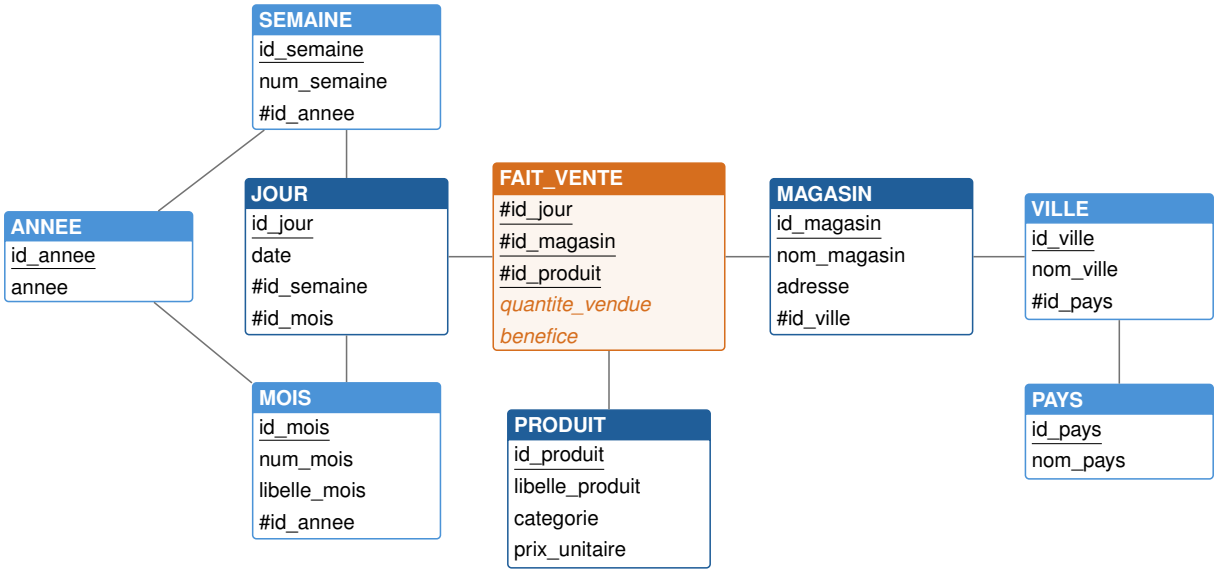


Légende : clé primaire #clé étrangère *mesure*

EXERCICE 6 : FLOCON, ÉTOILE ET CONSTELLATION

A) MODÈLE EN FLOCON

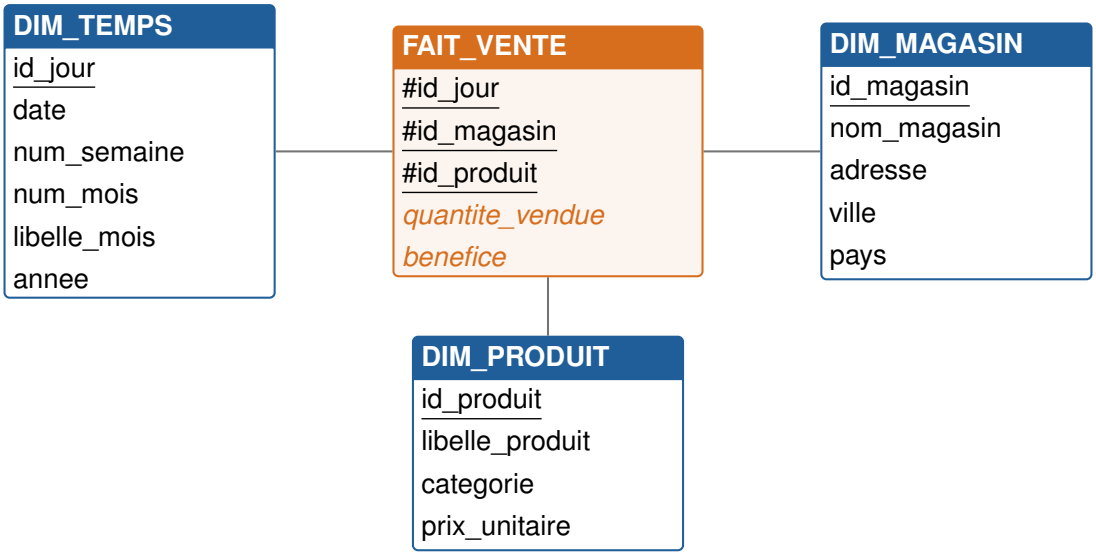
- **Fait :** la vente ; **grain :** un produit, dans un magasin, un jour donné.
- **Mesures :** `quantite_vendue` et `benefice`.
- **Temps :** deux hiérarchies parallèles, Jour → Semaine → Année et Jour → Mois → Année. Une semaine peut chevaucher deux mois : la semaine n'est donc pas un niveau du mois, les deux branches se rejoignent seulement au niveau Année.
- **Localisation :** Magasin → Ville → Pays.



Légende : clé primaire #clé étrangère *mesure*

B) MODÈLE EN ÉTOILE

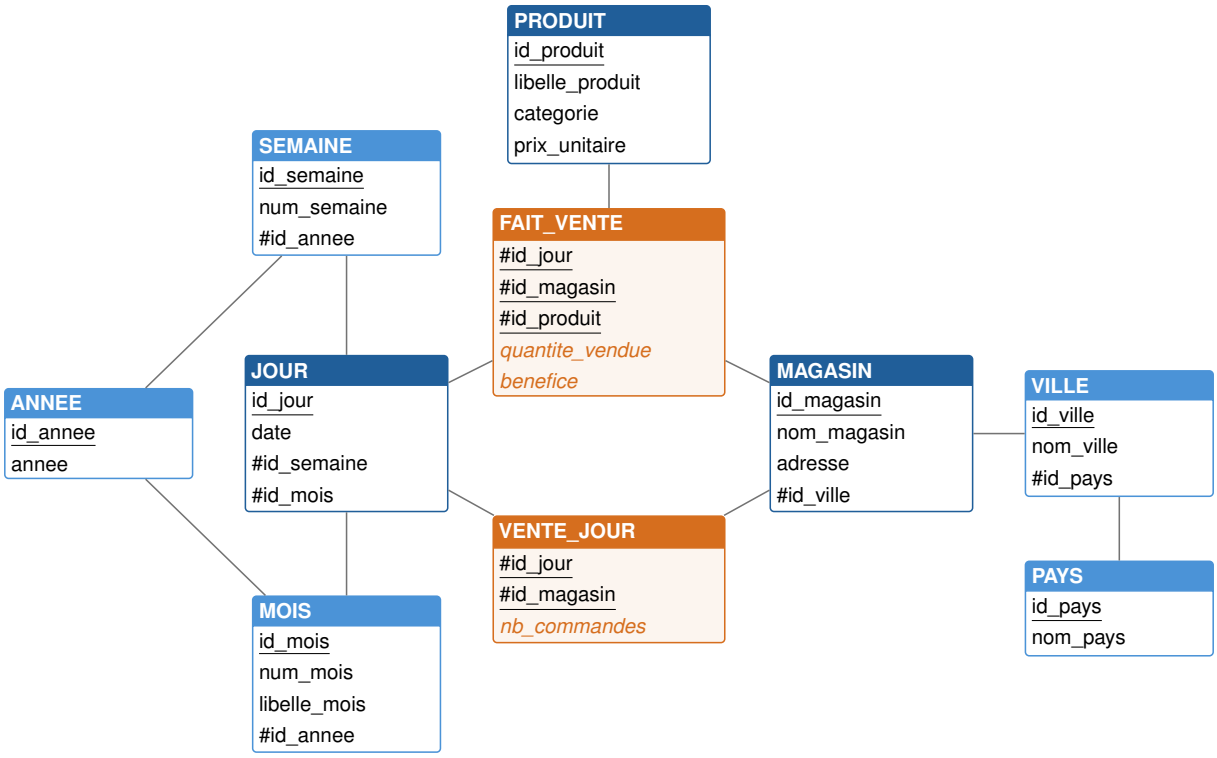
On **réduit les hiérarchies** en fusionnant leurs niveaux dans une seule table de dimension : Jour, Semaine, Mois et Année deviennent la dimension `DIM_TEMPS` ; Magasin, Ville et Pays deviennent `DIM_MAGASIN`. La table de faits reste identique.



Légende : clé primaire #clé étrangère *mesure*

C) MODÈLE EN CONSTELLATION

Le nombre de commandes se mesure **par jour et par magasin**, sans le produit : son grain est différent de celui de `FAIT_VENTE`. On ajoute donc une seconde table de faits, `VENTE_JOUR`, qui **partage** les dimensions Jour et Magasin (et leurs sous-tables) du flocon. Ces dimensions communes sont dites **conformes** : elles permettent de croiser les deux faits (ex. : quantité vendue moyenne par commande).



Légende : clé primaire #clé étrangère *mesure*

CONCLUSION

Ce workshop a suivi la démarche complète de modélisation d'un entrepôt de données :

1. **MCD** $\rightarrow$ **MLD** : les associations 1-n deviennent des clés étrangères, les associations n-n des tables d'association (historisées si besoin) ;
2. **modélisation dimensionnelle** : identifier le fait, fixer son grain, choisir des mesures additives et des axes d'analyse ;
3. **étoile, flocon ou constellation** : dénormaliser pour la performance et la simplicité, normaliser les hiérarchies pour limiter la redondance, partager des dimensions conformes entre plusieurs faits ;
4. **modèle physique** : typer les attributs, poser les contraintes d'intégrité et les index selon le SGBD cible.

Ces modèles ont une finalité **analytique et décisionnelle** : ils préparent le projet d'entrepôt de données hospitalier, où la même démarche s'applique (faits : consultations, hospitalisations ; dimensions : patient, établissement, diagnostic, temps).