CESI
ÉCOLE D'INGÉNIEURS

Projet CHU – Entrepôt de données

Livrable 1 | Référentiel et architecture

Vendredi 23 octobre 2026

Alexandre, Marine, Michael et Noa
Fisa Info 25–28
CESI

TABLE DES MATIÈRES

Introduction **2**

1 Modèle conceptuel et logique **3**
1.1 Modèle dimensionnel conceptuel 3
1.2 Schéma en constellation (modèle logique) 5
1.3 Dictionnaire de données 9

2 Architecture cible **14**
2.1 Zones de stockage 15
2.2 Flux de données de bout en bout 16
2.3 Technologies retenues et justification 17

3 Spécifications fonctionnelles des jobs ETL **19**
3.1 Sources 19
3.2 Règles de transformation 20
3.3 Valeurs nulles et doublons 22
3.4 Erreurs et rejets 22
3.5 Fréquence d'exécution 23

4 Plan de gouvernance des données **25**
4.1 Conformité RGPD 25
4.2 Conformité HDS 25
4.3 Rôles et droits d'accès 25
4.4 Traçabilité des flux 25

Conclusion **26**

Annexes **27**
Annexe A – Modèle dimensionnel conceptuel 27
Annexe B – Schéma logique en constellation 28

INTRODUCTION

Un groupe hospitalier universitaire (CHU) souhaite se doter d'un **entrepôt de données décisionnel**. Ses données sont aujourd'hui dispersées entre une base opérationnelle, des fichiers de référence et des fichiers déposés sur un serveur FTP. Elles ne permettent pas de suivre l'activité des établissements dans le temps ni de les comparer entre eux.

L'entrepôt doit servir deux publics : les **praticiens** (médecins, infirmiers), qui suivent l'activité de soins, et la **direction** des établissements, qui pilote l'offre et la qualité. Il doit permettre de calculer huit indicateurs, dont six obligatoires : les taux de consultation, d'hospitalisation, de décès et de satisfaction, croisés par établissement, période, diagnostic, professionnel, sexe, âge ou région.

Quatre sources alimentent l'entrepôt :

- la **base opérationnelle** PostgreSQL (patients, consultations, hospitalisations, diagnostics, professionnels) ;
- le **référentiel des établissements** de santé, au format CSV ;
- les **enquêtes de satisfaction** des patients, déposées sur le serveur FTP ;
- le **fichier des décès** publié par l'INSEE, déposé sur le serveur FTP.

Ces données concernent la santé de personnes identifiables. Leur traitement doit respecter le RGPD, les recommandations de la CNIL et l'obligation d'hébergement certifié HDS. La solution doit aussi rester élastique face à la hausse des volumes et justifier chaque outil par son rapport coût-efficacité.

Ce premier livrable pose le **référentiel de données** et l'**architecture** de la solution. Il présente le modèle conceptuel et logique du schéma décisionnel avec son dictionnaire de données, l'architecture cible de l'entrepôt avec les technologies retenues, les spécifications fonctionnelles des jobs ETL et le plan de gouvernance des données.

1 MODÈLE CONCEPTUEL ET LOGIQUE

Le modèle décisionnel est le socle de l'entrepôt : il fixe ce que l'on mesure et selon quels axes. Il suit l'approche de **Kimball**, qui organise les données en **tables de faits**, contenant les mesures, et en **tables de dimensions**, contenant les axes d'analyse. Chaque fait correspond à un processus métier du CHU : une consultation, une hospitalisation, une réponse à une enquête de satisfaction ou un décès.

Plusieurs faits partagent les mêmes dimensions, comme le temps ou l'établissement. Le modèle forme donc une **constellation** de schémas en étoile, reliés par des dimensions communes, dites **conformes**. Cette partie présente d'abord le modèle dimensionnel conceptuel, puis sa traduction en schéma en constellation, qui constitue le modèle logique, et enfin le dictionnaire de données qui décrit chaque table et chaque attribut.

1.1 MODÈLE DIMENSIONNEL CONCEPTUEL

Le modèle dimensionnel conceptuel suit la démarche de Kimball : choisir les processus métier à analyser, fixer leur grain, puis identifier les dimensions qui les décrivent et les faits qu'ils mesurent. Il est indépendant de toute technologie et a été construit à partir de l'analyse des quatre sources. Quatre processus métier donnent les tables de faits : Consultations, Hospitalisations, Satisfaction et Décès. Six dimensions servent d'axes d'analyse : Temps, Établissement, Patient anonymisé, Diagnostic, Professionnel et Région INSEE.

La figure 1 présente le modèle dimensionnel conceptuel. Une version agrandie, en format paysage, est donnée en Annexe A.

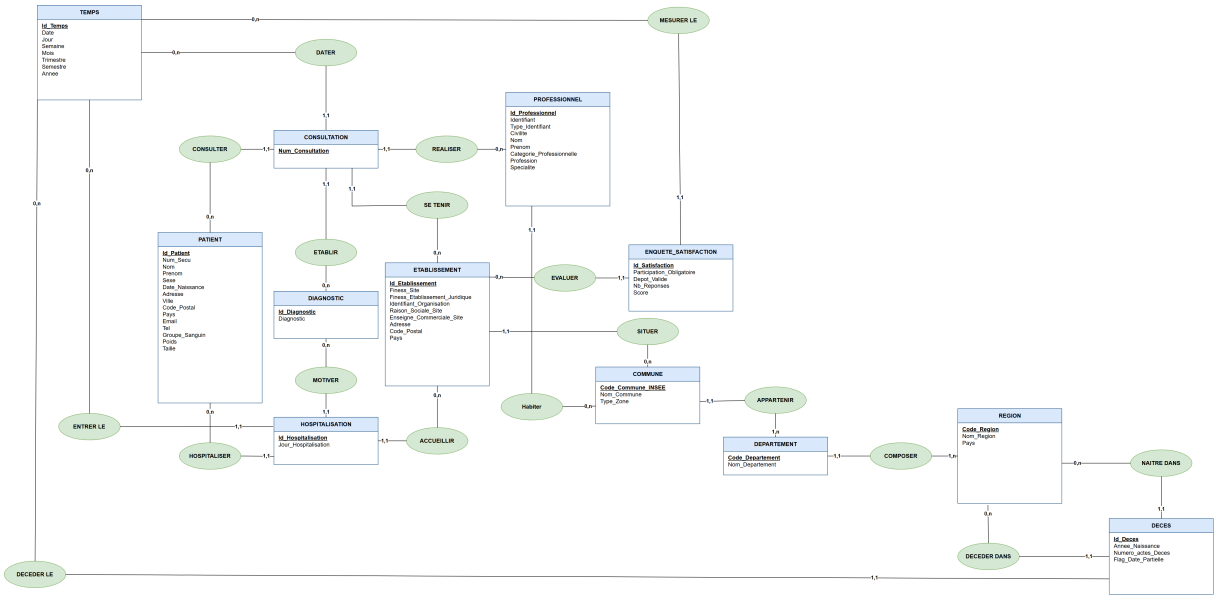


Figure 1 – Modèle dimensionnel conceptuel du CHU

CESI ÉCOLE D'INGÉNIEURS

Tables de faits et dimensions

Élément	Type	Table du modèle logique
Consultations	Table de faits (processus métier)	FAIT_CONSULTATION
Hospitalisations	Table de faits (processus métier)	FAIT_HOSPITALISATION
Satisfaction	Table de faits (processus métier)	FAIT_SATISFACTION
Décès	Table de faits (processus métier)	FAIT_DECES
Temps	Dimension conforme (Jour → Mois → Trimestre → Année)	DIM_Temps
Établissement	Dimension conforme	DIM_Etablissement
Patient anonymisé	Dimension	DIM_Patient
Diagnostic	Dimension	DIM_Diagnostic
Professionnel	Dimension	DIM_Professionnel
Région INSEE	Dimension (Commune → Département → Région)	DIM_Region_INSEE

Relations entre faits et dimensions

Chaque relation relie une table de faits à une dimension et se lit dans les deux sens : « une consultation est réalisée par exactement un professionnel (1,1) ; un professionnel réalise zéro, une ou plusieurs consultations (0,n) ». Toutes les relations sont de ce type, ce qui permet de les traduire en clés étrangères de la table de faits. La dimension Région INSEE joue deux rôles pour les décès (lieu de décès et lieu de naissance).

Rôle	Table de faits	Card.	Dimension	Card.
Auteur	Consultations	1,1	Professionnel	0,n
Patient	Consultations	1,1	Patient anonymisé	0,n
Diagnostic posé	Consultations	1,1	Diagnostic	0,n
Lieu	Consultations	1,1	Établissement	0,n
Date	Consultations	1,1	Temps	0,n
Patient	Hospitalisations	1,1	Patient anonymisé	0,n
Motif	Hospitalisations	1,1	Diagnostic	0,n
Lieu d'accueil	Hospitalisations	1,1	Établissement	0,n
Date d'entrée	Hospitalisations	1,1	Temps	0,n
Établissement évalué	Satisfaction	1,1	Établissement	0,n
Période de l'enquête	Satisfaction	1,1	Temps	0,n
Lieu de décès	Décès	1,1	Région INSEE	0,n
Lieu de naissance	Décès	1,1	Région INSEE	0,n
Date de décès	Décès	1,1	Temps	0,n

Les hiérarchies sont portées à l'intérieur des dimensions : Commune → Département → Région dans la dimension Région INSEE, Jour → Mois → Trimestre → Année dans la dimension Temps. L'établissement et le professionnel sont situés par leur commune, qui reste un attribut de leur dimension. Au passage au modèle logique, ces hiérarchies sont dénormalisées dans leur dimension, ce qui évite un schéma en flocon : les requêtes par région ne nécessitent qu'une seule jointure, au prix d'une légère redondance des libellés de département et de région.

1.2 SCHÉMA EN CONSTELLATION (MODÈLE LOGIQUE)

Le schéma en étoile constitue le **modèle logique** de l'entrepôt : il traduit le modèle conceptuel (partie 1.1) en tables relationnelles, avec leurs attributs et leurs clés, sans dépendre du moteur de stockage. Il compte **quatre tables de faits** et **six dimensions** ; chaque table de faits forme une étoile avec ses dimensions, et les étoiles se rejoignent sur DIM_Temps et DIM_Etablissement.

Granularité des faits

La granularité (le « grain ») définit ce que représente une ligne de la table de faits. Elle est fixée au niveau le plus fin disponible dans les sources, afin de pouvoir agréger ensuite sans perte d'information.

Table de faits	Grain (1 ligne =)	Mesures
FAIT_CONSULTATION	1 consultation d'un patient par un professionnel, dans un établissement, à une date	Nombre_de_consultation
FAIT_ HOSPITALISATION	1 séjour hospitalier d'un patient dans un établissement	Jour_Hospitalisation (durée)
FAIT_SATISFACTION	1 résultat d'enquête pour un établissement et une période	Nb_Reponses, Score
FAIT_DECES	1 décès du fichier INSEE	Age_Deces (et comptage des lignes)

Matrice faits × dimensions

La matrice ci-dessous (dite « matrice en bus » chez Kimball) indique quelles dimensions chaque fait utilise. Une dimension présente dans plusieurs colonnes est une dimension conforme : elle a la même structure et les mêmes clés pour tous les faits, ce qui permet de croiser les indicateurs.

Dimension	Consultation	Hospitalisation	Satisfaction	Décès
DIM_Temps	X	X (date d'entrée)	X	X (date de décès)
DIM_Etablissement	X	X	X	
DIM_Patient	X	X		
DIM_Diagnostic	X	X		
DIM_Professionnel	X			
DIM_Region_INSEE				X (décès + naissance)

La figure 2 réunit ces éléments en une vue d'ensemble de la constellation : les quatre faits, les six dimensions et leurs clés. Une version agrandie, en format paysage, est donnée en Annexe B.

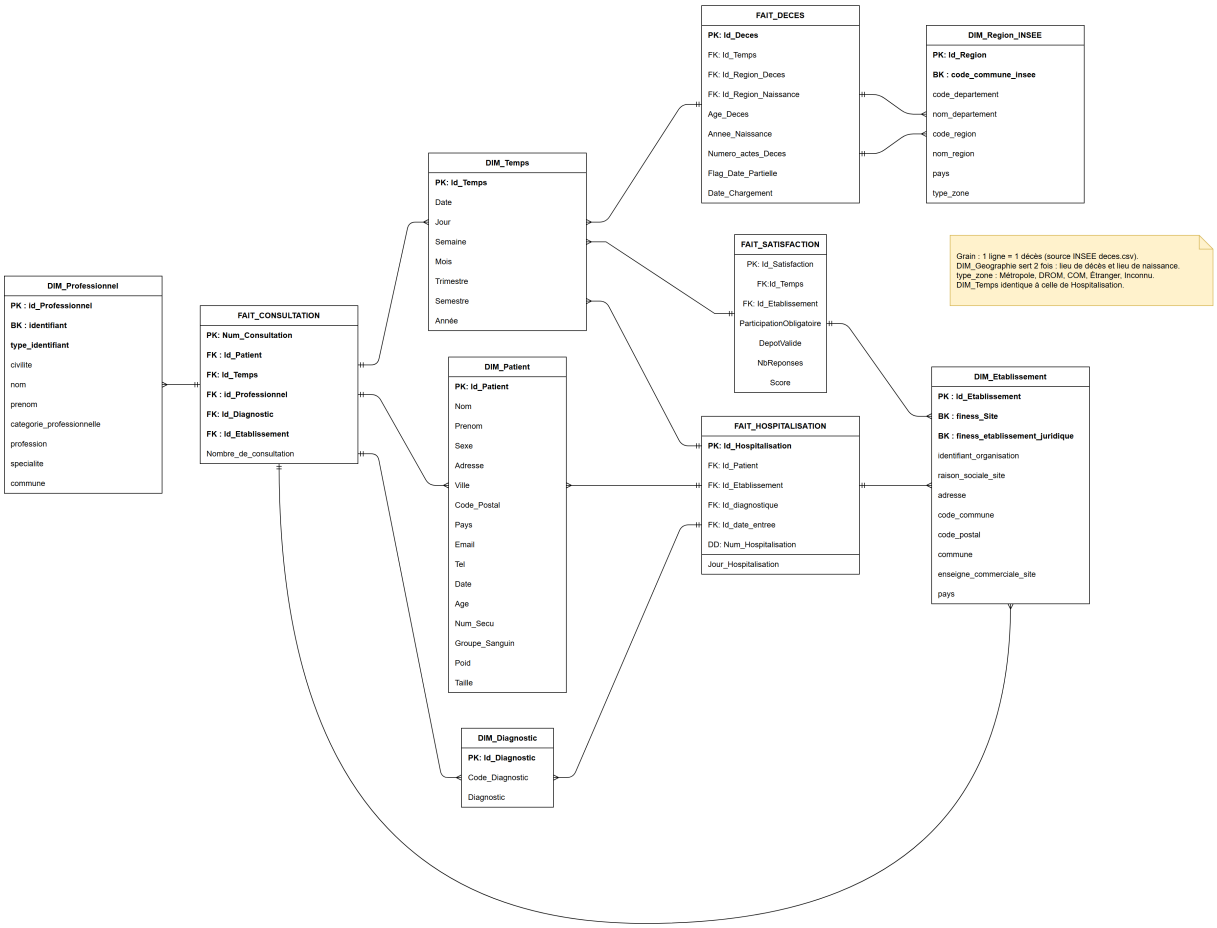


Figure 2 – Schéma logique en constellation du CHU

Couverture des besoins

Chaque besoin exprimé par le CHU se calcule à partir d'une seule table de faits et de ses dimensions, sans jointure entre faits.

N°	Besoin	Fait	Dimensions utilisées
1	Taux de consultation par établissement et par période	FAIT_CONSULTATION	DIM_Etablissement, DIM_Temps
2	Taux de consultation par diagnostic et par période	FAIT_CONSULTATION	DIM_Diagnostic, DIM_Temps
3	Taux global d'hospitalisation par période	FAIT_HOSPITALISATION	DIM_Temps
4	Taux d'hospitalisation par diagnostic et par période	FAIT_HOSPITALISATION	DIM_Diagnostic, DIM_Temps
5	Taux d'hospitalisation par sexe et par âge	FAIT_HOSPITALISATION	DIM_Patient
6	Taux de consultation par professionnel	FAIT_CONSULTATION	DIM_Professionnel
7	Nombre de décès par région en 2019 (optionnel)	FAIT_DECES	DIM_Region_INSEE (rôle décès), DIM_Temps
8	Taux global de satisfaction par région en 2020 (optionnel)	FAIT_SATISFACTION	DIM_Etablissement (→ région), DIM_Temps

Règles de passage

Trois règles ont permis de passer du modèle conceptuel (partie 1.1) aux tables :

1. chaque processus métier devient une table de faits ; ses relations vers les dimensions deviennent des **clés étrangères** ;
2. chaque dimension devient une table identifiée par une **clé de substitution** (entier sans signification métier), la clé de la source étant conservée comme **clé métier** (BK) ;
3. les hiérarchies (commune, département, région ; jour, mois, trimestre, année) sont **aplaties** dans leur dimension.

Notation : **PK** désigne une clé primaire, **FK** une clé étrangère, **BK** une clé métier et **DD** une dimension dégénérée (identifiant de la source conservé dans le fait sans table de dimension).

Schéma relationnel

Le schéma relationnel reprend la figure 2 sous forme textuelle. La clé primaire est soulignée et les clés étrangères sont précédées d'un #.

FAIT_CONSULTATION (Num_Consultation, #Id_Patient, #Id_Temps, #Id_Professionnel, #Id_Diagnostic, #Id_Etablissement, Nombre_de_consultation)

FAIT_HOSPITALISATION (Id_Hospitalisation, #Id_Patient, #Id_Etablissement, #Id_Diagnostic, #Id_Date_Entree, Num_Hospitalisation, Jour_Hospitalisation)

FAIT_SATISFACTION (Id_Satisfaction, #Id_Temps, #Id_Etablissement, Participation_Obligatoire, Depot_Valide, Nb_Reponses, Score)

FAIT_DECES (Id_Deces, #Id_Temps, #Id_Region_Deces, #Id_Region_Naissance, Age_Deces, Annee_Naissance, Numero_Acte_Deces, Flag_Date_Partielle, Date_Chargement)

DIM_Temps (Id_Temps, Date, Jour, Semaine, Mois, Trimestre, Semestre, Annee)

DIM_Patient (Id_Patient, Nom, Prenom, Sexe, Adresse, Ville, Code_Postal, Pays, Email, Tel, Date_Naissance, Age, Num_Secu, Groupe_Sanguin, Poids, Taille)

DIM_Diagnostic (Id_Diagnostic, Code_Diagnostic, Diagnostic)

DIM_Etablissement (Id_Etablissement, Finess_Site, Finess_Etablissement_Juridique, Identifiant_Organisation, Raison_Sociale_Site, Enseigne_Commerciale_Site, Adresse, Code_Commune, Code_Postal, Commune, Pays)

DIM_Professionnel (Id_Professionnel, Identifiant, Type_Identifiant, Civilite, Nom, Prenom, Categorie_Professionnelle, Profession, Specialite, Commune)

DIM_Region_INSEE (Id_Region, Code_Commune_INSEE, Code_Departement, Nom_Departement, Code_Region, Nom_Region, Pays, Type_Zone)

Clés étrangères et cardinalités

Toutes les relations du schéma sont de type **un-à-plusieurs** : une ligne de dimension est référencée par zéro, une ou plusieurs lignes de faits, et chaque ligne de faits référence exactement une ligne de dimension. Les clés étrangères des faits sont donc **non nulles** ; une valeur absente dans la source est rattachée à un membre « Inconnu » (clé -1) de la dimension plutôt que laissée à NULL, pour ne perdre aucune ligne dans les agrégats.

Table de faits	Clé étrangère	Dimension référencée	Côté dimension	Côté fait
FAIT_CONSULTATION	Id_Patient	DIM_Patient	1	0..n
FAIT_CONSULTATION	Id_Temps	DIM_Temps	1	0..n
FAIT_CONSULTATION	Id_Professionnel	DIM_Professionnel	1	0..n
FAIT_CONSULTATION	Id_Diagnostic	DIM_Diagnostic	1	0..n
FAIT_CONSULTATION	Id_Etablissement	DIM_Etablissement	1	0..n
FAIT_HOSPITALISATION	Id_Patient	DIM_Patient	1	0..n
FAIT_HOSPITALISATION	Id_Etablissement	DIM_Etablissement	1	0..n
FAIT_HOSPITALISATION	Id_Diagnostic	DIM_Diagnostic	1	0..n
FAIT_HOSPITALISATION	Id_Date_Entree	DIM_Temps	1	0..n
FAIT_SATISFACTION	Id_Temps	DIM_Temps	1	0..n
FAIT_SATISFACTION	Id_Etablissement	DIM_Etablissement	1	0..n
FAIT_DECES	Id_Temps	DIM_Temps	1	0..n
FAIT_DECES	Id_Region_Deces	DIM_Region_INSEE	1	0..n
FAIT_DECES	Id_Region_Naissance	DIM_Region_INSEE	1	0..n

Choix de modélisation

- **Clés de substitution** : les dimensions sont identifiées par un entier généré par l'ETL. Elles isolent l'entrepôt des changements de codification des sources et accélèrent les jointures.
- **Dimensions conformes** : DIM_Temps et DIM_Etablissement sont uniques et partagées, ce qui garantit que « mars 2019 » ou « tel établissement » ont le même sens pour tous les indicateurs.
- **Dimension à rôles multiples** : DIM_Region_INSEE est jouée deux fois par FAIT_DECES (lieu de décès et lieu de naissance), via deux clés étrangères distinctes.
- **Dimensions dégénérées** : Num_Hospitalisation et Numero_Acte_Deces restent dans les faits pour le dédoublonnage et la traçabilité vers la source.
- **Mesures** : les mesures additives (Nombre_de_consultation, Jour_Hospitalisation, Nb_Reponses) se somment sur tous les axes ; Score est non additif et s'agrège en moyenne pondérée par Nb_Reponses.

1.3 DICTIONNAIRE DE DONNÉES

Le dictionnaire décrit chaque table et chaque attribut du modèle. Les types sont exprimés en SQL standard (compatibles PostgreSQL) ; ils seront ajustés au moteur retenu lors de l'implémentation physique (livrable 2).

Légende de la colonne « Clé » : **PK** clé primaire, **FK** clé étrangère, **BK** clé métier (identifiant de la source, unique dans la dimension), **DD** dimension dégénérée.

FAIT_CONSULTATION

Type : Table de faits. **Grain** : 1 ligne = 1 consultation réalisée par un professionnel pour un patient, dans un établissement, à une date.
Source : base opérationnelle PostgreSQL (consultations, diagnostics, patients, professionnels).
Besoins couverts : 1, 2 et 6.

Attribut	Type	Clé	Null	Description
Num_Consultation	BIGINT	PK	Non	Identifiant de la consultation (numéro issu de la source).
Id_Patient	INTEGER	FK	Non	Patient consulté → DIM_Patient.
Id_Temps	INTEGER	FK	Non	Date de la consultation → DIM_Temps.
Id_Professionnel	INTEGER	FK	Non	Professionnel qui réalise la consultation → DIM_Professionnel.
Id_Diagnostic	INTEGER	FK	Non	Diagnostic posé → DIM_Diagnostic (membre « Non renseigné » si absent).
Id_Etablissement	INTEGER	FK	Non	Établissement où se tient la consultation → DIM_Etablissement.
Nombre_de_consultation	SMALLINT		Non	Mesure additive, vaut 1 par ligne. Sa somme donne le nombre de consultations.

FAIT_HOSPITALISATION

Type : Table de faits. **Grain** : 1 ligne = 1 séjour hospitalier d'un patient dans un établissement.
Source : base opérationnelle PostgreSQL (séjours, admissions, diagnostics).
Besoins couverts : 3, 4 et 5.

Attribut	Type	Clé	Null	Description
Id_Hospitalisation	BIGINT	PK	Non	Clé de substitution du séjour.
Id_Patient	INTEGER	FK	Non	Patient hospitalisé → DIM_Patient.
Id_Etablissement	INTEGER	FK	Non	Établissement d'accueil → DIM_Etablissement.
Id_Diagnostic	INTEGER	FK	Non	Diagnostic à l'origine du séjour → DIM_Diagnostic.
Id_Date_Entree	INTEGER	FK	Non	Date d'entrée du séjour → DIM_Temps (rôle « date d'entrée »).
Num_Hospitalisation	VARCHAR(20)	DD	Non	Dimension dégénérée : numéro du séjour dans la source, conservé pour la traçabilité.
Jour_Hospitalisation	SMALLINT		Oui	Mesure additive : durée du séjour en jours.

FAIT_SATISFACTION

Type : Table de faits. **Grain** : 1 ligne = 1 résultat d'enquête de satisfaction pour un établissement et une période de mesure.
Source : fichiers plats déposés sur le serveur FTP (enquêtes de satisfaction).
Besoins couverts : 8.

Attribut	Type	Clé	Null	Description
Id_Satisfaction	BIGINT	PK	Non	Clé de substitution du résultat d'enquête.
Id_Temps	INTEGER	FK	Non	Période de mesure → DIM_Temps.
Id_Etablissement	INTEGER	FK	Non	Établissement évalué → DIM_Etablissement.
Participation_Obligatoire	BOOLEAN		Oui	Indique si l'établissement était tenu de participer à l'enquête.
Depot_Valide	BOOLEAN		Oui	Indique si le dépôt des résultats a été validé.
Nb_Reponses	INTEGER		Oui	Mesure additive : nombre de questionnaires exploitables.
Score	NUMERIC(5,2)		Oui	Mesure non additive : score global de satisfaction. Agrégé en moyenne pondérée par Nb_Reponses.

FAIT_DECES

Type : Table de faits. **Grain** : 1 ligne = 1 décès enregistré dans le fichier INSEE (deces.csv, environ 25 millions de lignes).
Source : fichier des personnes décédées de l'INSEE (open data), déposé sur le serveur FTP.
Besoins couverts : 7.

Attribut	Type	Clé	Null	Description
Id_Deces	BIGINT	PK	Non	Clé de substitution du décès.
Id_Temps	INTEGER	FK	Non	Date du décès → DIM_Temps (rôle « date de décès »).
Id_Region_Deces	INTEGER	FK	Non	Lieu du décès → DIM_Region_INSEE (rôle « lieu de décès »). Membre -1 « Inconnu » si le code est vide.
Id_Region_Naissance	INTEGER	FK	Non	Lieu de naissance → DIM_Region_INSEE (rôle « lieu de naissance »).
Age_Deces	SMALLINT		Oui	Âge au décès en années, calculé à partir des dates de naissance et de décès.
Annee_Naissance	SMALLINT		Oui	Année de naissance. Seule l'année est conservée (minimisation RGPD).
Numero_Acte_Deces	VARCHAR(10)	DD	Oui	Dimension dégénérée : numéro de l'acte de décès, utile au dédoublonnage.
Flag_Date_Partielle	BOOLEAN		Non	Vrai si la date de naissance ou de décès est incomplète dans la source (ex. « 1930 », « 1989-05 »).
Date_Chargement	TIMESTAMP		Non	Horodatage du chargement de la ligne (traçabilité ETL).

CESI ÉCOLE D'INGÉNIEURS

DIM_Temps

Type : Dimension conforme. **Grain** : 1 ligne = 1 jour calendaire.
Source : générée par l'ETL (calendrier), partagée par les quatre tables de faits.
Besoins couverts : tous (axe « période »).

Attribut	Type	Clé	Null	Description
Id_Temps	INTEGER	PK	Non	Clé au format AAAAMMJJ (ex. 20190315), lisible et triable.
Date	DATE		Non	Date complète.
Jour	SMALLINT		Non	Jour du mois (1 à 31).
Semaine	SMALLINT		Non	Numéro de semaine ISO (1 à 53).
Mois	SMALLINT		Non	Mois (1 à 12).
Trimestre	SMALLINT		Non	Trimestre (1 à 4).
Semestre	SMALLINT		Non	Semestre (1 ou 2).
Annee	SMALLINT		Non	Année civile.

DIM_Patient

Type : Dimension. **Grain** : 1 ligne = 1 patient.
Source : base opérationnelle PostgreSQL (table des patients).
Besoins couverts : 5 (sexe, âge).

Attribut	Type	Clé	Null	Description
Id_Patient	INTEGER	PK	Non	Clé de substitution du patient.
Nom	VARCHAR(100)		Oui	Nom du patient. Donnée identifiante.
Prenom	VARCHAR(100)		Oui	Prénom du patient. Donnée identifiante.
Sexe	CHAR(1)		Non	Sexe (M, F, I pour inconnu).
Adresse	VARCHAR(255)		Oui	Adresse postale. Donnée identifiante.
Ville	VARCHAR(100)		Oui	Ville de résidence.
Code_Postal	CHAR(5)		Oui	Code postal de résidence.
Pays	VARCHAR(50)		Oui	Pays de résidence.
Email	VARCHAR(255)		Oui	Adresse électronique. Donnée identifiante.
Tel	VARCHAR(20)		Oui	Téléphone. Donnée identifiante.
Date_Naissance	DATE		Oui	Date de naissance (attribut « Date » du schéma).
Age	SMALLINT		Oui	Âge du patient en années.
Num_Secu	CHAR(15)		Oui	Numéro de sécurité sociale (NIR). Donnée identifiante.
Groupe_Sanguin	VARCHAR(3)		Oui	Groupe sanguin (A+, O-. . .).
Poids	NUMERIC(5,1)		Oui	Poids en kg.
Taille	NUMERIC(4,1)		Oui	Taille en cm.

DIM_Diagnostic

Type : Dimension. **Grain** : 1 ligne = 1 code diagnostic.
Source : base opérationnelle PostgreSQL (table des diagnostics).
Besoins couverts : 2 et 4.

Attribut	Type	Clé	Null	Description
Id_Diagnostic	INTEGER	PK	Non	Clé de substitution du diagnostic.
Code_Diagnostic	VARCHAR(10)	BK	Non	Code du diagnostic dans la source (clé métier).
Diagnostic	VARCHAR(255)		Non	Libellé du diagnostic.

DIM_Etablissement

Type : Dimension conforme. **Grain** : 1 ligne = 1 site géographique d'établissement (FINESS site).
Source : fichier CSV de gestion administrative des établissements (référentiel FINESS).
Besoins couverts : 1 et 8 ; partagée par Consultation, Hospitalisation et Satisfaction.

Attribut	Type	Clé	Null	Description
Id_Etablissement	INTEGER	PK	Non	Clé de substitution de l'établissement.
Finess_Site	CHAR(9)	BK	Non	Numéro FINESS du site géographique (clé métier).
Finess_Etablissement_Juridique	CHAR(9)	BK	Oui	Numéro FINESS de l'entité juridique de rattachement.
Identifiant_Organisation	VARCHAR(30)		Oui	Identifiant de l'organisation dans le référentiel.
Raison_Sociale_Site	VARCHAR(255)		Non	Raison sociale du site.
Enseigne_Commerciale_Site	VARCHAR(255)		Oui	Enseigne commerciale du site.
Adresse	VARCHAR(255)		Oui	Adresse du site.
Code_Commune	CHAR(5)		Oui	Code commune INSEE du site (permet le rattachement à la région).
Code_Postal	CHAR(5)		Oui	Code postal du site.
Commune	VARCHAR(100)		Oui	Nom de la commune.
Pays	VARCHAR(50)		Oui	Pays.

DIM_Professionnel

Type : Dimension. **Grain** : 1 ligne = 1 professionnel de santé.
Source : référentiel des professionnels de santé.
Besoins couverts : 6.

Attribut	Type	Clé	Null	Description
Id_Professionnel	INTEGER	PK	Non	Clé de substitution du professionnel.
Identifiant	VARCHAR(20)	BK	Non	Identifiant national du professionnel (clé métier).
Type_Identifiant	VARCHAR(10)		Non	Nature de l'identifiant (ex. RPPS, ADELI).
Civilite	VARCHAR(10)		Oui	Civilité.
Nom	VARCHAR(100)		Non	Nom d'exercice.
Prenom	VARCHAR(100)		Oui	Prénom d'exercice.
Categorie_Professionnelle	VARCHAR(50)		Oui	Catégorie (civil, militaire, étudiant…).
Profession	VARCHAR(100)		Oui	Profession exercée (médecin, infirmier…).
Specialite	VARCHAR(150)		Oui	Spécialité ou savoir-faire.
Commune	VARCHAR(100)		Oui	Commune d'exercice.

DIM_Region_INSEE

Type : Dimension (à rôles multiples). **Grain** : 1 ligne = 1 commune INSEE, avec son département et sa région. Membre -1 « Inconnu » pour les codes vides.
Source : Code officiel géographique de l'INSEE, construit à partir des codes lieu du fichier des décès.
Besoins couverts : 7 ; jouée deux fois par FAIT_DECES (lieu de décès, lieu de naissance).

Attribut	Type	Clé	Null	Description
Id_Region	INTEGER	PK	Non	Clé de substitution de la commune.
Code_Commune_INSEE	CHAR(5)	BK	Oui	Code commune INSEE (2A/2B pour la Corse, 99xxx pour l'étranger). Clé métier.
Code_Departement	VARCHAR(3)		Oui	Code du département (3 caractères pour les DROM : 971 à 976).
Nom_Departement	VARCHAR(100)		Oui	Nom du département.
Code_Region	VARCHAR(3)		Oui	Code de la région (ex. 84).
Nom_Region	VARCHAR(100)		Oui	Nom de la région (ex. Auvergne-Rhône-Alpes).
Pays	VARCHAR(50)		Oui	Pays (France ou pays étranger).
Type_Zone	VARCHAR(10)		Non	Métropole, DROM, COM, Étranger ou Inconnu.

EN RÉSUMÉ

Le modèle décisionnel du CHU est une **constellation** construite selon l'approche de Kimball :

- **quatre tables de faits**, une par processus métier (Consultations, Hospitalisations, Satisfaction, Décès), chacune au grain le plus fin disponible dans les sources ;
- **six dimensions** (Temps, Établissement, Patient anonymisé, Diagnostic, Professionnel, Région INSEE), dont deux **conformes**, Temps et Établissement, partagées par plusieurs faits pour croiser les indicateurs ;
- des relations toutes **un-à-plusieurs**, traduites en clés étrangères non nulles vers des dimensions identifiées par des **clés de substitution** ;
- des hiérarchies (Commune $\rightarrow$ Département $\rightarrow$ Région, Jour $\rightarrow$ Mois $\rightarrow$ Trimestre $\rightarrow$ Année) dénormalisées dans leur dimension, sans schéma en flocon.

Chaque besoin du CHU se calcule à partir d'une seule table de faits et de ses dimensions. Le dictionnaire de données décrit les dix tables, leurs attributs, leurs types et leurs clés ; il sert de référence aux jobs ETL et à l'implémentation physique du livrable 2.

2 ARCHITECTURE CIBLE

L'architecture doit répondre à trois exigences : intégrer des sources hétérogènes, protéger des données de santé et suivre la hausse des volumes. Elle repose sur un **entrepôt de données** (*Data Warehouse*) : une base unique, historisée et structurée selon le modèle dimensionnel de la partie 1, conçue pour l'analyse et non pour la gestion quotidienne des soins.

Les données passent par une **zone de transit**, où elles sont déposées telles qu'elles arrivent des sources, avant d'être nettoyées et chargées dans l'entrepôt. Cette partie décrit le rôle de chaque zone, le parcours des données depuis les sources jusqu'au tableau de bord, puis les technologies retenues et les raisons de ces choix.

La figure 3 présente l'architecture retenue.

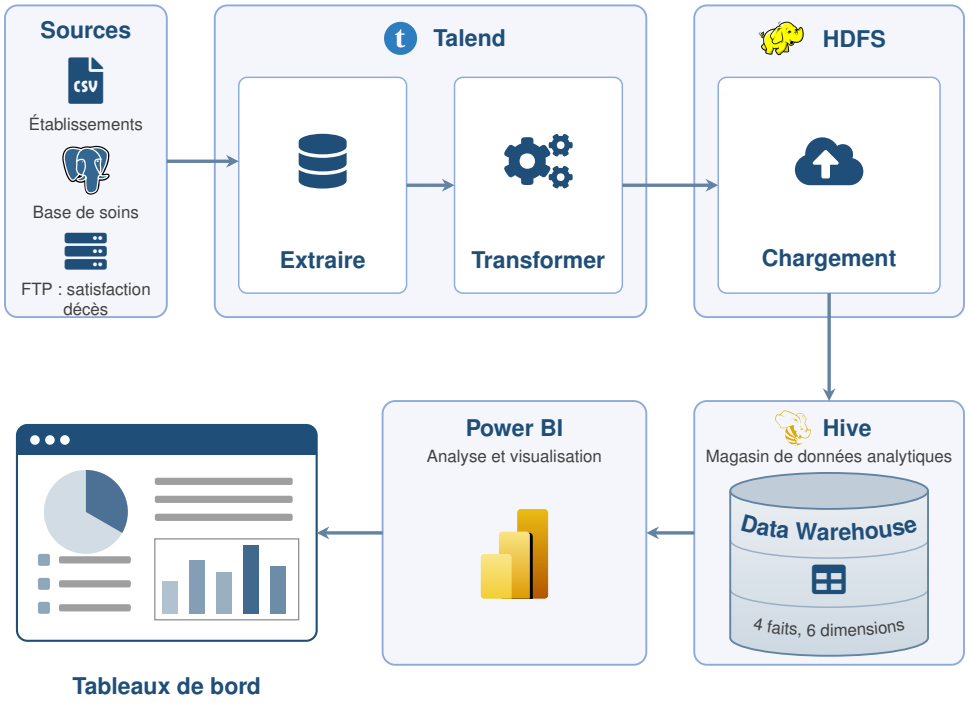


Figure 3 – Architecture cible de l'entrepôt du CHU

L'architecture choisie se décompose en quatre parties clés, chacune essentielle pour le traitement et le stockage des données :

— **La source des données :** elle regroupe l'ensemble des informations collectées. Ces données peuvent provenir de différentes sources et formats, comme des fichiers Excel, CSV, ou encore de bases de données relationnelles (MySQL, PostgreSQL, etc.).

— **L'extraction, la transformation et le chargement (ETL) :** cette étape est réalisée à l'aide de l'outil Talend et permet de préparer les données pour l'analyse. Les données sont nettoyées, standardisées et intégrées dans l'environnement HDFS.

— **Le magasin de données analytiques :** les données sont stockées dans un environnement dit distribué, permettant de répartir la charge sur plusieurs machines plutôt que sur une seule. Une fois stockées, les données sont structurées pour alimenter le Data Warehouse et peuvent être interrogées à l'aide de Hive.

— **Analyse et visualisation :** il est ensuite possible d'exploiter ces données à l'aide de Power BI pour concevoir des tableaux de bord (*dashboards*) permettant de mettre en lumière des tendances (*insights*) ou même des alertes en cas de traitement en continu. Cette brique offre à l'utilisateur une vision claire des informations importantes grâce à des tableaux, des courbes ou des graphiques sur les données traitées.

2.1 ZONES DE STOCKAGE

Le stockage est découpé en deux zones de HDFS, chacune avec ses droits d'accès. Les données ne sont jamais modifiées dans la zone de transit : l'entrepôt est produit à partir d'elle par les jobs Talend, ce qui permet de rejouer un chargement en cas d'erreur sans retourner aux sources.

Zone	Contenu	Traitements appliqués	Format et accès
Zone de transit (*staging*)	Copie fidèle des sources : extractions PostgreSQL, CSV des établissements, fichiers de satisfaction et de décès	Aucune transformation ; ajout de la date de chargement et du nom de la source	Format d'origine (CSV, JSON), un dossier par source et par date de chargement ; accès réservé à l'équipe d'ingénierie
Entrepôt de données	Constellation décrite en partie 1 : quatre tables de faits et six dimensions	Contrôle des types, harmonisation des codes (INSEE, FINESS), suppression des doublons, rejet des lignes invalides, pseudonymisation des patients, calcul des clés de substitution et des mesures	Tables Hive au format ORC, faits partitionnés par année ; seule zone ouverte à Power BI

Les lignes rejetées lors du chargement sont écrites dans une zone de rejets, à part, pour être analysées puis corrigées. Les données identifiantes (nom, prénom, numéro de sécurité sociale, coordonnées) ne dépassent pas la zone de transit : dans l'entrepôt, chaque patient n'est connu que par un identifiant pseudonyme.

2.2 FLUX DE DONNÉES DE BOUT EN BOUT

Le traitement est réalisé par lots (*batch*). Les indicateurs du CHU portent sur des périodes (mois, trimestre, année) : une actualisation quotidienne suffit et ne justifie pas le coût d'un traitement en continu. Le parcours d'une donnée suit quatre étapes :

1. **Collecte** : Talend lit la base PostgreSQL par requêtes SQL (extraction incrémentale sur la date de modification) et récupère les fichiers déposés sur le serveur FTP ;
2. **Dépôt en zone de transit** : les données sont écrites telles quelles dans HDFS, dans un dossier daté ;
3. **Transformation et chargement dans l'entrepôt** : les règles de qualité sont appliquées et les patients sont pseudonymisés ; les dimensions sont chargées en premier, puis les faits, qui reçoivent les clés de substitution des dimensions ;
4. **Restitution** : Power BI actualise ses jeux de données à partir des tables de l'entrepôt et met à jour les tableaux de bord.

Le tableau suivant résume le parcours de chaque source.

Source	Format	Acquisition	Tables alimentées
Base opérationnelle de soins	PostgreSQL	Connexion JDBC, extraction incrémentale	FAIT_CONSULTATION, DIM_Patient, DIM_Diagnostic, DIM_Professionnel
Référentiel des établissements	CSV	Fichier déposé, chargement complet	DIM_Etablissement
Hospitalisations	CSV	Fichier déposé, chargement incrémental	FAIT_HOSPITALISATION
Enquêtes de satisfaction	Fichiers plats (CSV ou JSON)	Serveur FTP	FAIT_SATISFACTION
Fichier des décès (INSEE)	Fichiers plats (CSV)	Serveur FTP	FAIT_DECES, DIM_Region_INSEE

DIM_Temps n'a pas de source : elle est générée une seule fois par un job Talend, avec un jour par ligne sur toute la période couverte par les données.

2.3 TECHNOLOGIES RETENUES ET JUSTIFICATION

Pourquoi avoir choisi ces outils ?

- **Talend :** Il a été choisi pour son rôle de chef d'orchestre des flux de données. Notre architecture repose sur un processus ETL (Extraire, Transformer, Charger), que Talend permet de mettre en œuvre facilement. Pour des données de santé, certaines étapes sont indispensables. Talend permet de se connecter à n'importe quel type de source sans avoir à coder des scripts manuels. Il gère également le nettoyage indispensable des données de santé (dates, lieux, motifs de consultation, etc.) tout en automatisant le chargement de ces données vers l'environnement Big Data.
- **HDFS (Hadoop Distributed File System) :** Le volume important des données nous a poussés à utiliser HDFS pour encaisser cette volumétrie. De plus, sa flexibilité à stocker des données provenant de n'importe quelle source constitue un atout majeur pour notre projet.
- **Le Data Warehouse :** Nous nous sommes tournés vers un entrepôt de données pour structurer notre architecture. Cela nous paraissait essentiel au vu de la finalité du projet : analyser ces données à des fins décisionnelles. L'objectif est de produire des rapports et des tableaux de bord pour aider les utilisateurs (soignants et direction) à prendre des décisions dans les meilleures conditions.
- **Hive :** Pour mettre en forme ces données dans le Data Warehouse, nous avons utilisé Hive. Il nous permet de poser une couche relationnelle sur les fichiers stockés dans HDFS, afin de pouvoir interroger facilement les données en SQL.
- **Power BI :** C'est le dernier outil de notre chaîne. Il permet de se connecter facilement aux tables structurées de Hive pour interroger les données et générer des rapports lisibles ainsi que des graphiques adaptés à l'aide à la décision.

Alternatives écartées

Chaque outil a été comparé à au moins une alternative :

- **Apache NiFi** est adapté à l'acheminement de flux en continu, mais il est moins riche pour les transformations complexes. **dbt** ne transforme que des données déjà chargées dans l'entrepôt et ne gère pas l'extraction. Talend couvre seul les trois étapes de l'ETL ;
- un SGBD relationnel comme **PostgreSQL** serait plus simple à administrer, mais il passe moins bien à l'échelle sur de gros volumes historiques. **BigQuery** supprimerait l'administration du cluster, mais il impose un hébergement cloud qui doit être certifié HDS et une facturation à la requête difficile à prévoir. Le couple HDFS et Hive peut être déployé chez un hébergeur certifié HDS et garde les données sous le contrôle du CHU ;
- **Metabase** et **Apache Superset** sont gratuits, mais ils offrent moins de visuels et une gestion des droits moins fine que Power BI, qui permet par exemple de limiter un utilisateur aux données de son établissement.

Brique	Outil retenu	Alternatives écartées	Raison principale du choix
ETL	Talend	Apache NiFi, dbt	Couvre l'extraction, la transformation et le chargement, avec des connecteurs natifs vers PostgreSQL, FTP, HDFS et Hive
Stockage	HDFS	PostgreSQL	Stockage distribué, extensible par ajout de nœuds, qui accepte tous les formats
Entrepôt	Hive	PostgreSQL, BigQuery	Requêtes SQL sur HDFS, partitionnement et format colonne ; déployable chez un hébergeur HDS
BI	Power BI	Metabase, Superset	Visuels riches, cartes, sécurité par ligne et prise en main rapide

EN RÉSUMÉ

L'architecture cible est un **entrepôt de données** bâti sur l'écosystème Hadoop :

- **Talend** collecte les quatre sources et enchaîne les traitements par lots, une fois par jour ;
- **HDFS** stocke les données en deux zones : la **zone de transit**, copie brute des sources, et l'**entrepôt**, qui contient la constellation dimensionnelle ;
- **Hive** expose l'entrepôt en SQL, avec des tables partitionnées au format colonne ;
- **Power BI** restitue les indicateurs aux praticiens et à la direction à partir des seules tables de l'entrepôt.

Les données identifiantes restent confinées dans la zone de transit, et l'ensemble peut être hébergé chez un prestataire certifié HDS. Les règles détaillées des jobs Talend sont spécifiées dans la partie suivante.

3 SPÉCIFICATIONS FONCTIONNELLES DES JOBS ETL

Les jobs ETL (*Extract, Transform, Load*) alimentent l'entrepôt : ils extraient les données des sources, les transforment pour respecter le modèle cible, puis les chargent dans l'entrepôt. Ce sont eux qui garantissent la qualité des données mises à disposition des utilisateurs.

Cette partie spécifie leur comportement attendu. Pour chaque source, elle précise les règles de transformation, le traitement des valeurs nulles et des doublons, la gestion des erreurs et des lignes rejetées, ainsi que la fréquence d'exécution.

Les jobs sont développés dans **Talend Open Studio for Big Data** (version 7.3). Chaque table de l'entrepôt est alimentée par un job dédié ; un job maître les enchaîne dans l'ordre imposé par les clés étrangères. La dimension DIM_Region_INSEE est alimentée par le Code officiel géographique de l'INSEE, qui sert aussi de table de correspondance pour les lieux de décès et de naissance.

3.1 SOURCES

Les sources ont été profilées avant la rédaction des règles : les volumes, taux de remplissage et taux de rapprochement cités dans cette partie proviennent de ce profilage. La base opérationnelle est lue directement dans PostgreSQL ; les fichiers sont d'abord copiés tels quels dans la zone de transit de HDFS (partie 2.1), puis lus depuis cette zone.

Job	Source	Format et lecture	Volume	Table alimentée
J01	Aucune (calendrier généré)	tRowGenerator	1 ligne par jour	DIM_Temps
J02	etablissement_sante.csv	CSV « ; », UTF-8, tFileInputDelimited	416 665 lignes	DIM_Etablissement
J03	Tables Professionnel_de_sante et Specialites (PostgreSQL), professionnel_sante.csv	tPostgresqlInput, tFileInputDelimited	1 048 575 professionnels	DIM_Professionnel
J04	Table Diagnostic (PostgreSQL)	tPostgresqlInput	15 492 codes	DIM_Diagnostic
J05	Table Patient (PostgreSQL)	tPostgresqlInput	100 000 patients	DIM_Patient
J06	Code officiel géographique de l'INSEE (communes_insee.csv)	CSV « , », UTF-8, tFileInputDelimited	39 521 codes	DIM_Region_INSEE
J07	Table Consultation (PostgreSQL), activite_professionnel_sante.csv	tPostgresqlInput, extraction incrémentale sur la date	1 027 157 consultations (2015 à 2023)	FAIT_CONSULTATION
J08	Hospitalisations.csv	CSV « ; », tFileInputDelimited	2 479 séjours (2015 à 2021)	FAIT_HOSPITALISATION
J09	Résultats e-Satis 48h MCO (serveur FTP)	CSV « ; » en Latin-1 jusqu'en 2019, Excel en 2020 ; tFTPGet puis tFileInputDelimited ou tFileInputExcel	Environ 1 150 établissements par an	FAIT_SATISFACTION
J10	deces.csv (serveur FTP)	CSV « , », UTF-8 ; tFTPGet puis tFileInputDelimited	25 088 208 lignes, 2 Go	FAIT_DECES

La base opérationnelle n'indique pas l'établissement où a lieu une consultation. Il est retrouvé à partir du professionnel : le fichier activite_professionnel_sante.csv associe chaque professionnel aux organisations où il exerce. Les enquêtes de satisfaction des années 2013 à 2016 portent sur d'autres indicateurs (tenue du dossier patient, délais d'envoi du courrier) et ne contiennent pas de score de satisfaction ; seuls les fichiers e-Satis, publiés à partir de 2017, sont chargés.

3.2 RÈGLES DE TRANSFORMATION

Les transformations sont réalisées dans des composants **tMap**. Quatre règles s'appliquent à tous les jobs :

- les textes sont convertis en UTF-8, débarrassés de leurs espaces en début et en fin de chaîne, et les codes (FINESS, INSEE, diagnostic) sont mis en majuscules ;
- les dates sont converties au type DATE, puis en clé de DIM_Temps au format AAAAMMJJ ;
- chaque clé métier est remplacée par la clé de substitution de sa dimension, lue dans un tMap en jointure de recherche (*lookup*) ;
- chaque rejet et chaque erreur sont datés et enregistrés avec le nom du job, pour la traçabilité.

Les règles propres à chaque job sont les suivantes.

Job	Règles de transformation
J01 DIM_Temps	Une ligne par jour du 1er janvier 1880 au 31 décembre 2030 : le plus ancien décès du fichier INSEE date de 1882. Jour, semaine ISO, mois, trimestre, semestre et année sont calculés à partir de la date.
J02 DIM_ Etablissement	La clé de rapprochement est identifiant_organisation, renseigné et unique sur toutes les lignes ; le numéro FINESS du site n'est renseigné que pour 200 lignes. Un identifiant qui commence par « F » est formé de la lettre F suivie du numéro FINESS : ce numéro sert à rattacher les enquêtes de satisfaction. Les colonnes de contact (téléphone, télécopie, courriel) ne sont pas chargées.
J03 DIM_Professionnel	Le code spécialité est remplacé par son libellé (table Specialites). La commune d'exercice est reprise de professionnel_sante.csv, en rapprochant les identifiants sans leurs zéros de tête (les 1 048 575 professionnels y sont retrouvés). Le nom est mis en majuscules.
J04 DIM_Diagnostic	Code et libellé repris tels quels, après nettoyage des espaces.
J05 DIM_Patient	Le patient reçoit un **pseudonyme** : une empreinte HMAC-SHA256 de son identifiant source, calculée avec une clé secrète conservée hors de l'entrepôt. La table de correspondance entre identifiant source et pseudonyme reste dans la zone de transit. Le sexe est recodé (female → F, male → M, autre → I). La date de naissance, stockée en texte au format M/J/AAAA, est convertie en date pour recalculer l'âge le jour du chargement ; elle n'est pas chargée dans l'entrepôt. Poids et taille, stockés en texte, sont convertis en nombres. Nom, prénom, adresse, courriel, téléphone et numéro de sécurité sociale ne sont pas chargés.
J06 DIM_Region_ INSEE	Une ligne par code commune : communes actuelles et anciennes, Corse (2A, 2B), départements et collectivités d'outre-mer, pays étrangers (codes 99xxx). Chaque commune porte son département et sa région ; le type de zone (Métropole, DROM, COM, Étranger) est calculé à partir du code. Le membre -1 « Inconnu » est fourni par le référentiel.
J07 FAIT_ CONSULTATION	Le patient, le professionnel et le diagnostic sont remplacés par leurs clés de substitution. L'établissement est déduit du professionnel : s'il exerce dans une seule organisation, celle-ci est retenue ; s'il en a plusieurs, l'organisation où il exerce en tant que salarié est retenue, puis la plus petite par ordre d'identifiant, pour que la règle donne toujours le même résultat. Nombre_de_consultation vaut 1. Le motif et les heures ne sont pas chargés.
J08 FAIT_ HOSPITALISATION	La date d'entrée (JJ/MM/AAAA) devient Id_Date_Entree. L'établissement est retrouvé par identifiant_organisation (100 % des séjours rapprochés), le diagnostic par son code (100 %). Num_Hospitalisation est conservé en dimension dégénérée ; Jour_ Hospitalisation est repris tel quel. Le libellé du diagnostic, déjà présent dans DIM_ Diagnostic, n'est pas chargé.
J09 FAIT_ SATISFACTION	Les fichiers de chaque année sont alignés sur un même schéma. Le numéro FINESS géographique, préfixé de « F », donne l'établissement (97 à 99 % des lignes rapprochées selon l'année). La période de mesure est le 1er janvier de l'année du recueil. « 1- Obligatoire » et « 1- Oui » deviennent VRAI. Score reprend la note ajustée de satisfaction globale et Nb_Reponses son nombre de réponses ; la virgule décimale est remplacée par un point.
J10 FAIT_DECES	Les dates incomplètes sont complétées au premier jour du mois ou de l'année (« 1989-05 » → 1989-05-01) et Flag_Date_Partielle passe à VRAI. L'âge au décès est calculé à partir des deux dates. Seule l'année de naissance est conservée. Les codes de lieu de décès et de naissance sont rapprochés de DIM_Region_INSEE. Nom et prénom servent au dédoublonnage dans la zone de transit et ne sont pas chargés.

3.3 VALEURS NULLES ET DOUBLONS

Une valeur absente n'est jamais laissée à NULL dans une clé étrangère : la ligne de faits est rattachée au membre « Inconnu » (clé -1) de la dimension, créé par le job de la dimension. La ligne reste ainsi comptée dans les totaux. Une mesure absente reste à NULL, car la remplacer par zéro fausserait les moyennes.

Job	Valeurs nulles	Doublons
J02 DIM_ Etablissement	Commune et code commune vides sur un tiers des lignes : laissés à NULL. Raison sociale toujours renseignée.	Aucun doublon sur identifiant_ organisation ; contrôle par tUniqRow à chaque chargement.
J03 DIM_Professionnel	Civilité (4 lignes) et prénom (18 lignes) vides : laissés à NULL.	Unicité sur l'identifiant ; un doublon garde la ligne la plus récente.
J04 DIM_Diagnostic	Aucune valeur vide. Membre -1 « Non renseigné » ajouté.	Unicité sur le code.
J05 DIM_Patient	Aucune valeur vide dans la source. Sexe inconnu $\rightarrow$ I ; date de naissance illisible $\rightarrow$ âge NULL.	Unicité sur l'identifiant source.
J06 DIM_Region_ INSEE	Département et région vides pour les pays étrangers et les collectivités d'outre-mer : laissés à NULL.	Unicité sur le code commune.
J07 FAIT_ CONSULTATION	Professionnel sans organisation connue (36 % des consultations) $\rightarrow$ établissement -1. Diagnostic absent $\rightarrow -1$.	Unicité sur Num_Consultation : une consultation déjà chargée est ignorée, ce qui rend le job rejouable.
J08 FAIT_ HOSPITALISATION	Aucune valeur vide. Durée absente $\rightarrow$ NULL.	Unicité sur Num_Hospitalisation.
J09 FAIT_ SATISFACTION	Score vide quand l'établissement a moins de 30 réponses, n'a pas répondu ou n'est pas validé (classes DI, NR, NV : 25 % des lignes en 2019) : la ligne est chargée avec Score et Nb_Reponses à NULL, et exclue des moyennes. FINESS inconnu $\rightarrow$ établissement -1.	Une ligne par établissement et par année ; un fichier rechargé remplace l'année entière.
J10 FAIT_DECES	Lieu de décès vide (10 934 lignes) $\rightarrow -1$. Numéro d'acte vide $\rightarrow$ NULL. Date de naissance absente $\rightarrow$ âge et année NULL.	161 112 doublons exacts (0,64 %) supprimés, puis un seul décès gardé par nom, prénom, date de naissance, date et lieu de décès.

3.4 ERREURS ET REJETS

Une ligne qui ne respecte pas une règle n'arrête pas le job : elle est écartée par la sortie de rejet du composant (tFilterRow, tSchemaComplianceCheck ou tMap) et écrite dans la **zone de rejets** de HDFS, dans un fichier par job et par date. Chaque rejet garde la ligne d'origine, le nom du job, la date et un code motif :

Code motif	Cas	Exemple
FORMAT	Valeur qui ne respecte pas le type attendu (date, nombre)	Date de décès « 2015 » illisible même après complétion
OBLIGATOIRE	Champ obligatoire vide	Consultation sans numéro ou sans date
INCOHERENT	Valeur hors des bornes métier	Naissance après le décès ou âge supérieur à 120 ans (78 lignes) ; heure de fin avant l'heure de début (10 consultations)
REFERENCE	Clé métier absente de sa dimension alors qu'elle est obligatoire	Patient d'une consultation absent de DIM_Patient

Les rejets sont analysés par l'équipe d'ingénierie, corrigés dans la source quand c'est possible, puis rechargés au passage suivant. Les erreurs techniques (base PostgreSQL ou serveur FTP inaccessible, fichier absent, HDFS plein) sont traitées autrement :

- un composant **tLogCatcher** intercepte l'erreur et l'enregistre dans une table de journal, avec le job, l'heure et le message ;
- le job s'arrête sans rien écrire dans l'entrepôt : les données y sont chargées dans une table temporaire, qui ne remplace la table finale qu'en fin de job ;
- un courriel est envoyé à l'équipe (**tSendMail**) ;
- si plus de 5 % des lignes d'un fichier sont rejetées, le job est aussi arrêté (**tDie**) : un tel taux signale plutôt un changement de format de la source qu'une erreur de saisie.

Les composants **tStatCatcher** et **tFlowMeterCatcher** enregistrent pour chaque exécution la durée, le nombre de lignes lues, chargées et rejetées. Ces chiffres servent au contrôle de complétude du livrable 2.

3.5 FRÉQUENCE D'EXÉCUTION

Les jobs sont regroupés dans un **job maître** (composants tRunJob) qui les lance dans l'ordre suivant : d'abord les dimensions, ensuite les faits, qui ont besoin des clés de substitution. Un job ne démarre que si le précédent a réussi. Le job maître est exporté depuis Talend en script autonome et planifié chaque nuit à 2 h, en dehors des heures d'activité de la base de soins.

Job	Fréquence	Mode de chargement
J01 DIM_Temps	Une seule fois	Complet, prolongé si les données dépassent 2030
J02 à J06 (dimensions)	Quotidienne	Complet pour les référentiels CSV ; les lignes nouvelles ou modifiées sont ajoutées, les clés de substitution existantes ne changent pas
J07 FAIT_CONSULTATION	Quotidienne	Incrémental : consultations dont la date est postérieure au dernier chargement
J08 FAIT_ HOSPITALISATION	Quotidienne	Incrémental sur Num_Hospitalisation
J09 FAIT_SATISFACTION	Annuelle, à la publication des résultats e-Satis	Remplacement de l'année concernée
J10 FAIT_DECES	Mensuelle, à la publication du fichier INSEE	Premier chargement complet, puis ajout des nouveaux décès ; partition par année

Les jobs quotidiens ne relisent que les données nouvelles et durent quelques minutes. Le chargement initial des 25 millions de décès est le plus long : il est lancé une seule fois, avant la mise en service.

EN RÉSUMÉ

L'alimentation de l'entrepôt repose sur dix jobs Talend, lancés par un job maître :

- chaque job lit une source, PostgreSQL ou un fichier de la zone de transit, et alimente une seule table ;
- les règles de transformation convertissent les types, remplacent les clés métier par des clés de substitution et pseudonymisent les patients ;
- une valeur absente est rattachée au membre « Inconnu » dans les clés et laissée à NULL dans les mesures ; les doublons sont éliminés sur la clé métier, ce qui permet de rejouer un job sans risque ;
- les lignes invalides partent dans la zone de rejets avec un code motif, et une erreur technique arrête le job sans altérer l'entrepôt ;
- les dimensions et les faits de la base de soins sont chargés chaque nuit, la satisfaction chaque année et les décès chaque mois.

4 PLAN DE GOUVERNANCE DES DONNÉES

Les données du CHU sont des **données de santé**, classées parmi les données sensibles par le RGPD. Leur traitement est encadré par le RGPD, par les recommandations de la CNIL et par l'obligation de les confier à un hébergeur certifié **HDS** (Hébergeur de Données de Santé).

Le plan de gouvernance définit les règles qui assurent cette conformité tout au long du cycle de vie des données. Il précise les mesures d'anonymisation et de pseudonymisation, les exigences d'hébergement, les rôles et les droits d'accès de chaque utilisateur, et la traçabilité des flux, du chargement de la source jusqu'au tableau de bord.

4.1 CONFORMITÉ RGPD

4.2 CONFORMITÉ HDS

4.3 RÔLES ET DROITS D'ACCÈS

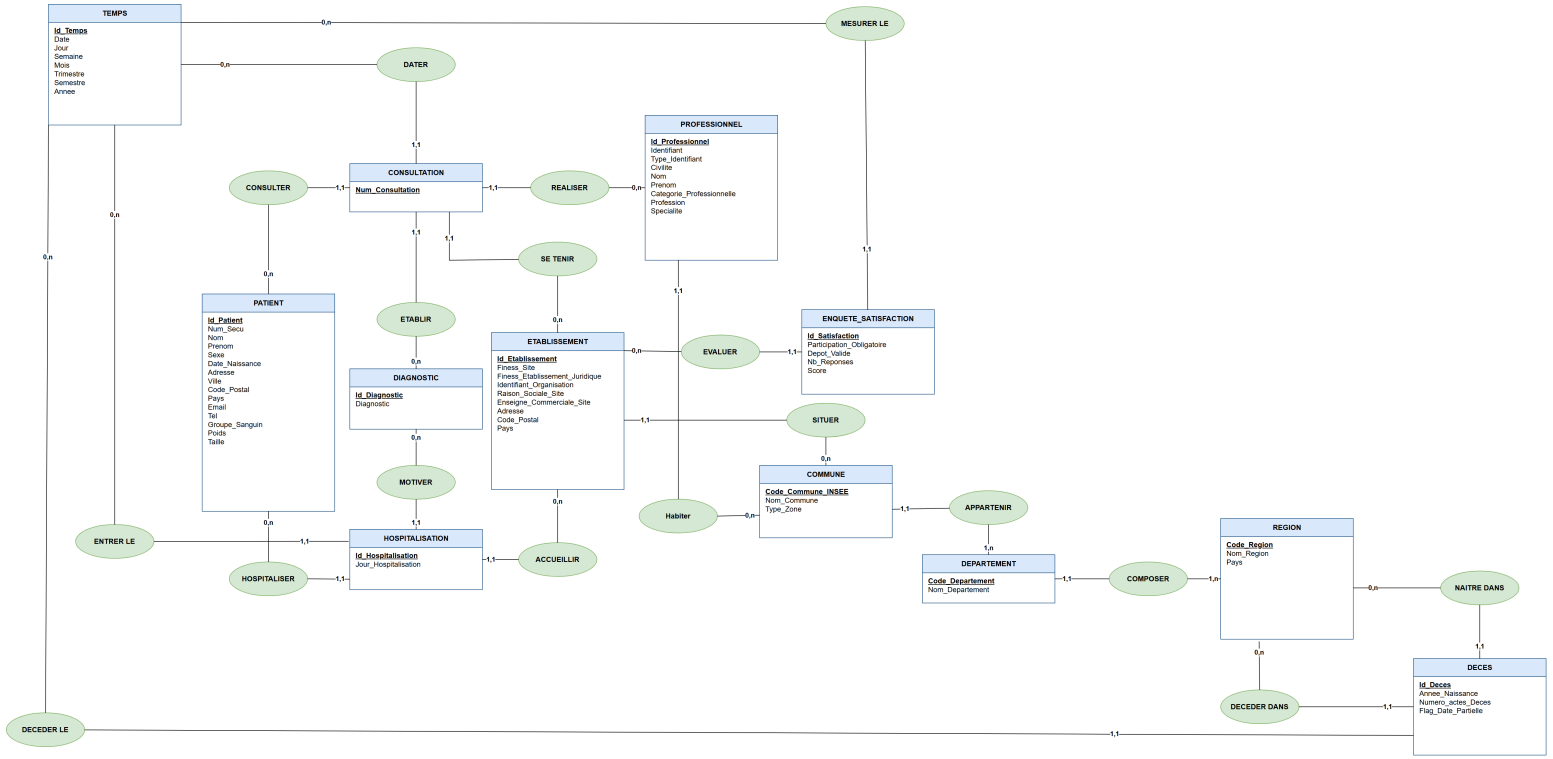
4.4 TRAÇABILITÉ DES FLUX

CONCLUSION

ANNEXES

ANNEXE A – MODÈLE DIMENSIONNEL CONCEPTUEL

Tables de faits et dimensions du CHU et leurs relations. Ce modèle est décrit en partie 1.1.



ANNEXE B – SCHÉMA LOGIQUE EN CONSTELLATION

Constellation des quatre tables de faits et des six dimensions, avec leurs clés primaires (PK), étrangères (FK) et métier (BK). Ce schéma est décrit en partie 1.2.

