CESI
ÉCOLE D'INGÉNIEURS

Projet CHU – Entrepôt de données



Livrable 1 | Référentiel et architecture

Vendredi 23 octobre 2026

A. Tellez
M. Mazou
M. Sepulveda
N. Durtelle de Saint Sauveur

Fisa Info 25–28
CESI

TABLE DES MATIÈRES

Introduction **2**

1 Architecture cible **3**
1.1 Technologies retenues et justification 4

2 Modèle conceptuel et logique **6**
2.1 Modèle dimensionnel conceptuel 6
2.2 Modèle dimensionnel logique 8
2.3 Dictionnaire de données 13

3 Spécifications fonctionnelles des jobs ETL **18**
3.1 Vue d'ensemble 18
3.2 Règles communes à tous les jobs 19
3.3 Les jobs un par un 20

4 Plan de gouvernance des données **28**
4.1 Conformité RGPD : Protection et traitement des données de santé . . . 28
4.2 Conformité HDS (Hébergement de Données de Santé) 29
4.3 Gestion des rôles et des droits d'accès (RBAC - Role-Based Access Control) 29
4.4 Traçabilité des flux (Audit et journalisation) 30

Conclusion **31**

Glossaire **32**

Sitographie **33**

Annexes **34**
Annexe A – Modèle dimensionnel conceptuel 34
Annexe B – Schéma logique en constellation 35

INTRODUCTION

Un groupe hospitalier universitaire (CHU) souhaite se doter d'un **entrepôt de données décisionnel**. Ses données sont aujourd'hui dispersées entre une base opérationnelle, des fichiers de référence et des fichiers déposés sur un serveur FTP. Elles ne permettent pas de suivre l'activité des établissements dans le temps ni de les comparer entre eux.

L'entrepôt doit servir deux publics : les **praticiens** (médecins, infirmiers), qui suivent l'activité de soins, et la **direction** des établissements, qui pilote l'offre et la qualité. Il doit permettre de calculer huit indicateurs, dont six obligatoires : les taux de consultation, d'hospitalisation, de décès et de satisfaction, croisés par établissement, période, diagnostic, professionnel, sexe, âge ou région.

Quatre sources alimentent l'entrepôt :

- la **base opérationnelle** PostgreSQL (patients, consultations, diagnostics, professionnels), complétée par un fichier des hospitalisations ;
- le **référentiel des établissements** et des professionnels de santé, au format CSV ;
- les **enquêtes de satisfaction** des patients, déposées sur le serveur FTP ;
- le **fichier des décès** publié par l'INSEE, déposé sur le serveur FTP.

Ces données concernent la santé de personnes identifiables. Leur traitement doit respecter le RGPD, les recommandations de la CNIL et l'obligation d'hébergement certifié HDS. La solution doit aussi rester élastique face à la hausse des volumes et justifier chaque outil par son rapport coût-efficacité.

Ce premier livrable pose le **référentiel de données** et l'**architecture** de la solution. Il présente l'architecture cible de l'entrepôt avec les technologies retenues, le modèle conceptuel et logique du schéma décisionnel avec son dictionnaire de données, les spécifications fonctionnelles des jobs ETL et le plan de gouvernance des données.

1 ARCHITECTURE CIBLE

L'architecture doit répondre à trois exigences : intégrer des sources hétérogènes, protéger des données de santé et suivre la hausse des volumes. Elle repose sur un **entrepôt de données** (*Data Warehouse*) : une base unique, historisée et structurée selon le modèle dimensionnel de la partie 2, conçue pour l'analyse et non pour la gestion quotidienne des soins.

Les données passent par une **zone de transit**, où elles sont déposées telles qu'elles arrivent des sources, avant d'être nettoyées et chargées dans l'entrepôt. Cette partie présente l'architecture retenue, puis les technologies choisies et les raisons de ces choix.

La figure 1 présente l'architecture retenue.

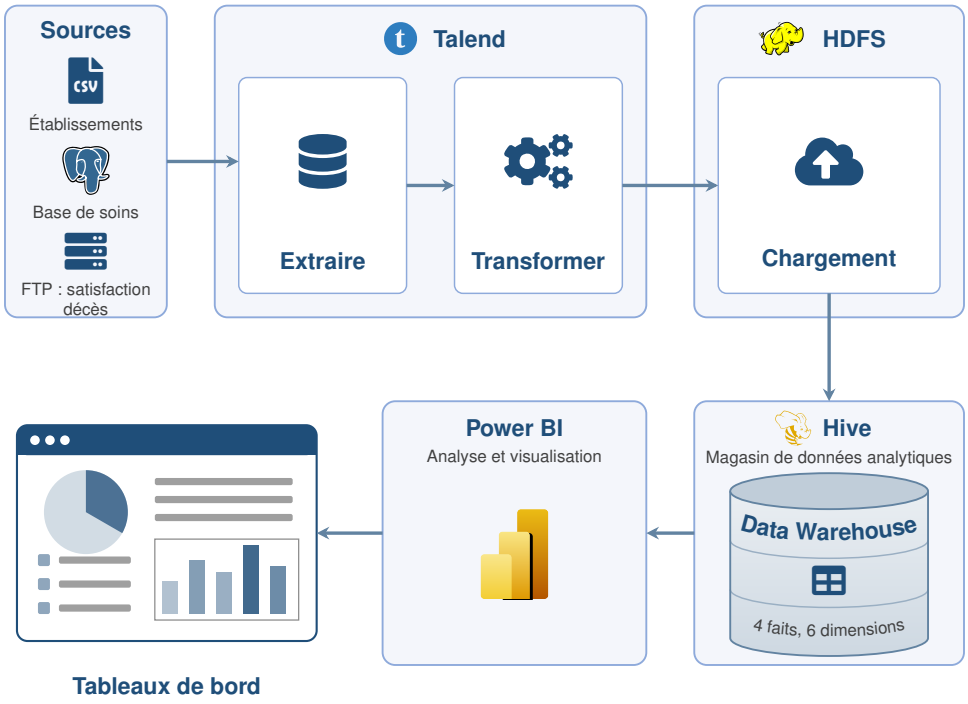


Figure 1 – Architecture cible de l'entrepôt du CHU

L'architecture choisie se décompose en quatre parties clés, chacune essentielle pour le traitement et le stockage des données :

— **La source des données :** elle regroupe l'ensemble des informations collectées. Ces données peuvent provenir de différentes sources et formats, comme des fichiers Excel, CSV, ou encore de bases de données relationnelles (MySQL, PostgreSQL, etc.).

— **L'extraction, la transformation et le chargement (ETL) :** cette étape est réalisée à l'aide de l'outil Talend et permet de préparer les données pour l'analyse. Les données sont nettoyées, standardisées et intégrées dans l'environnement HDFS.

— **Le magasin de données analytiques :** les données sont stockées dans un environnement dit distribué, permettant de répartir la charge sur plusieurs machines plutôt que sur une seule. Une fois stockées, les données sont structurées pour alimenter le Data Warehouse et peuvent être interrogées à l'aide de Hive.

— **Analyse et visualisation :** il est ensuite possible d'exploiter ces données à l'aide de Power BI pour concevoir des tableaux de bord (*dashboards*) permettant de mettre en lumière des tendances (*insights*) ou même des alertes en cas de traitement en continu. Cette brique offre à l'utilisateur une vision claire des informations importantes grâce à des tableaux, des courbes ou des graphiques sur les données traitées.

1.1 TECHNOLOGIES RETENUES ET JUSTIFICATION

Pourquoi avoir choisi ces outils ?

- **Talend :** Il a été choisi pour son rôle de chef d'orchestre des flux de données. Notre architecture repose sur un processus ETL (Extraire, Transformer, Charger), que Talend permet de mettre en œuvre facilement. Pour des données de santé, certaines étapes sont indispensables. Talend permet de se connecter à n'importe quel type de source sans avoir à coder des scripts manuels. Il gère également le nettoyage indispensable des données de santé (dates, lieux, motifs de consultation, etc.) tout en automatisant le chargement de ces données vers l'environnement Big Data.
- **HDFS (Hadoop Distributed File System) :** Le volume important des données nous a poussés à utiliser HDFS pour encaisser cette volumétrie. De plus, sa flexibilité à stocker des données provenant de n'importe quelle source constitue un atout majeur pour notre projet.
- **Le Data Warehouse :** Nous nous sommes tournés vers un entrepôt de données pour structurer notre architecture. Cela nous paraissait essentiel au vu de la finalité du projet : analyser ces données à des fins décisionnelles. L'objectif est de produire des rapports et des tableaux de bord pour aider les utilisateurs (soignants et direction) à prendre des décisions dans les meilleures conditions.
- **Hive :** Pour mettre en forme ces données dans le Data Warehouse, nous avons utilisé Hive. Il nous permet de poser une couche relationnelle sur les fichiers stockés dans HDFS, afin de pouvoir interroger facilement les données en SQL.
- **Power BI :** C'est le dernier outil de notre chaîne. Il permet de se connecter facilement aux tables structurées de Hive pour interroger les données et générer des rapports lisibles ainsi que des graphiques adaptés à l'aide à la décision.

Alternatives écartées

Chaque outil a été comparé à au moins une alternative :

- **Apache NiFi** est adapté à l'acheminement de flux en continu, mais il est moins riche pour les transformations complexes. **dbt** ne transforme que des données déjà chargées dans l'entrepôt et ne gère pas l'extraction. Talend couvre seul les trois étapes de l'ETL ;
- un SGBD relationnel comme **PostgreSQL** serait plus simple à administrer, mais il passe moins bien à l'échelle sur de gros volumes historiques. **BigQuery** supprimerait l'administration du cluster, mais il impose un hébergement cloud qui doit être certifié HDS et une facturation à la requête difficile à prévoir. Le couple HDFS et Hive peut être déployé chez un hébergeur certifié HDS et garde les données sous le contrôle du CHU ;
- **Metabase** et **Apache Superset** sont gratuits, mais ils offrent moins de visuels et une gestion des droits moins fine que Power BI, qui permet par exemple de limiter un utilisateur aux données de son établissement.

Brique	Outil retenu	Alternatives écartées	Raison principale du choix
ETL	Talend	Apache NiFi, dbt	Couvre l'extraction, la transformation et le chargement, avec des connecteurs natifs vers PostgreSQL, FTP, HDFS et Hive
Stockage	HDFS	PostgreSQL	Stockage distribué, extensible par ajout de nœuds, qui accepte tous les formats
Entrepôt	Hive	PostgreSQL, BigQuery	Requêtes SQL sur HDFS, partitionnement et format colonne ; déployable chez un hébergeur HDS
BI	Power BI	Metabase, Superset	Visuels riches, cartes, sécurité par ligne et prise en main rapide

EN RÉSUMÉ

L'architecture cible est un **entrepôt de données** bâti sur l'écosystème Hadoop :

- **Talend** collecte les quatre sources et enchaîne les traitements par lots, une fois par jour ;
- **HDFS** stocke les données en deux zones : la **zone de transit**, copie brute des sources, et l'**entrepôt**, qui contient la constellation dimensionnelle ;
- **Hive** expose l'entrepôt en SQL, avec des tables partitionnées au format colonne ;
- **Power BI** restitue les indicateurs aux praticiens et à la direction à partir des seules tables de l'entrepôt.

Les données identifiantes restent confinées dans la zone de transit, et l'ensemble peut être hébergé chez un prestataire certifié HDS. Le modèle des données stockées dans l'entrepôt est présenté dans la partie suivante ; les règles des jobs Talend sont spécifiées en partie 3.

2 MODÈLE CONCEPTUEL ET LOGIQUE

Le modèle décisionnel est le socle de l'entrepôt : il fixe ce que l'on mesure et selon quels axes. Il suit l'approche de **Kimball**, qui organise les données en **tables de faits**, contenant les mesures, et en **tables de dimensions**, contenant les axes d'analyse. Chaque fait correspond à un processus métier du CHU : une consultation, une hospitalisation, une réponse à une enquête de satisfaction ou un décès.

Plusieurs faits partagent les mêmes dimensions, comme le temps ou l'établissement. Le modèle forme donc une **constellation** de schémas en étoile, reliés par des dimensions communes, dites **conformes**. Cette partie présente d'abord le modèle dimensionnel conceptuel, puis sa traduction en schéma en constellation, qui constitue le modèle logique, et enfin le dictionnaire de données qui décrit chaque table et chaque attribut.

2.1 MODÈLE DIMENSIONNEL CONCEPTUEL

Le modèle dimensionnel conceptuel suit la démarche de Kimball : choisir les processus métier à analyser, fixer leur grain, puis identifier les dimensions qui les décrivent et les faits qu'ils mesurent. Il est indépendant de toute technologie et a été construit à partir de l'analyse des quatre sources. Quatre processus métier donnent les tables de faits : Consultations, Hospitalisations, Satisfaction et Décès. Six dimensions servent d'axes d'analyse : Temps, Établissement, Patient, Diagnostic, Professionnel et Région INSEE, cette dernière détaillée en Commune, Département et Région.

La figure 2 présente le modèle dimensionnel conceptuel. Une version agrandie, en format paysage, est donnée en Annexe A (page 34).

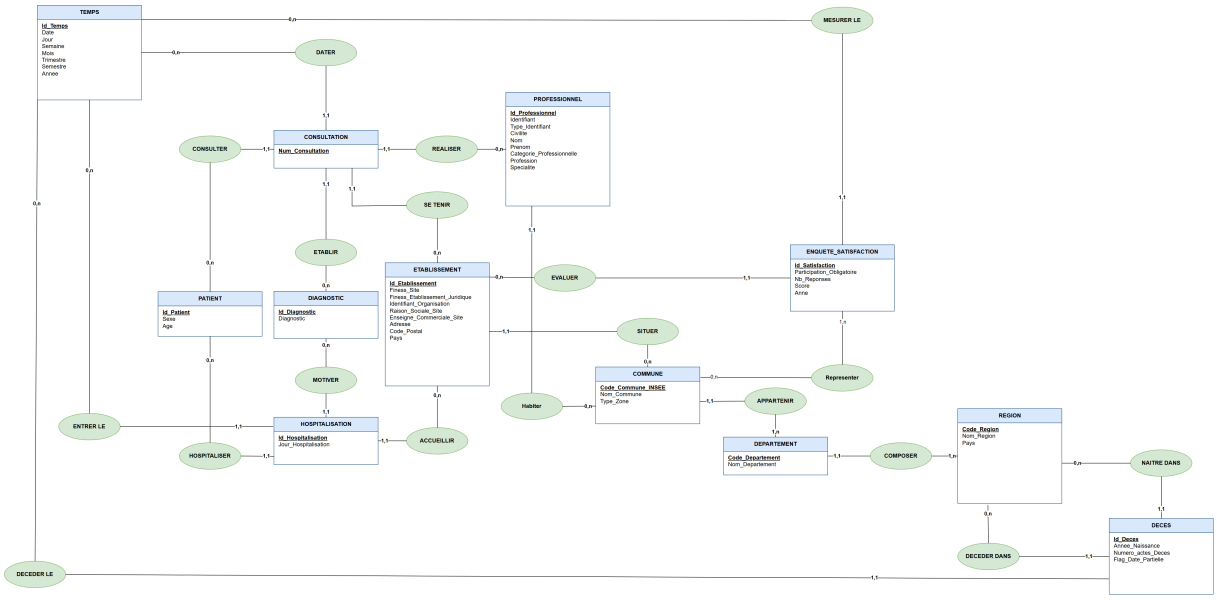


Figure 2 – Modèle dimensionnel conceptuel du CHU (agrandi en Annexe A)

Lire le modèle conceptuel

Le schéma se lit en trois éléments :

- les **rectangles** représentent les processus métier (Consultation, Hospitalisation, Enquête de satisfaction, Décès) et les dimensions qui les décrivent (Temps, Patient, Professionnel, Diagnostic, Établissement, Commune, Département, Région) ; l'identifiant de chacun est souligné ;
- les **ellipses vertes** nomment la relation entre deux rectangles, par un verbe : une consultation est « réalisée » par un professionnel, un séjour « accueilli » par un établissement ;
- les **cardinalités** indiquent combien de fois un élément participe à la relation. Elles se lisent depuis le rectangle le plus proche : « une consultation est réalisée par un et un seul professionnel (1,1) ; un professionnel réalise zéro, une ou plusieurs consultations (0,n) ».

Processus métier et dimensions

Élément du schéma	Rôle	Table du modèle logique
Consultation	Processus métier (table de faits)	FAIT_CONSULTATION
Hospitalisation	Processus métier (table de faits)	FAIT_HOSPITALISATION
Enquête de satisfaction	Processus métier (table de faits)	FAIT_SATISFACTION
Décès	Processus métier (table de faits)	FAIT_DECES
Temps	Dimension conforme (Jour → Mois → Trimestre → Année)	DIM_Temps
Établissement	Dimension conforme	DIM_Etablissement
Patient	Dimension	DIM_Patient
Diagnostic	Dimension	DIM_Diagnostic
Professionnel	Dimension	DIM_Professionnel
Commune, Département, Région	Dimension conforme, sous forme de hiérarchie (Commune → Département → Région)	DIM_Region_INSEE

Relations entre processus métier et dimensions

Le tableau reprend chaque relation du schéma avec son nom et ses cardinalités. Côté processus métier, la cardinalité est (1,1) pour presque toutes les relations : chaque consultation, chaque séjour, chaque résultat d'enquête et chaque décès est rattaché à une seule valeur de chaque dimension. Seule la relation REPRÉSENTER est en (1,n) : une enquête de satisfaction représente au moins une commune, celle de l'établissement évalué. Ces relations deviennent les clés étrangères des tables de faits.

Relation	Processus métier	Card.	Dimension	Card.
CONSULTER	Consultation	1,1	Patient	0,n
RÉALISER	Consultation	1,1	Professionnel	0,n
ÉTABLIR	Consultation	1,1	Diagnostic	0,n
SE TENIR	Consultation	1,1	Établissement	0,n
DATER	Consultation	1,1	Temps	0,n
HOSPITALISER	Hospitalisation	1,1	Patient	0,n
MOTIVER	Hospitalisation	1,1	Diagnostic	0,n
ACCUEILLIR	Hospitalisation	1,1	Établissement	0,n
ENTRER LE	Hospitalisation	1,1	Temps	0,n
ÉVALUER	Enquête de satisfaction	1,1	Établissement	0,n
MESURER LE	Enquête de satisfaction	1,1	Temps (année)	0,n
REPRÉSENTER	Enquête de satisfaction	1,n	Commune	0,n
DÉCÉDER LE	Décès	1,1	Temps	0,n
DÉCÉDER DANS	Décès	1,1	Région INSEE (lieu de décès)	0,n
NAÎTRE DANS	Décès	1,1	Région INSEE (lieu de naissance)	0,n

La dimension géographique joue deux rôles pour le même décès : le lieu de décès et le lieu de naissance. Elle est aussi utilisée par l'enquête de satisfaction, pour situer l'établissement évalué dans sa région.

Hiérarchies

Le schéma détaille la géographie en trois niveaux : une commune **appartient** à un département, un département **compose** une région. L'établissement est **situé** dans une commune, et le professionnel **habite** une commune. La dimension Temps porte de même la hiérarchie Jour $\rightarrow$ Mois $\rightarrow$ Trimestre $\rightarrow$ Année.

Au passage au modèle logique, ces hiérarchies sont **aplaties** : Commune, Département et Région forment une seule table, DIM_Region_INSEE, dont chaque ligne est une commune accompagnée de son département et de sa région. Ce choix évite un schéma en flocon : une requête par région ne demande qu'une seule jointure, au prix d'une légère répétition des noms de département et de région. Pour l'établissement et le professionnel, la commune reste un simple attribut de leur dimension.

2.2 MODÈLE DIMENSIONNEL LOGIQUE

Le schéma en constellation constitue le **modèle logique** de l'entrepôt : il traduit le modèle conceptuel (partie 2.1) en tables relationnelles, avec leurs attributs et leurs clés, sans dépendre du moteur de stockage. Il compte **quatre tables de faits** et **six dimensions** ; chaque table de faits forme une étoile avec ses dimensions, et les étoiles se rejoignent sur les trois dimensions conformes : DIM_Temps, DIM_Etablissement et DIM_Region_INSEE.

Granularité des faits

La granularité (le « grain ») définit ce que représente une ligne de la table de faits. Elle est fixée au niveau le plus fin disponible dans les sources, afin de pouvoir agréger ensuite sans perte d'information.

Table de faits	Grain (1 ligne =)	Mesures
FAIT_CONSULTATION	1 consultation d'un patient par un professionnel, dans un établissement, à une date	Nombre_de_consultation
FAIT_ HOSPITALISATION	1 séjour hospitalier d'un patient dans un établissement	Jour_Hospitalisation (durée)
FAIT_SATISFACTION	1 résultat d'enquête pour un établissement et une année	NbReponses, Score
FAIT_DECES	1 décès du fichier INSEE	Age_Deces (et comptage des lignes)

Matrice faits × dimensions

La matrice ci-dessous (dite « matrice en bus » chez Kimball) indique quelles dimensions chaque fait utilise. Une dimension présente dans plusieurs colonnes est une dimension conforme : elle a la même structure et les mêmes clés pour tous les faits, ce qui permet de croiser les indicateurs.

Dimension	Consultation	Hospitalisation	Satisfaction	Décès
DIM_Temps	X	X (date d'entrée)		X (date de décès)
DIM_Etablissement	X	X	X	
DIM_Patient	X	X		
DIM_Diagnostic	X	X		
DIM_Professionnel	X			
DIM_Region_INSEE			X (région de l'établissement)	X (décès + naissance)

La figure 3 réunit ces éléments en une vue d'ensemble de la constellation : les quatre faits, les six dimensions et leurs clés. Une version agrandie, en format paysage, est donnée en Annexe B (page 35).

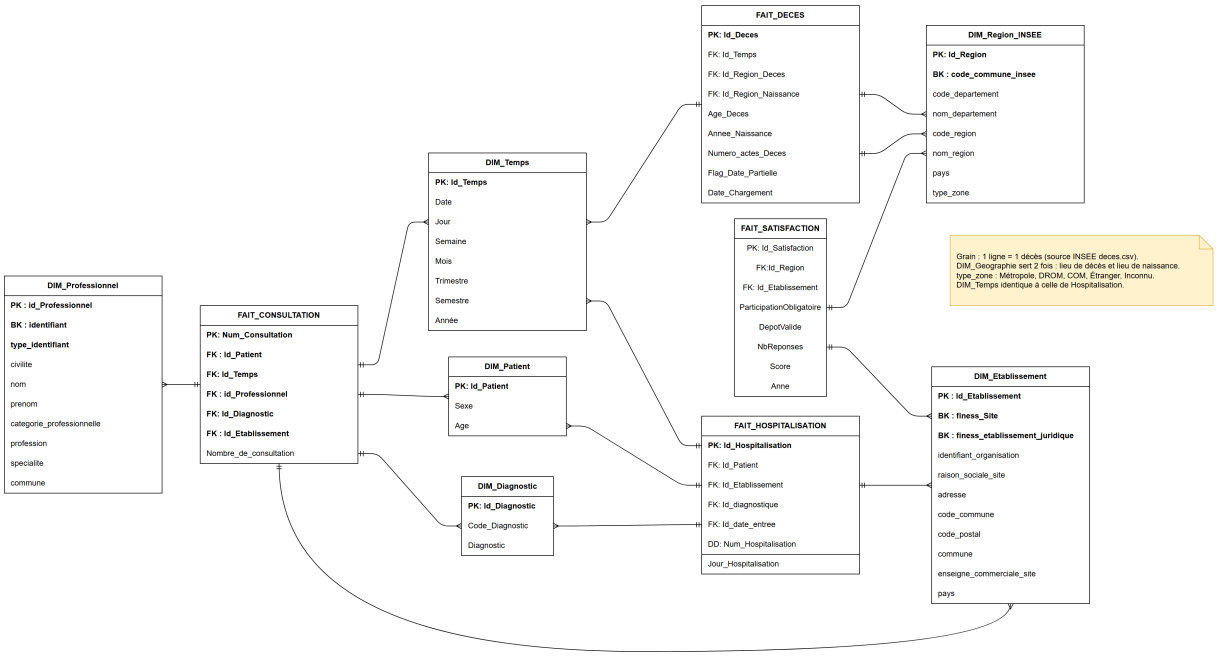


Figure 3 – Schéma logique en constellation du CHU (agrandi en Annexe B)

Chaque rectangle est une table. Ses colonnes sont annotées : **PK** pour la clé primaire, **FK** pour une clé étrangère vers une dimension, **BK** pour la clé métier venue de la source et **DD** pour une dimension dégénérée. Les traits relient une clé étrangère à la dimension qu'elle désigne : le côté à deux barres signifie « exactement un », le côté en patte d'oie « plusieurs ». Un même patient peut ainsi apparaître dans plusieurs consultations, mais chaque consultation désigne un seul patient.

Couverture des besoins

Chaque besoin exprimé par le CHU se calcule à partir d'une seule table de faits et de ses dimensions, sans jointure entre faits.

N°	Besoin	Fait	Dimensions utilisées
1	Taux de consultation par établissement et par période	FAIT_CONSULTATION	DIM_Etablissement, DIM_Temps
2	Taux de consultation par diagnostic et par période	FAIT_CONSULTATION	DIM_Diagnostic, DIM_Temps
3	Taux global d'hospitalisation par période	FAIT_HOSPITALISATION	DIM_Temps
4	Taux d'hospitalisation par diagnostic et par période	FAIT_HOSPITALISATION	DIM_Diagnostic, DIM_Temps
5	Taux d'hospitalisation par sexe et par âge	FAIT_HOSPITALISATION	DIM_Patient
6	Taux de consultation par professionnel	FAIT_CONSULTATION	DIM_Professionnel
7	Nombre de décès par région en 2019 (optionnel)	FAIT_DECES	DIM_Region_INSEE (rôle décès), DIM_Temps
8	Taux global de satisfaction par région en 2020 (optionnel)	FAIT_SATISFACTION	DIM_Region_INSEE, attribut Annee du fait

Règles de passage

Quatre règles ont permis de passer du modèle conceptuel (figure 2) au schéma en constellation (figure 3) :

1. chaque processus métier devient une table de faits ; ses relations vers les dimensions deviennent des **clés étrangères** ;
2. chaque dimension devient une table identifiée par une **clé de substitution** (entier sans signification métier), la clé de la source étant conservée comme **clé métier** ; seule DIM_Patient garde directement l'identifiant interne de la base de soins, pour ne pas stocker de table de correspondance (BK) ;
3. les hiérarchies (commune, département, région ; jour, mois, trimestre, année) sont **aplaties** dans leur dimension ;
4. deux relations sont traduites autrement qu'en clé étrangère classique : « MESURER LE » devient une simple colonne Annee de FAIT_SATISFACTION, car l'enquête est annuelle alors que DIM_Temps est au jour ; « REPRÉSENTER » devient la clé Id_Region, qui désigne la commune de l'établissement dans DIM_Region_INSEE et donne donc accès à son département et à sa région.

Notation : **PK** désigne une clé primaire, **FK** une clé étrangère, **BK** une clé métier et **DD** une dimension dégénérée (identifiant de la source conservé dans le fait sans table de dimension).

Schéma relationnel

Le schéma relationnel reprend la figure 3 sous forme textuelle. La clé primaire est soulignée et les clés étrangères sont précédées d'un #.

FAIT_CONSULTATION (Num_Consultation, #Id_Patient, #Id_Temps, #Id_Professionnel, #Id_Diagnostic, #Id_Etablissement, Nombre_de_consultation)

FAIT_HOSPITALISATION (Id_Hospitalisation, #Id_Patient, #Id_Etablissement, #Id_Diagnostique, #Id_Date_Entree, Num_Hospitalisation, Jour_Hospitalisation)

FAIT_SATISFACTION (Id_Satisfaction, #Id_Etablissement, #Id_Region, ParticipationObligatoire, DepotValide, NbReponses, Score, Annee)

FAIT_DECES (Id_Deces, #Id_Temps, #Id_Region_Deces, #Id_Region_Naissance, Age_Deces, Annee_Naissance, Numero_Actes_Deces, Flag_Date_Partielle, Date_Chargement)

DIM_Temps (Id_Temps, Date, Jour, Semaine, Mois, Trimestre, Semestre, Annee)

DIM_Patient (Id_Patient, Sexe, Age)

DIM_Diagnostic (Id_Diagnostic, Code_Diagnostic, Diagnostic)

DIM_Etablissement (Id_Etablissement, Finess_Site, Finess_Etablissement_Juridique, Identifiant_Organisation, Raison_Sociale_Site, Enseigne_Commerciale_Site, Adresse, Code_Commune, Code_Postal, Commune, Pays)

DIM_Professionnel (Id_Professionnel, Identifiant, Type_Identifiant, Civilite, Nom, Prenom, Categorie_Professionnelle, Profession, Specialite, Commune)

DIM_Region_INSEE (Id_Region, Code_Commune_INSEE, Code_Departement, Nom_Departement, Code_Region, Nom_Region, Pays, Type_Zone)

Clés étrangères et cardinalités

Toutes les relations du schéma sont de type **un-à-plusieurs** : une ligne de dimension est référencée par zéro, une ou plusieurs lignes de faits, et chaque ligne de faits référence exactement une ligne de dimension. Les clés étrangères des faits sont donc **non nulles** ; une valeur absente dans la source est rattachée à un membre « Inconnu » (clé -1) de la dimension plutôt que laissée à NULL, pour ne perdre aucune ligne dans les agrégats.

Table de faits	Clé étrangère	Dimension référencée	Côté dimension	Côté fait
FAIT_CONSULTATION	Id_Patient	DIM_Patient	1	0..n
FAIT_CONSULTATION	Id_Temps	DIM_Temps	1	0..n
FAIT_CONSULTATION	Id_Professionnel	DIM_Professionnel	1	0..n
FAIT_CONSULTATION	Id_Diagnostic	DIM_Diagnostic	1	0..n
FAIT_CONSULTATION	Id_Etablissement	DIM_Etablissement	1	0..n
FAIT_HOSPITALISATION	Id_Patient	DIM_Patient	1	0..n
FAIT_HOSPITALISATION	Id_Etablissement	DIM_Etablissement	1	0..n
FAIT_HOSPITALISATION	Id_Diagnostique	DIM_Diagnostic	1	0..n
FAIT_HOSPITALISATION	Id_Date_Entree	DIM_Temps	1	0..n
FAIT_SATISFACTION	Id_Etablissement	DIM_Etablissement	1	0..n
FAIT_SATISFACTION	Id_Region	DIM_Region_INSEE	1	0..n
FAIT_DECES	Id_Temps	DIM_Temps	1	0..n
FAIT_DECES	Id_Region_Deces	DIM_Region_INSEE	1	0..n
FAIT_DECES	Id_Region_Naissance	DIM_Region_INSEE	1	0..n

Choix de modélisation

- **Clés de substitution** : les dimensions sont identifiées par un entier généré par l'ETL. Elles isolent l'entrepôt des changements de codification des sources et accélèrent les jointures.
- **Dimensions conformes** : DIM_Temps, DIM_Etablissement et DIM_Region_INSEE sont uniques et partagées, ce qui garantit que « mars 2019 », « tel établissement » ou « telle région » ont le même sens pour tous les indicateurs.
- **Dimension à rôles multiples** : DIM_Region_INSEE est jouée deux fois par FAIT_DECES (lieu de décès et lieu de naissance), via deux clés étrangères distinctes, et une fois par FAIT_SATISFACTION (région de l'établissement).
- **Année de l'enquête** : les résultats de satisfaction sont publiés une fois par an ; FAIT_SATISFACTION porte donc une simple colonne Annee plutôt qu'une clé vers DIM_Temps, dont le grain est le jour.
- **Dimensions dégénérées** : Num_Hospitalisation et Numero_Actes_Deces restent dans les faits pour le dédoublonnage et la traçabilité vers la source.
- **Mesures** : les mesures additives (Nombre_de_consultation, Jour_Hospitalisation, NbReponses) se somment sur tous les axes ; Score est non additif et s'agrège en moyenne pondérée par NbReponses.

2.3 DICTIONNAIRE DE DONNÉES

Le dictionnaire décrit chaque table et chaque attribut du modèle. Les types sont exprimés en SQL standard (compatibles PostgreSQL) ; ils seront ajustés au moteur retenu lors de l'implémentation physique (livrable 2).

Légende de la colonne « Clé » : **PK** clé primaire, **FK** clé étrangère, **BK** clé métier (identifiant de la source, unique dans la dimension), **DD** dimension dégénérée.

FAIT_CONSULTATION

Type : Table de faits. **Grain** : 1 ligne = 1 consultation réalisée par un professionnel pour un patient, dans un établissement, à une date.
Source : base opérationnelle PostgreSQL (consultations) ; l'établissement est retrouvé à partir du professionnel, grâce au fichier activite_professionnel_sante.csv.
Besoins couverts : 1, 2 et 6.

Attribut	Type	Clé	Null	Description
Num_Consultation	INT	PK	Non	Identifiant de la consultation (numéro issu de la source).
Id_Patient	INT	FK	Non	Patient consulté → DIM_Patient.
Id_Temps	INT	FK	Non	Date de la consultation → DIM_Temps.
Id_Professionnel	INT	FK	Non	Professionnel qui réalise la consultation → DIM_Professionnel.
Id_Diagnostic	INT	FK	Non	Diagnostic posé → DIM_Diagnostic (membre « Non renseigné » si absent).
Id_Etablissement	INT	FK	Non	Établissement où se tient la consultation → DIM_Etablissement.
Nombre_de_consultation	INT		Non	Mesure additive, vaut 1 par ligne. Sa somme donne le nombre de consultations.

FAIT_HOSPITALISATION

Type : Table de faits. **Grain** : 1 ligne = 1 séjour hospitalier d'un patient dans un établissement.
Source : fichier Hospitalisations.csv (séjours hospitaliers).
Besoins couverts : 3, 4 et 5.

Attribut	Type	Clé	Null	Description
Id_Hospitalisation	INT	PK	Non	Clé de substitution du séjour.
Id_Patient	INT	FK	Non	Patient hospitalisé → DIM_Patient.
Id_Etablissement	INT	FK	Non	Établissement d'accueil → DIM_Etablissement.
Id_Diagnostique	INT	FK	Non	Diagnostic à l'origine du séjour → DIM_Diagnostic.
Id_Date_Entree	INT	FK	Non	Date d'entrée du séjour → DIM_Temps (rôle « date d'entrée »).
Num_Hospitalisation	VARCHAR(20)	DD	Non	Dimension dégénérée : numéro du séjour dans la source, conservé pour la traçabilité.
Jour_Hospitalisation	INT		Oui	Mesure additive : durée du séjour en jours.

FAIT_SATISFACTION

Type : Table de faits. **Grain** : 1 ligne = 1 résultat d'enquête de satisfaction pour un établissement et une année.
Source : résultats e-Satis 48h MCO de 2017, 2019 et 2020, fichiers déposés sur le serveur FTP.
Besoins couverts : 8.

Attribut	Type	Clé	Null	Description
Id_Satisfaction	INT	PK	Non	Clé de substitution du résultat d'enquête.
Id_Etablissement	INT	FK	Non	Établissement évalué → DIM_Etablissement.
Id_Region	INT	FK	Non	Région de l'établissement, retrouvée par sa commune → DIM_Region_INSEE. Membre -1 « Inconnu » si la commune est absente.
ParticipationObligatoire	BOOLEAN		Oui	Indique si l'établissement était tenu de participer à l'enquête.
DepotValide	BOOLEAN		Oui	Indique si le dépôt des résultats a été validé.
NbReponses	INT		Oui	Mesure additive : nombre de questionnaires exploitables.
Score	NUMERIC(5,2)		Oui	Mesure non additive : score global de satisfaction. Agrégé en moyenne pondérée par NbReponses.
Annee	INT		Non	Année de l'enquête (2017, 2019 ou 2020), ajoutée par le job J09.

FAIT_DECES

Type : Table de faits. **Grain** : 1 ligne = 1 décès enregistré dans le fichier INSEE (deces.csv, environ 25 millions de lignes).
Source : fichier des personnes décédées de l'INSEE (open data), déposé sur le serveur FTP.
Besoins couverts : 7.

Attribut	Type	Clé	Null	Description
Id_Deces	INT	PK	Non	Clé de substitution du décès.
Id_Temps	INT	FK	Non	Date du décès → DIM_Temps (rôle « date de décès »).
Id_Region_Deces	INT	FK	Non	Lieu du décès → DIM_Region_INSEE (rôle « lieu de décès »). Membre -1 « Inconnu » si le code est vide.
Id_Region_Naissance	INT	FK	Non	Lieu de naissance → DIM_Region_INSEE (rôle « lieu de naissance »).
Age_Deces	INT		Oui	Âge au décès en années, calculé à partir des dates de naissance et de décès.
Annee_Naissance	INT		Oui	Année de naissance. Seule l'année est conservée (minimisation RGPD).
Numero_Actes_Deces	VARCHAR(10)	DD	Oui	Dimension dégénérée : numéro de l'acte de décès, utile au dédoublonnage.
Flag_Date_Partielle	BOOLEAN		Non	Vrai si la date de naissance ou de décès est incomplète dans la source (ex. « 1930 », « 1989-05 »).
Date_Chargement	TIMESTAMP		Non	Horodatage du chargement de la ligne (traçabilité ETL).

DIM_Temps

Type : Dimension conforme. **Grain** : 1 ligne = 1 jour calendaire.
Source : générée par l'ETL (calendrier du 1er janvier 1880 au 31 décembre 2030), partagée par les faits Consultation, Hospitalisation et Décès.
Besoins couverts : tous (axe « période »).

Attribut	Type	Clé	Null	Description
Id_Temps	INT	PK	Non	Clé au format AAAAMMJJ (ex. 20190315), lisible et triable.
Date	DATE		Non	Date complète.
Jour	INT		Non	Jour du mois (1 à 31).
Semaine	INT		Non	Numéro de semaine ISO (1 à 53).
Mois	INT		Non	Mois (1 à 12).
Trimestre	INT		Non	Trimestre (1 à 4).
Semestre	INT		Non	Semestre (1 ou 2).
Annee	INT		Non	Année civile.

DIM_Patient

Type : Dimension sans données identifiantes. **Grain** : 1 ligne = 1 patient (un numéro de sécurité sociale).
Source : base opérationnelle PostgreSQL (table des patients). Seuls l'identifiant, le sexe et l'âge sont chargés, le minimum nécessaire au besoin 5 ; les autres colonnes (nom, prénom, adresse, numéro de sécurité sociale, données médicales. . .) restent dans la base de soins.
Besoins couverts : 5 (sexe, âge).

Attribut	Type	Clé	Null	Description
Id_Patient	INT	PK	Non	Identifiant du patient dans la base de soins, repris tel quel : c'est un numéro interne, qui ne permet pas à lui seul d'identifier la personne.
Sexe	CHAR(1)		Non	Sexe (M, F, I pour inconnu).
Age	INT		Oui	Âge du patient en années, repris tel quel de la base de soins.

DIM_Diagnostic

Type : Dimension. **Grain** : 1 ligne = 1 code diagnostic.
Source : base opérationnelle PostgreSQL (table des diagnostics).
Besoins couverts : 2 et 4.

Attribut	Type	Clé	Null	Description
Id_Diagnostic	INT	PK	Non	Clé de substitution du diagnostic.
Code_Diagnostic	VARCHAR(10)	BK	Non	Code du diagnostic dans la source (clé métier).
Diagnostic	VARCHAR(255)		Non	Libellé du diagnostic.

DIM_Etablissement

Type : Dimension conforme. **Grain** : 1 ligne = 1 site géographique d'établissement (FINESS site).
Source : fichier CSV de gestion administrative des établissements (référentiel FINESS).
Besoins couverts : 1 et 8 ; partagée par Consultation, Hospitalisation et Satisfaction.

Attribut	Type	Clé	Null	Description
Id_Etablissement	INT	PK	Non	Clé de substitution de l'établissement.
Finess_Site	CHAR(9)	BK	Non	Numéro FINESS du site géographique (clé métier).
Finess_Etablissement_Juridique	CHAR(9)	BK	Oui	Numéro FINESS de l'entité juridique de rattachement (clé métier).
Identifiant_Organisation	VARCHAR(30)		Oui	Identifiant de l'organisation dans le référentiel ; pour un établissement de santé, il vaut « F » suivi du numéro FINESS.
Raison_Sociale_Site	VARCHAR(255)		Non	Raison sociale du site.
Enseigne_Commerciale_Site	VARCHAR(255)		Oui	Enseigne commerciale du site.
Adresse	VARCHAR(255)		Oui	Adresse du site.
Code_Commune	CHAR(5)		Oui	Code commune INSEE du site (permet le rattachement à la région).
Code_Postal	CHAR(5)		Oui	Code postal du site.
Commune	VARCHAR(100)		Oui	Nom de la commune.
Pays	VARCHAR(50)		Oui	Pays.

DIM_Professionnel

Type : Dimension. **Grain** : 1 ligne = 1 professionnel de santé.
Source : base opérationnelle PostgreSQL (professionnels et spécialités) ; la commune d'exercice vient du fichier professionnel_sante.csv.
Besoins couverts : 6.

Attribut	Type	Clé	Null	Description
Id_Professionnel	INT	PK	Non	Clé de substitution du professionnel.
Identifiant	VARCHAR(20)	BK	Non	Identifiant national du professionnel (clé métier).
Type_Identifiant	VARCHAR(10)		Non	Nature de l'identifiant (ex. RPPS, ADELI).
Civilite	VARCHAR(10)		Oui	Civilité.
Nom	VARCHAR(100)		Non	Nom d'exercice.
Prenom	VARCHAR(100)		Oui	Prénom d'exercice.
Categorie_Professionnelle	VARCHAR(50)		Oui	Catégorie (civil, militaire, étudiant. . .).
Profession	VARCHAR(100)		Oui	Profession exercée (médecin, infirmier. . .).
Specialite	VARCHAR(150)		Oui	Spécialité ou savoir-faire.
Commune	VARCHAR(100)		Oui	Commune d'exercice.

DIM_Region_INSEE

Type : Dimension conforme, à rôles multiples. **Grain** : 1 ligne = 1 commune INSEE, avec son département et sa région. Membre -1 « Inconnu » pour les codes vides.
Source : Code officiel géographique de l'INSEE (39 521 codes : communes actuelles et anciennes, outre-mer, pays étrangers).
Besoins couverts : 7 et 8 ; jouée deux fois par FAIT_DECES (lieu de décès, lieu de naissance) et une fois par FAIT_SATISFACTION (région de l'établissement).

Attribut	Type	Clé	Null	Description
Id_Region	INT	PK	Non	Clé de substitution de la commune.
Code_Commune_INSEE	CHAR(5)	BK	Oui	Code commune INSEE (2A/2B pour la Corse, 99xxx pour l'étranger). Clé métier.
Code_Departement	VARCHAR(3)		Oui	Code du département (3 caractères pour les DROM : 971 à 976).
Nom_Departement	VARCHAR(100)		Oui	Nom du département.
Code_Region	VARCHAR(3)		Oui	Code de la région (ex. 84).
Nom_Region	VARCHAR(100)		Oui	Nom de la région (ex. Auvergne-Rhône-Alpes).
Pays	VARCHAR(60)		Oui	Pays (France ou pays étranger).
Type_Zone	VARCHAR(10)		Non	Métropole, DROM, COM, Étranger ou Inconnu.

EN RÉSUMÉ

Le modèle décisionnel du CHU est une **constellation** construite selon l'approche de Kimball :

- **quatre tables de faits**, une par processus métier (Consultations, Hospitalisations, Satisfaction, Décès), chacune au grain le plus fin disponible dans les sources ;
- **six dimensions** (Temps, Établissement, Patient, Diagnostic, Professionnel, Région INSEE), dont trois **conformes**, Temps, Établissement et Région INSEE, partagées par plusieurs faits pour croiser les indicateurs ;
- des relations toutes **un-à-plusieurs**, traduites en clés étrangères non nulles vers des dimensions identifiées par des **clés de substitution** (sauf DIM_Patient, qui garde l'identifiant de la base de soins) ;
- des hiérarchies (Commune $\rightarrow$ Département $\rightarrow$ Région, Jour $\rightarrow$ Mois $\rightarrow$ Trimestre $\rightarrow$ Année) dénormalisées dans leur dimension, sans schéma en flocon.

Chaque besoin du CHU se calcule à partir d'une seule table de faits et de ses dimensions. Le dictionnaire de données décrit les dix tables, leurs attributs, leurs types et leurs clés ; il sert de référence aux jobs ETL et à l'implémentation physique du livrable 2.

3 SPÉCIFICATIONS FONCTIONNELLES DES JOBS ETL

Les jobs ETL (*Extract, Transform, Load*) alimentent l'entrepôt : ils extraient les données des sources, les transforment pour respecter le modèle cible, puis les chargent dans l'entrepôt. Ils sont développés dans **Talend Open Studio for Big Data** (version 7.3) : chaque table de l'entrepôt est alimentée par un job, et un job maître les enchaîne. La cible finale est Hive ; pour le développement, l'entrepôt est sur PostgreSQL.

Tous les jobs suivent le même modèle : une **source** (table PostgreSQL ou fichier), un composant **tMap** qui nettoie les données et remplace les codes par les clés des dimensions, puis la **table** de l'entrepôt. Sur les schémas, une flèche orange porte les données ; une flèche partant d'un composant placé au-dessus du tMap est une table de correspondance (*lookup*) ; une flèche verte « OnSubjobOk » signifie « lancer la suite si l'étape précédente a réussi ».

3.1 VUE D'ENSEMBLE

Le job maître **PROJET_CHU** lance les onze jobs dans l'ordre imposé par les clés étrangères : d'abord la remise à zéro (J00), puis les dimensions (J01 à J06), enfin les faits (J07 à J10), qui ont besoin des clés des dimensions. Si un job échoue, la chaîne s'arrête et l'erreur est inscrite dans un journal.

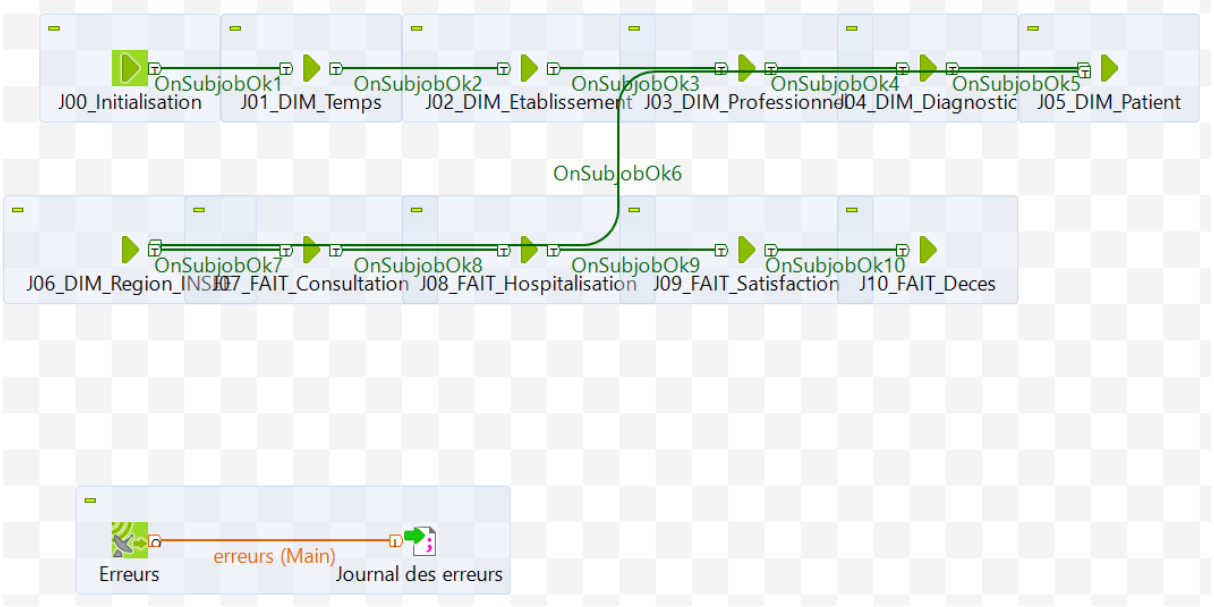


Figure 4 – Job maître PROJET_CHU

Le tableau suivant résume, pour chaque job, sa source, la table qu'il alimente et sa fréquence d'exécution. Le job maître est planifié chaque nuit à 2 h, en dehors des heures d'activité de la base de soins ; les sources qui changent moins souvent ne sont relues qu'à leur publication.

Job	Source	Table alimentée	Fréquence
J00	–	Toutes (remise à zéro)	À chaque exécution
J01	Calendrier généré	DIM_Temps	Une seule fois
J02	etablissement_sante.csv	DIM_Etablissement	Quotidienne
J03	Base de soins (professionnels, spécialités) et professionnel_sante.csv	DIM_Professionnel	Quotidienne
J04	Base de soins (diagnostics)	DIM_Diagnostic	Quotidienne
J05	Base de soins (patients)	DIM_Patient	Quotidienne
J06	Code officiel géographique de l'INSEE	DIM_Region_INSEE	Annuelle
J07	Base de soins (consultations) et activite_professionnel_sante.csv	FAIT_CONSULTATION	Quotidienne
J08	Hospitalisations.csv	FAIT_HOSPITALISATION	Quotidienne
J09	Résultats e-Satis (serveur FTP)	FAIT_SATISFACTION	Annuelle
J10	Fichier des décès de l'INSEE (serveur FTP)	FAIT_DECES	Mensuelle

3.2 RÈGLES COMMUNES À TOUS LES JOBS

Transformations

- les textes sont débarrassés de leurs espaces en début et en fin de chaîne, et les codes (FINESS, INSEE, diagnostic) sont mis en majuscules ;
- les dates sont converties en clé de DIM_Temps au format AAAAMMJJ (par exemple 20190315) ;
- chaque code de la source est remplacé par la clé de sa dimension, lue dans une table de correspondance du tMap.

Valeurs nulles et doublons

- une clé absente ou introuvable n'est jamais laissée vide : la ligne est rattachée au membre « Inconnu » (clé -1) de la dimension, pour rester comptée dans les totaux ;
- une mesure absente reste à NULL : la remplacer par zéro fausserait les moyennes ;
- les doublons sont supprimés sur la clé métier (code, identifiant ou numéro de la source).

Lignes écartées et erreurs

Une ligne invalide n'arrête pas le job : le filtre du tMap l'écarte et elle n'est pas chargée. Quatre contrôles sont appliqués :

- **format** : une date ou un nombre illisible (date de décès « 2016-02-30 ») ;
- **champ obligatoire** : un champ obligatoire vide (professionnel sans nom) ;
- **cohérence** : une valeur hors des bornes métier (âge au décès supérieur à 120 ans, heure de fin avant l'heure de début) ;
- **référence** : une ligne qui renvoie à un patient ou un professionnel introuvable.

Une erreur technique (base inaccessible, fichier absent) arrête la chaîne : le job maître n'enchaîne pas la suite et inscrit l'erreur dans un journal, avec la date, le job et le message.

3.3 LES JOBS UN PAR UN

J00 – Initialisation

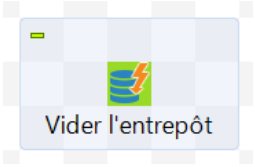


Figure 5 – Job J00 – Initialisation

Source : aucune.

Traitement :

1. une requête SQL vide toutes les tables de l'entrepôt ;
2. elle crée les membres « Inconnu » (clé -1) des dimensions Patient, Diagnostic, Établissement et Professionnel.

Valeurs nulles et doublons : sans objet : chaque exécution repart d'un entrepôt propre.

J01 – DIM_Temps

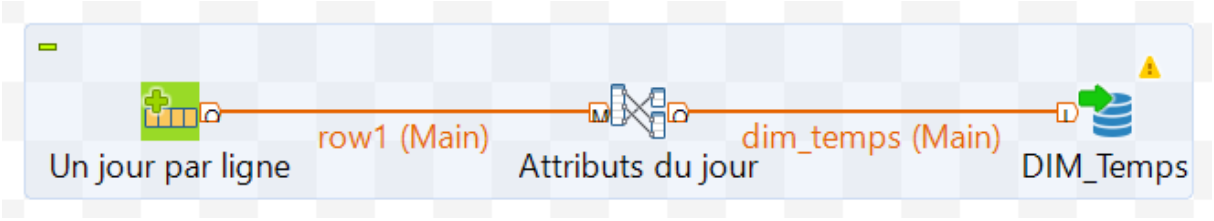


Figure 6 – Job J01 – DIM_Temps

Source : aucune : le calendrier est généré.

Traitement :

1. le composant tRowGenerator produit une ligne par jour, du 1er janvier 1880 au 31 décembre 2030 (le plus ancien décès date de 1882) ;
2. le tMap calcule pour chaque jour la clé AAAAMMJJ, le jour, la semaine, le mois, le trimestre, le semestre et l'année.

Valeurs nulles et doublons : aucune valeur absente ; chaque jour est unique.

J02 – DIM_Etablissement

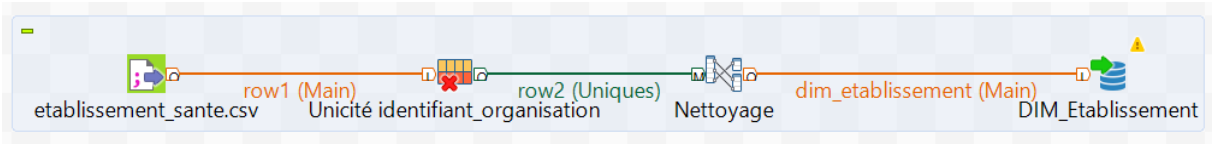


Figure 7 – Job J02 – DIM_Etablissement

Source : fichier etablissement_sante.csv (416 665 lignes).

Traitement :

1. le tUniqRow garde une seule ligne par identifiant d'organisation ;
2. le tMap attribue une clé à chaque établissement et laisse de côté les colonnes de contact (téléphone, courriel).

Valeurs nulles et doublons : la commune est vide sur un tiers des lignes et reste à NULL ; 25 lignes sans raison sociale sont écartées.

J03 – DIM_Professionnel

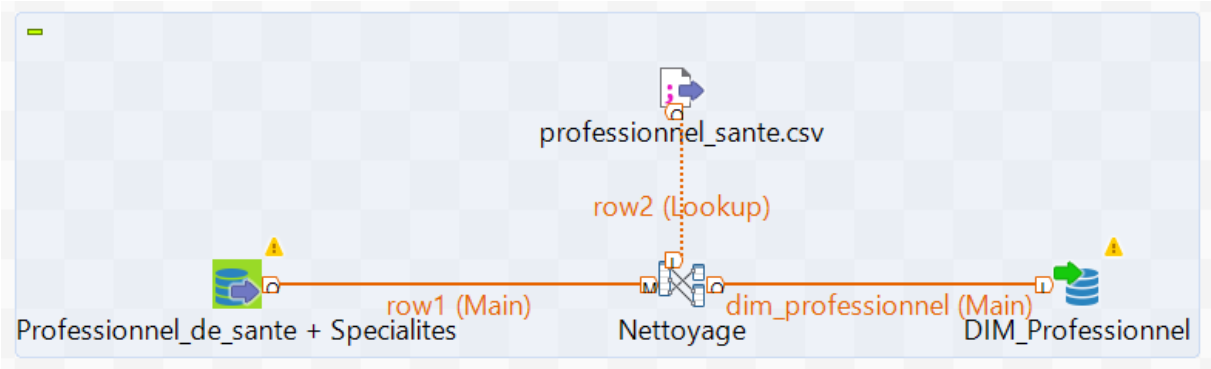


Figure 8 – Job J03 – DIM_Professionnel

Source : trois sources, qui se complètent :

- la table **Professionnel_de_sante** de la base de soins (1 048 575 professionnels) : identifiant, nom, prénom, profession et *code* de spécialité ;
- la table **Specialites** de la même base : elle donne le *libellé* de chaque code de spécialité (par exemple « Anesthésie-réanimation ») ;
- le fichier **professionnel_sante.csv**, extrait de l'annuaire national des professionnels de santé : il donne la *commune d'exercice*, absente de la base de soins.

La table Specialites est reliée aux professionnels par la clé **Code_specialite**, présente dans les deux tables ; le fichier leur est relié par l'identifiant national du professionnel (numéro RPPS ou ADELI), présent des deux côtés. Sans ces rapprochements, la dimension n'aurait ni libellé de spécialité ni commune, deux axes utiles pour analyser les consultations par professionnel (besoin 6).

Traitement :

1. la requête lit les professionnels et les croise avec la table Specialites grâce à la clé Code_specialite, pour remplacer le code par son libellé ;
2. le tMap cherche chaque professionnel dans professionnel_sante.csv, par son identifiant, et récupère sa commune d'exercice ;
3. il met le nom en majuscules et attribue une clé à chaque professionnel.

Valeurs nulles et doublons : civilité et prénom vides restent à NULL ; 2 professionnels sans nom sont écartés ; les 1 048 575 professionnels sont tous retrouvés dans le fichier.

J04 – DIM_Diagnostic

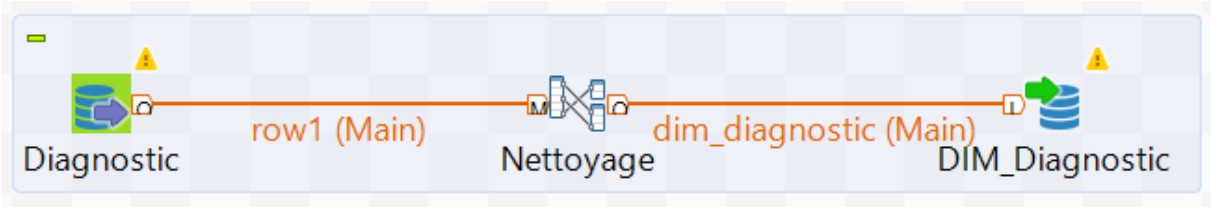


Figure 9 – Job J04 – DIM_Diagnostic

Source : table des diagnostics de la base de soins (15 490 codes).

Traitement :

1. le tMap met les codes en majuscules et attribue une clé à chaque diagnostic.

Valeurs nulles et doublons : aucune valeur absente ; un diagnostic manquant dans les faits pointe vers le membre « Non renseigné ».

J05 – DIM_Patient

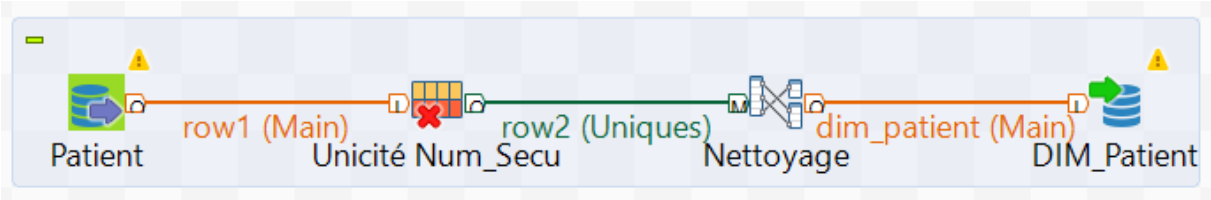


Figure 10 – Job J05 – DIM_Patient

Source : table des patients de la base de soins (100 000 patients).

Traitement :

1. la requête lit seulement l'identifiant, le numéro de sécurité sociale, le sexe et l'âge ; la date de naissance n'est pas lue ;
2. le tUniqRow garde un seul patient par numéro de sécurité sociale ;
3. le tMap ne conserve que trois colonnes : l'identifiant, le sexe recodé (F, M, I) et l'âge, repris tel quel.

Le numéro de sécurité sociale n'entre pas dans l'entrepôt. L'identifiant du patient dans la base de soins sert directement de clé : les consultations et les hospitalisations le retrouvent sans table de correspondance.

Valeurs nulles et doublons : aucun doublon sur le numéro de sécurité sociale ; sexe inconnu → I ; l'âge est renseigné pour tous les patients.

J06 – DIM_Region_INSEE

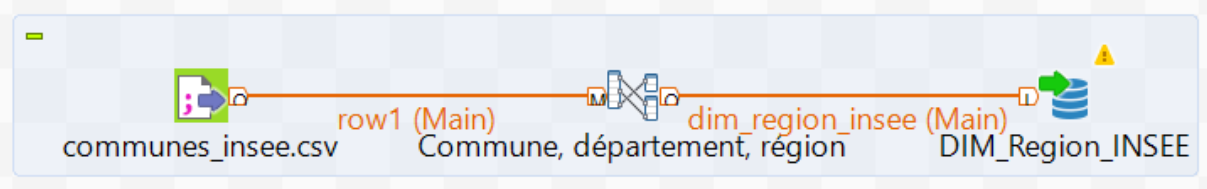


Figure 11 – Job J06 – DIM_Region_INSEE

Source : Code officiel géographique de l'INSEE (39 521 codes : communes actuelles et anciennes, outre-mer, pays étrangers).

Traitement :

1. chaque commune est chargée avec son département, sa région et son type de zone (Métropole, DROM, COM, Étranger).

Valeurs nulles et doublons : département et région restent à NULL pour les pays étrangers ; le membre « Inconnu » est fourni par le référentiel.

J07 – FAIT_CONSULTATION

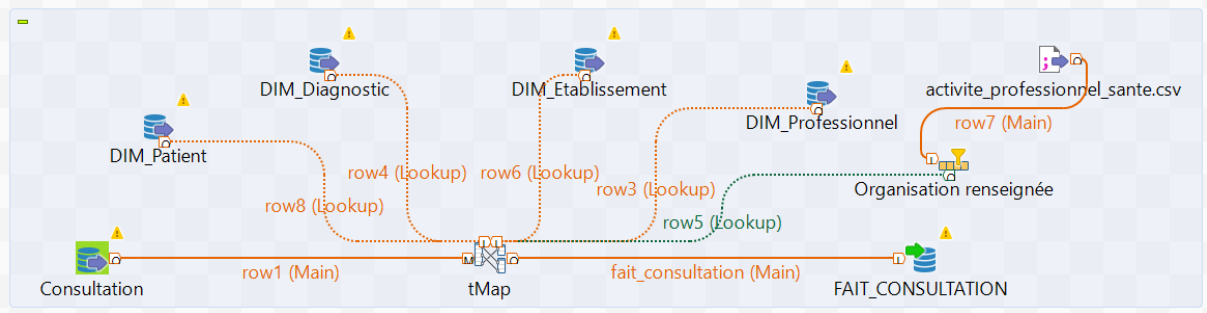


Figure 12 – Job J07 – FAIT_CONSULTATION

Source : table des consultations de la base de soins (1 027 157 consultations, 2015 à 2023).

Traitement :

1. le tMap remplace chaque code par la clé de sa dimension, grâce à quatre lookups : DIM_Patient, DIM_Professionnel, DIM_Diagnostic et DIM_Etablissement ;
2. il convertit la date de la consultation en clé de DIM_Temps (AAAAMMJJ) ;
3. la base n'indique pas l'établissement : il est déduit du professionnel. Le fichier activite_professionnel_sante.csv donne les organisations où il exerce ; le tFilterRow « Organisation renseignée » garde les lignes utiles, puis le lookup DIM_Etablissement donne la clé de cette organisation.

Valeurs nulles et doublons : professionnel sans organisation connue (36 % des consultations) $\rightarrow$ établissement -1 ; 10 consultations dont l'heure de fin précède l'heure de début et 10 consultations de professionnels écartés ne sont pas chargées.

J08 – FAIT_HOSPITALISATION

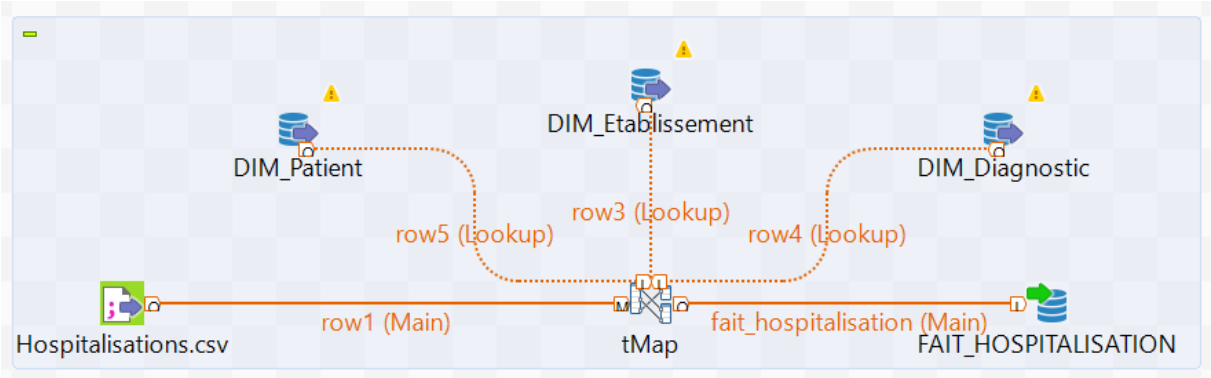


Figure 13 – Job J08 – FAIT_HOSPITALISATION

Source : fichier Hospitalisations.csv (2 479 séjours, 2015 à 2021).

Traitement :

1. le tMap retrouve le patient, l'établissement et le diagnostic grâce à trois lookups, DIM_Patient, DIM_Etablissement et DIM_Diagnostic (100 % des séjours rapprochés) ;
2. il convertit la date d'entrée en clé de DIM_Temps ;
3. il conserve le numéro du séjour pour la traçabilité.

Valeurs nulles et doublons : aucune valeur absente ; durée absente → NULL.

J09 – FAIT_SATISFACTION

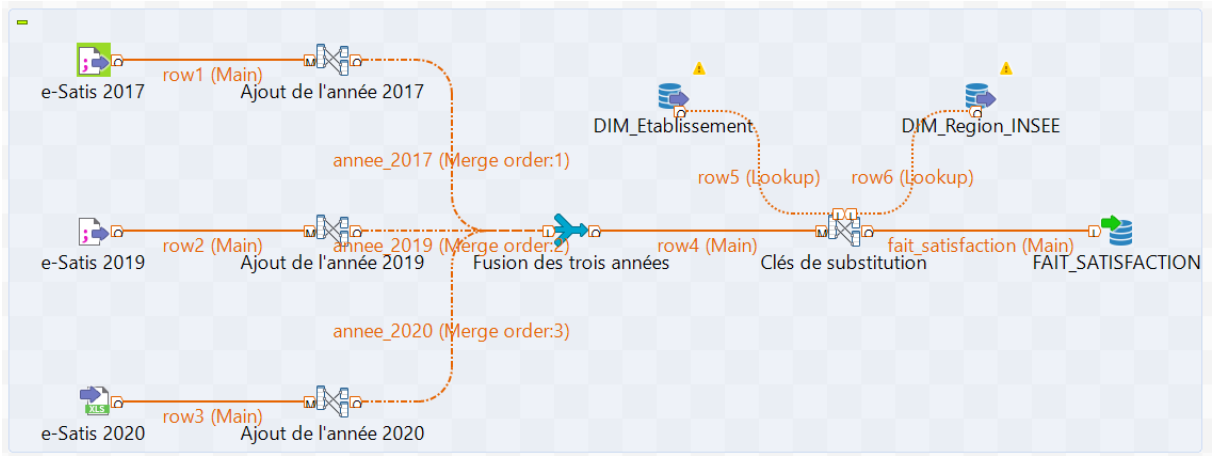


Figure 14 – Job J09 – FAIT_SATISFACTION

Source : résultats e-Satis 48h MCO de 2017 et 2019 (CSV) et de 2020 (Excel), environ 1 150 établissements par an.

Traitement :

1. les fichiers n'indiquent pas leur année : un tMap par fichier ajoute une colonne **annee** (2017, 2019 ou 2020) ;
2. le tUnite réunit les trois fichiers en un seul flux ;
3. le tMap principal retrouve l'établissement par son numéro FINESS, puis sa région par sa commune dans DIM_Region_INSEE ;
4. « 1- Obligatoire » devient VRAI, la virgule décimale devient un point, et l'année est chargée dans la colonne Annee.

Valeurs nulles et doublons : score vide quand l'établissement a moins de 30 réponses ou n'a pas répondu (environ un tiers des lignes) : la ligne est chargée avec un score NULL, exclu des moyennes ; établissement introuvable $\rightarrow$ établissement et région -1.

J10 – FAIT_DECES

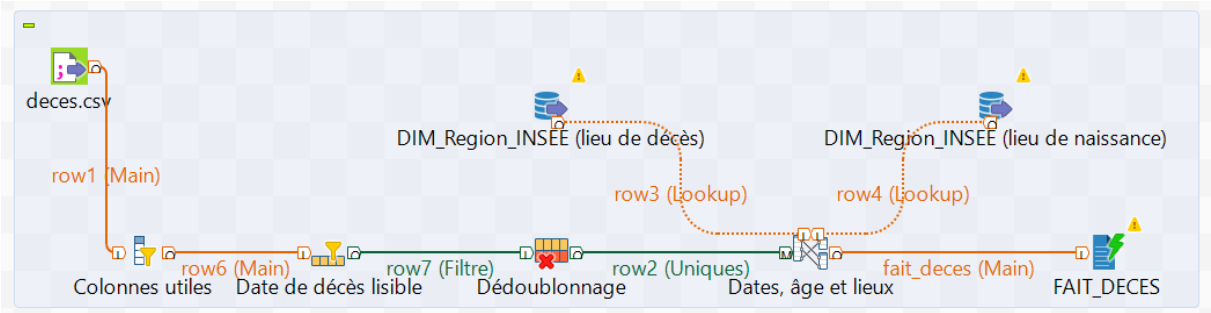


Figure 15 – Job J10 – FAIT_DECES

Source : fichier des personnes décédées de l'INSEE (25 088 208 lignes, 2 Go).

Traitement :

1. le tFilterColumns ne garde que les 7 colonnes utiles sur 10 ;
2. le tFilterRow écarte les dates de décès illisibles ;
3. le tUniqRow supprime les doublons ;
4. le tMap complète les dates partielles (« 1989-05 » $\rightarrow$ 1989-05-01, signalées par un indicateur), calcule l'âge au décès et convertit la date en clé de DIM_Temps ;
5. deux lookups sur DIM_Region_INSEE retrouvent la région du lieu de décès et celle du lieu de naissance ;
6. le tPostgresqlOutputBulkExec charge les lignes en masse avec la commande COPY de PostgreSQL.

Seule l'année de naissance est conservée ; nom et prénom ne sont pas chargés. Réduire le flux dès le début et charger en masse accélère nettement le traitement des 25 millions de lignes.

Valeurs nulles et doublons : 161 112 doublons exacts supprimés ; lieu de décès vide (10 934 lignes) $\rightarrow -1$; âge négatif ou supérieur à 120 ans $\rightarrow$ ligne écartée.

EN RÉSUMÉ

Onze jobs Talend, lancés chaque nuit par un job maître, alimentent l'entrepôt :

- chaque job suit le même modèle : source, tMap, table ;
- les codes deviennent des clés de dimension, et les données identifiantes des patients ne sont pas chargées ;
- clé absente $\rightarrow$ membre « Inconnu », mesure absente $\rightarrow$ NULL, doublons supprimés ;
- lignes invalides écartées, erreur technique inscrite dans un journal ;
- chargement accéléré des décès : données réduites au début, chargement en masse à la fin.

4 PLAN DE GOUVERNANCE DES DONNÉES

4.1 CONFORMITÉ RGPD : PROTECTION ET TRAITEMENT DES DONNÉES DE SANTÉ

Cet axe explique comment traiter les données personnelles et sensibles chargées dans l'entrepôt. Les plus sensibles sont celles des patients, issues de la base opérationnelle PostgreSQL (DIM_Patient) : ce sont des données de santé à caractère personnel, que le RGPD classe parmi les données sensibles. Les professionnels de santé (DIM_Professionnel) et les personnes décédées (FAIT_DECES) font aussi l'objet de règles, détaillées ci-dessous.

- **Principe de minimisation (Article 5 du RGPD) :** Les données strictement identifiantes et non nécessaires aux statistiques médicales (comme le *Nom*, le *Prénom*, l'*Adresse*, le *Téléphone*, l'*Email* et le *numéro de sécurité sociale* de la table des patients de la base de soins) sont supprimées dès l'étape d'extraction par Talend et n'entrent jamais dans le Data Warehouse (Hive). Le numéro de sécurité sociale n'est lu que pour garantir qu'une même personne n'apparaît qu'une fois, puis il est écarté : DIM_Patient ne conserve que l'identifiant du patient, son sexe et son âge, le minimum nécessaire au besoin 5.
- **Précision concernant les données démographiques :** L'âge exact est conservé à la place de la date de naissance complète. Cette dernière, étant considérée comme une donnée indirectement identifiante (susceptible de permettre la réidentification d'une personne), est soumise aux mêmes règles de protection que les données à caractère personnel.
- **Cas des personnes décédées :** Le RGPD ne s'applique pas aux données des personnes décédées. Par prudence, le fichier des décès de l'INSEE est tout de même minimisé : le nom et le prénom servent uniquement à supprimer les doublons et ne sont pas chargés, et seule l'année de naissance est conservée dans FAIT_DECES.
- **Cas des professionnels de santé :** Contrairement aux patients, les données des praticiens (médecins, personnel) sont conservées en clair dans la table DIM_Professionnel (nom, prénom, profession, spécialité, commune d'exercice), car elles relèvent de données professionnelles nécessaires au pilotage de l'activité hospitalière et aux indicateurs demandés par le CHU (besoin 6, consultations par professionnel). Ce sont tout de même des données personnelles : leur accès est limité par les droits décrits en partie 4.3.

4.2 CONFORMITÉ HDS (HÉBERGEMENT DE DONNÉES DE SANTÉ)

Puisque notre architecture manipule des données de santé à caractère personnel, l'infrastructure globale (le cluster Hadoop / HDFS et les environnements de stockage) doit respecter la législation française et européenne :

- **Certification de l'hébergeur :** L'infrastructure devant supporter l'environnement Big Data doit reposer sur un hébergeur certifié HDS (Hébergeur de Données de Santé), garantissant que les serveurs physiques sont situés sur le territoire européen et soumis aux normes de sécurité strictes de l'Agence du numérique en santé (ANS, ex-ASIP Santé).
- **Chiffrement des données :**
  - *Au repos :* Les données stockées dans les blocs HDFS font l'objet d'un chiffrement avec Ranger KMS puis un algorithme AES/CTR/NoPadding sur disque pour empêcher tout accès non autorisé aux fichiers.
  - *En transit :* Les flux de données circulant entre les sources (CSV,PostgreSQL, serveurs FTP) et l'ETL (Talend) sont sécurisés en SSL/TLS, et de Talend au stockage HDFS on utilise Kerberos qui servira de frontière entre les deux.

4.3 GESTION DES RÔLES ET DES DROITS D'ACCÈS (RBAC - ROLE-BASED ACCESS CONTROL)

Pour s'assurer que seuls les utilisateurs habilités accèdent aux informations correspondant à leur profil (praticien vs direction), on définit les droits d'accès à l'aide de quatre permissions : Read, Write, Full Control et Delete, qui permettent de préciser le niveau d'accès à une ressource.

- **Sécurité au niveau de la BI (Power BI) :** Mise en place de règles de filtrage par profil (RLS - *Row-Level Security*). Un administrateur de la direction d'établissement aura une vue macroscopique globale (consultations, hospitalisations, satisfaction et décès, aux niveaux national et régional), tandis qu'un praticien pourra consulter les indicateurs de son établissement ou de sa spécialité sans pouvoir remonter à des données nominatives.
- **Sécurité au niveau du stockage (Hive / Hadoop) :** Les privilèges d'accès aux tables du Data Warehouse sont restreints via des mécanismes de gestion des accès avec Apache Ranger. Seuls les profils techniques (Data Engineers) ont les droits de modification sur la couche Hive, tandis que les analystes accèdent uniquement aux tables agrégées de la couche analyse et visualisation.

4.4 TRAÇABILITÉ DES FLUX (AUDIT ET JOURNALISATION)

La traçabilité est un point clé de la gouvernance des données à caractère personnel ; elle impose de savoir d'où vient la donnée et comment elle a été transformée.

- **Traçabilité ETL (Talend) :** À chaque exécution, Talend affiche sur chaque flux le nombre de lignes lues et chargées, ce qui permet de mesurer les lignes écartées par les contrôles. Les erreurs techniques sont inscrites par le job maître dans un journal (fichier journal_erreurs.csv), avec l'horodatage, le nom du job et le message. Ces informations sont centralisées pour auditer la qualité des données de santé intégrées.
- **Traçabilité d'accès :** L'utilisation des outils de visualisation et de requêtage (Power BI / Hive) intègre un système d'historisation des connexions et des requêtes exécutées, permettant de répondre aux exigences de contrôle de la CNIL en cas d'audit sur l'utilisation des données hospitalières.

CONCLUSION

Ce premier livrable pose les fondations de l'entrepôt de données du CHU.

L'**architecture** retenue réunit les sources de soins, les référentiels et les fichiers publics dans un entrepôt unique, alimenté par Talend et exploité dans Power BI. Le **modèle dimensionnel** organise ces données en une constellation de quatre tables de faits et six dimensions, dont trois sont partagées pour croiser les indicateurs ; il couvre les huit besoins exprimés, y compris les deux besoins optionnels sur les décès et la satisfaction par région.

Les **jobs ETL** ont été développés et exécutés sur les données réelles : ils chargent plus d'un million de consultations, les séjours, trois années d'enquêtes de satisfaction et 25 millions de décès, en écartant les lignes invalides et sans charger de données identifiantes sur les patients.

Le **plan de gouvernance** encadre ces traitements : minimisation des données des patients au titre du RGPD, hébergement certifié HDS et chiffrement, droits d'accès par profil et traçabilité des flux et des accès.

Le livrable suivant portera sur l'implémentation physique : le passage de l'entrepôt sur Hive, le partitionnement et l'indexation des tables, les contrôles de qualité et la mesure des performances des requêtes.

GLOSSAIRE

Terme	Définition
Entrepôt de données (*Data Warehouse*)	Base unique et historisée, organisée pour l'analyse plutôt que pour la gestion quotidienne.
ETL	*Extract, Transform, Load* : extraire les données des sources, les transformer, puis les charger dans l'entrepôt.
Job Talend, job maître	Un job est un traitement ETL dessiné dans Talend ; le job maître lance les autres jobs dans l'ordre.
Kimball	Méthode de modélisation décisionnelle qui organise les données en faits et en dimensions.
Processus métier	Activité que l'on veut mesurer (consultation, hospitalisation, enquête, décès) ; il devient une table de faits.
Table de faits	Table qui enregistre les événements d'un processus métier et leurs mesures (nombre, durée, score).
Dimension	Table qui décrit un axe d'analyse (temps, patient, établissement. . .).
Dimension conforme	Dimension partagée par plusieurs tables de faits, avec les mêmes clés, pour croiser les indicateurs.
Dimension à rôles multiples	Dimension utilisée plusieurs fois par le même fait (lieu de décès et lieu de naissance).
Dimension dégénérée (DD)	Identifiant de la source gardé dans le fait, sans table de dimension (numéro de séjour).
Grain	Ce que représente une ligne d'une table de faits.
Schéma en étoile, constellation	Une table de faits entourée de ses dimensions forme une étoile ; plusieurs étoiles reliées par des dimensions conformes forment une constellation.
PK, FK, BK	Clé primaire, clé étrangère et clé métier (identifiant venu de la source).
Clé de substitution	Numéro attribué par l'ETL à chaque ligne d'une dimension, sans signification métier.
Membre « Inconnu » (-1)	Ligne d'une dimension qui reçoit les faits dont la valeur est absente ou introuvable.
Lookup	Table de correspondance consultée par le tMap pour remplacer un code par la clé d'une dimension.
tMap, tUniqRow, tFilterRow, tUnite	Composants Talend : transformation et jointures, suppression des doublons, filtrage des lignes, fusion de plusieurs flux.
Zone de transit (*staging*)	Espace où les données sont déposées telles qu'elles arrivent, avant leur nettoyage.
HDFS, Hive	Système de fichiers distribué de Hadoop, et moteur qui permet d'interroger ces fichiers en SQL.
RGPD	Règlement général sur la protection des données (UE 2016/679).
Minimisation	Principe du RGPD : ne traiter que les données strictement nécessaires à l'objectif.
CNIL	Commission nationale de l'informatique et des libertés, autorité française de protection des données.
HDS	Hébergeur de données de santé : certification obligatoire pour héberger des données de santé.
RBAC, RLS	Droits d'accès selon le rôle de l'utilisateur, et filtrage des lignes visibles selon ce rôle (Power BI).
FINESS	Fichier national des établissements sanitaires et sociaux.
RPPS, ADELI	Répertoires d'identification des professionnels de santé.
COG	Code officiel géographique de l'INSEE : liste des communes, départements et régions.
e-Satis	Mesure nationale de la satisfaction des patients hospitalisés, publiée par la Haute Autorité de santé.
MCO	Médecine, chirurgie, obstétrique : séjours hospitaliers de courte durée.

SITOGRAPHIE

Sites consultés en octobre 2026.

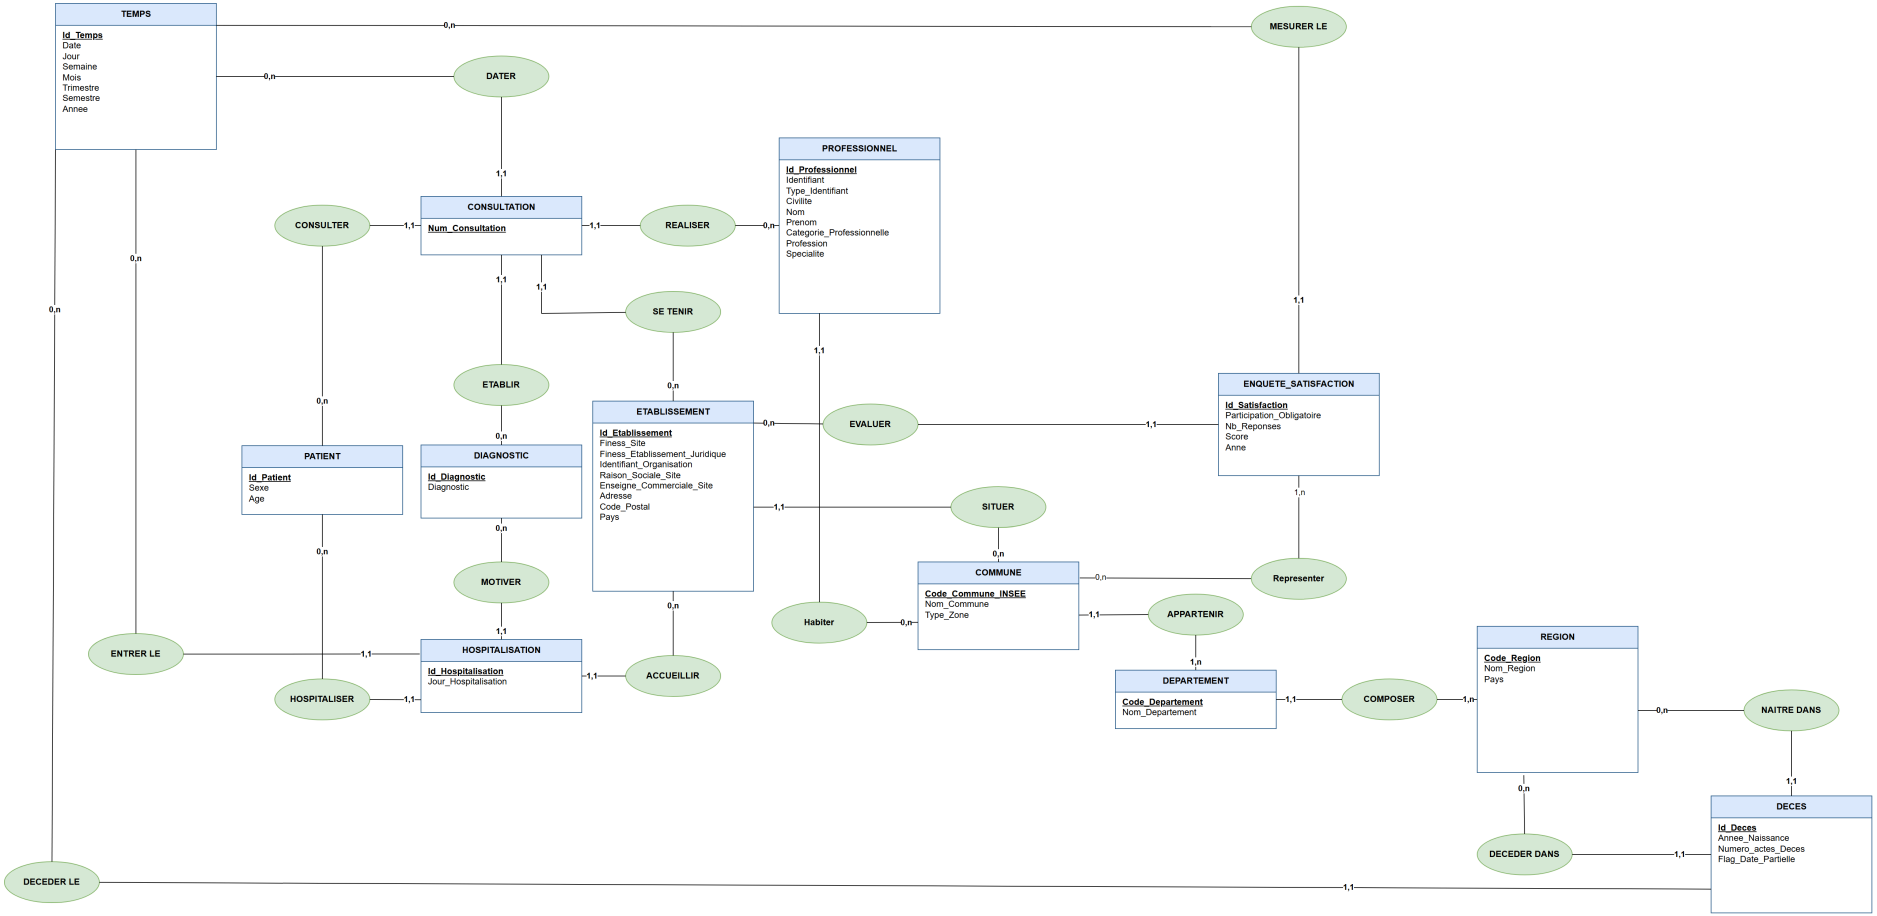
SOURCES DE DONNÉES

- INSEE, data.gouv.fr : *Fichier des personnes décédées*.
  https://www.data.gouv.fr/fr/datasets/fichier-des-personnes-decedees/
- INSEE : *Code officiel géographique 2026*.
  https://www.insee.fr/fr/information/8740218
- Haute Autorité de santé, data.gouv.fr : *Indicateurs de qualité et de sécurité des soins, mesure de la satisfaction (dispositif e-Satis)*.
  https://www.data.gouv.fr/datasets/indicateurs-de-qualite-et-de-securite-des-soins-mesure-de-la-satisfaction-dispositif-e-satis-recueil-2017
- Agence du numérique en santé : *Répertoire FINESS des établissements*.
  https://finess.esante.gouv.fr/
- Agence du numérique en santé, data.gouv.fr : *Annuaire Santé, données en libre accès des professionnels (RPPS)*.
  https://www.data.gouv.fr/datasets/annuaire-sante-extractions-des-donnees-en-libre-acces-des-professionnels-intervenant-dans-le-systeme-de-sante-rpps

RGPD ET DONNÉES DE SANTÉ

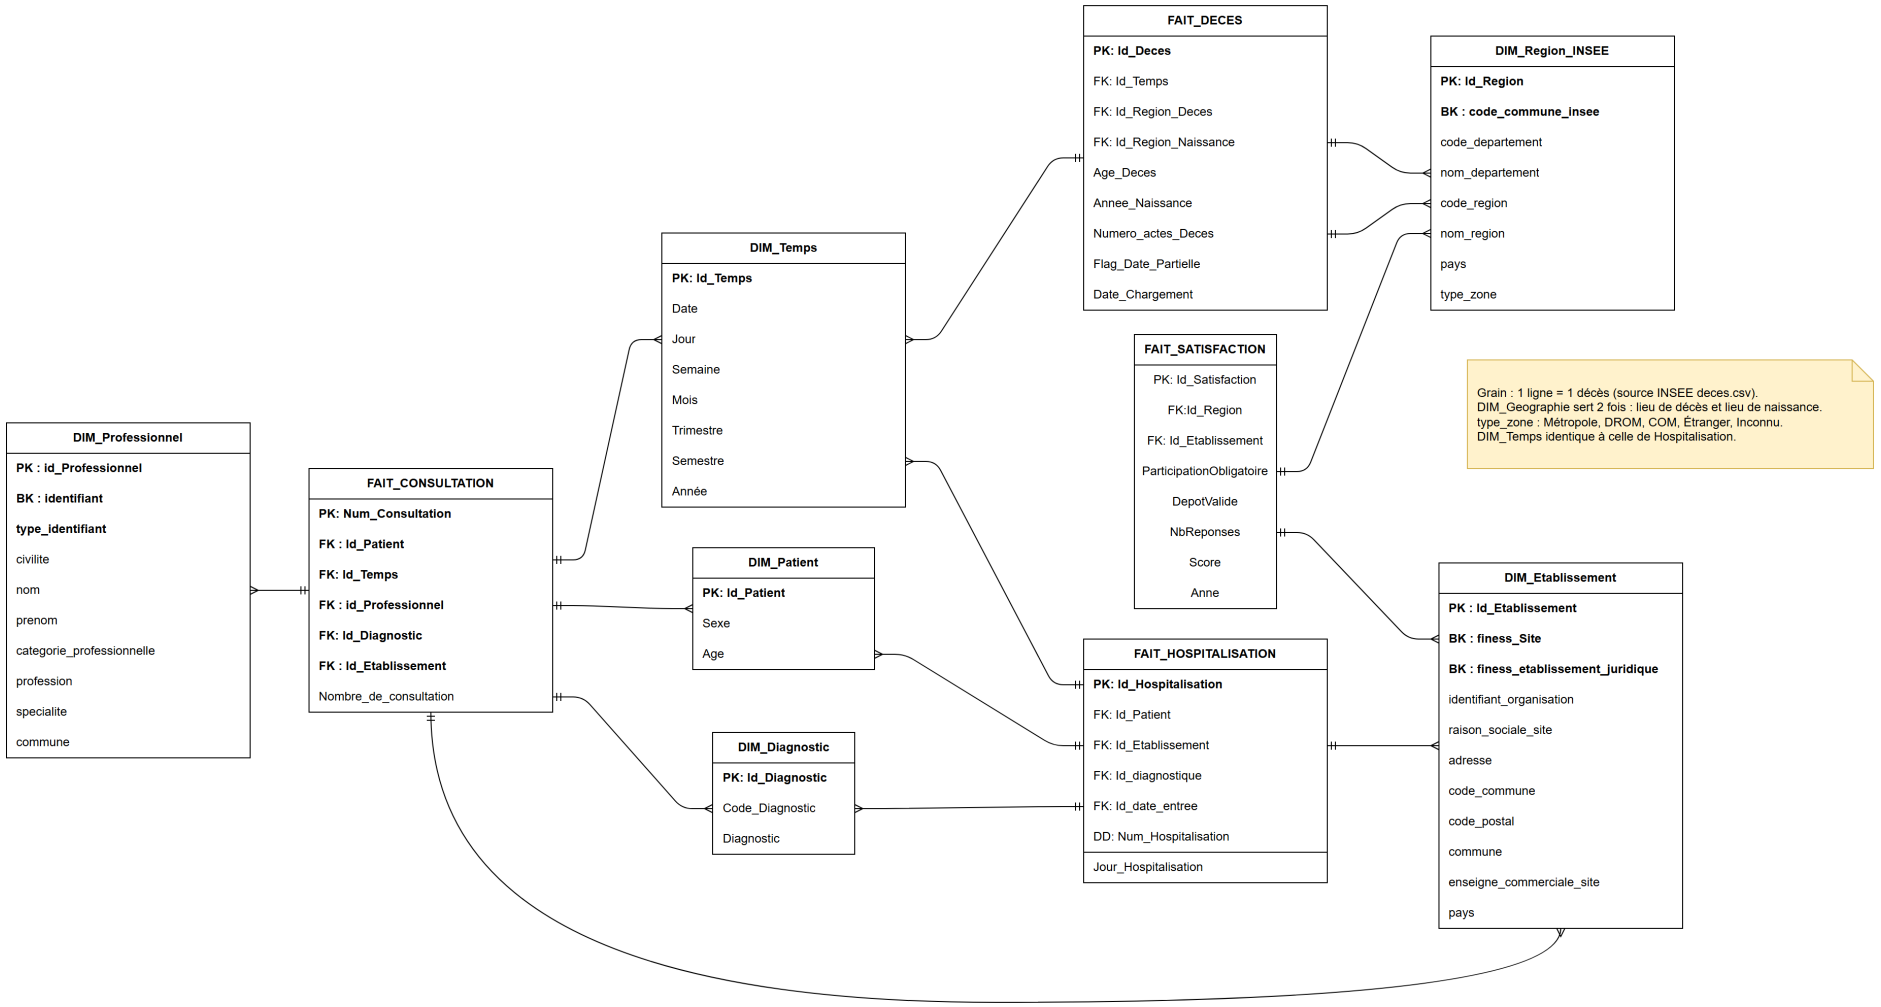
- CNIL : *RGPD, chapitre 2, article 5 : principes relatifs au traitement des données*.
  https://www.cnil.fr/fr/reglement-europeen-protection-donnees/chapitre2#Article5
- EUR-Lex : *Règlement (UE) 2016/679 du 27 avril 2016 (RGPD), texte intégral*.
  https://eur-lex.europa.eu/legal-content/FR/TXT/?uri=CELEX:32016R0679
- CNIL : *Santé : le traitement des données de santé*.
  https://www.cnil.fr/fr/sante
- Agence du numérique en santé : *Hébergement de données de santé (HDS)*.
  https://esante.gouv.fr/produits-services/hds

ANNEXE A – MODÈLE DIMENSIONNEL CONCEPTUEL



Voir partie 2.1

ANNEXE B – SCHÉMA LOGIQUE EN CONSTELLATION



Voir partie 2.2